Факультет инженерных наук Университета в Крагуевце

Название учебной программы: ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ
Уровень обучения: Магистерские академические студии
Предмет: Продвинутое машинное обучение
Номер индекса: 1ВИ/2023

Bogdan Babaev

Прогнозирование переменных во времени межрыночных зависимостей между криптовалютами и традиционными активами с применением машинного обучения

Магистерская работа

Комиссия по рецензии и защите:

1. проф. д-р Владимир М. Милованович — научный руководитель
2. TODO: член комиссии 1
3. TODO: член комиссии 2

Дата защиты: _____
Оценка: _____

Задание

В рамках данной магистерской работы кандидат должен исследовать возможность прогнозирования переменных во времени межрыночных зависимостей между криптовалютами и традиционными финансовыми активами с применением моделей машинного обучения. В частности, кандидат должен:

1. собрать исторические дневные цены для Bitcoin и традиционных активов (фондовые индексы, фонды драгоценных металлов, индекс доллара США, Ethereum) и выполнить соответствующую предобработку и синхронизацию набора данных;
2. разработать воспроизводимую вычислительную процедуру для расчёта переменных во времени корреляционных целей с помощью скользящих окон различной длины и конструирования предсказательных признаков на основе инерции зависимости, волатильности и доходностей;
3. реализовать внеобразцовую оценку и сравнение нескольких моделей машинного обучения (AR, ElasticNet, Ridge, Random Forest, GBM, XGBoost) с эконометрическим бенчмарком

DCC-GARCH(1,1) с применением процедуры скользящего окна и теста Дибольда–Мариано на статистическую значимость;

4. ввести практический сигнальный слой для раннего обнаружения стрессовых дней на рынке традиционных активов на основе динамики криптовалют и прогнозов зависимостей, и оценить его метриками классификационной точности, подходящими для несбалансированного набора классов.

Рекомендуемая литература:

[1] Robert F. Engle, «Dynamic Conditional Correlation: A Simple Class of Multivariate Generalized Autoregressive Conditional Heteroskedasticity Models», в: Journal of Business & Economic Statistics 20.3 (2002), стр. 339–350.

[2] Francis X. Diebold и Roberto S. Mariano, «Comparing Predictive Accuracy», в: Journal of Business & Economic Statistics 13.3 (1995), стр. 253–263.

[3] Hui Zou и Trevor Hastie, «Regularization and Variable Selection via the Elastic Net», в: Journal of the Royal Statistical Society: Series B 67.2 (2005), стр. 301–320.

[4] Jerome H. Friedman, «Greedy Function Approximation: A Gradient Boosting Machine», в: The Annals of Statistics 29.5 (2001), стр. 1189–1232.

[5] Tianqi Chen и Carlos Guestrin, «XGBoost: A Scalable Tree Boosting System», в: Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2016, стр. 785–794.

Крагуевац, 10. 3. 2026.
Научный руководитель: Д-р Владимир М. Милованович, ординарный профессор

Аннотация (Abstract)

В данной магистерской работе исследуется вопрос о том, может ли информация, содержащаяся в динамике криптовалют, использоваться для прогнозирования переменных во времени структур зависимости с традиционными активами и, на втором шаге, для формирования раннего предупреждающего сигнала для инвесторов. Bitcoin рассматривается в качестве базовой криптовалюты, тогда как вселенная традиционных активов включает фондовые индексы, ETF драгоценных металлов, индекс доллара США и Ethereum в качестве дополнительного крипто-ориентира. Разработан воспроизводимый конвейер машинного обучения для получения данных, построения доходностей, генерации скользящих корреляционных целей, конструирования признаков, скользящей оценки моделей и сравнения с защищённой от утечек спецификацией DCC-GARCH. Эмпирические результаты показывают, что межрыночная зависимость поддаётся прогнозированию, однако большая часть предсказательной силы происходит из персистентности самого ряда зависимостей.

Следовательно, простые авторегрессионные базовые модели превосходят более сложные по среднему показателю, тогда как модели машинного обучения всё же обеспечивают полезные улучшения относительно бенчмарка DCC-GARCH. Инвесторо-ориентированный сигнальный слой, основанный на крипто-признаках и прогнозах зависимостей, достигает умеренной, но значимой эффективности и лучше всего интерпретируется как дополнительный фильтр управления рисками, а не как самостоятельный инструмент выбора момента входа на рынок.

Ключевые слова: криптовалюты, Bitcoin, межрыночная зависимость, корреляция, машинное обучение, DCC-GARCH, прогнозирование, управление рисками.

Резюме

В данной магистерской работе рассматривается проблема прогнозирования переменных межрыночных зависимостей между криптовалютами и традиционными финансовыми активами. В центре внимания находится Bitcoin как базовая криптовалюта, тогда как набор традиционных активов включает фондовые индексы, фонды драгоценных металлов и индекс доллара США. Разработана воспроизводимая вычислительная процедура, охватывающая загрузку данных, вычисление логарифмических доходностей, формирование переменных во времени корреляционных целей, конструирование признаков, внеобразцовую оценку нескольких моделей машинного обучения и сравнение с эконометрическим бенчмарком DCC-GARCH. Помимо основной задачи прогнозирования зависимостей, введён практический слой формирования раннего сигнала риска, призванного предупреждать инвестора о стрессовых днях на рынке традиционных активов. Результаты показывают, что переменная во времени межрыночная зависимость поддаётся прогнозированию, однако наибольшая часть предсказуемости происходит из собственной инерции целевого ряда, тогда как более сложные модели машинного обучения приносят ограниченное дополнительное улучшение по сравнению с простыми авторегрессионными подходами. Практический сигнальный слой даёт умеренные результаты и имеет смысл прежде всего как дополнительный фильтр риска, а не как самостоятельный механизм ежедневного определения направления рынка.

Ключевые слова: криптовалюты, Bitcoin, межрыночные зависимости, корреляция, машинное обучение, DCC-GARCH, управление рисками.

Содержание

- Список сокращений
- 1 Введение
  - 1.1 Мотивация и контекст исследования
  - 1.2 Исследовательские вопросы

    - 1.3 Вклад работы
    - 1.4 Структура работы
- 2 Теоретическая база и обзор литературы
    - 2.1 Почему межрыночная зависимость важна
    - 2.2 Криптовалюты и традиционные активы
    - 2.3 Скользящая корреляция как цель прогнозирования
    - 2.4 Эконометрический бенчмарк: DCC-GARCH
    - 2.5 Подходы машинного обучения к прогнозированию
    - 2.6 Скользящая оценка и утечка информации
    - 2.7 Сравнение моделей и тест Дибольда–Мариано
    - 2.8 От прогнозирования зависимостей к инвесторскому сигналу
    - 2.9 Позиционирование настоящей работы
- 3 Методология
- 4 Эмпирические результаты
- 5 Обсуждение
- 6 Заключение
- Приложения A–D

Список сокращений

Сокращение	Полная форма
AR1	Авторегрессионная модель первого порядка
AUC	Площадь под ROC-кривой
BTC	Bitcoin (BTC-USD)
CSV	Значения, разделённые запятыми
DCC	Динамическая условная корреляция
DCC-GARCH	DCC-GARCH(1,1)
DM	Тест Дибольда–Мариано
EDA	Разведочный анализ данных

Сокращение	Полная форма
ElasticNet	Регрессия с регуляризацией Elastic Net
ETF	Биржевой инвестиционный фонд
ETH	Ethereum (ETH-USD)
F1	F1-мера (гармоническое среднее точности и полноты)
GARCH	Обобщённая авторегрессионная условная гетероскедастичность
GBM	Градиентный бустинг
GLD	SPDR Gold Shares ETF
GPU	Графический процессор
GSPC	Индекс S&P 500
IXIC	Сводный индекс NASDAQ
MAE	Средняя абсолютная ошибка
ML	Машинное обучение
NASDAQ	Национальная ассоциация дилеров ценных бумаг
OOS	Внеобразцовый
RF	Случайный лес
RMSE	Среднеквадратическая ошибка
ROC	Рабочая характеристика приёмника
S&P 500	Индекс Standard & Poor's 500
SLV	iShares Silver Trust ETF
UUP	Invesco DB US Dollar Index Bullish Fund
XGB	XGBoost (Extreme Gradient Boosting)

1 Введение

1.1 Мотивация и контекст исследования

Прогрессивная интеграция рынков криптовалют в глобальную финансовую систему вывела их из статуса технологического эксперимента в статус реального канала трансмиссии межрыночного риска. Bitcoin, в частности, превратился в непрерывно торгуемый, высоко заметный актив, чья ценовая динамика привлекает внимание не только крипто-нативных участников, но и институциональных портфельных менеджеров, макро-стратегов и регуляторов. По мере созревания рыночной инфраструктуры и углубления институционального участия возникает важный исследовательский вопрос: содержит ли информация, заложенная в динамике цен криптовалют, предсказательный контент для будущих условий в традиционных классах активов — таких как акции, металлы или валютные инструменты?

Данная работа отвечает на этот вопрос, исследуя переменную во времени межрыночную зависимость. Вместо попытки прямого прогнозирования уровней цен или доходностей анализ моделирует эволюцию взаимосвязи между Bitcoin и традиционными активами посредством структур скользящей корреляции и исследует, поддаются ли эти структуры прогнозированию в строгих внеобразцовых рамках. Это разграничение важно методологически. Межрыночная корреляция хорошо задокументирована как нестационарная, демонстрирующая выраженную временну´ю вариацию в периоды стресса ликвидности, инфляционного давления, монетарного ужесточения или резких изменений склонности инвесторов к риску. В таких условиях знак и величина межрыночных связей могут меняться с темпами, которые стандартные долгосрочные предположения о статической диверсификации не в состоянии учесть.

Практическая мотивация не менее убедительна. Ориентированный на риск портфельный менеджер не нуждается в точном прогнозе доходности на один день вперёд, чтобы получить полезную информацию. Во многих контекстах управления рисками более важна информация, связанная с ранним распознаванием структурного сдвига рыночной среды — изменения паттернов совместного движения и роста условной вероятности стрессового эпизода на рынках традиционных активов. Если информация, полученная из криптовалют, заметно способствует такому потенциалу раннего предупреждения, то даже скромное статистически ограниченное преимущество прогнозирования представляет собой значимый вклад в количественное управление рисками.

1.2 Исследовательские вопросы

Центральная исследовательская проблема разложена на два взаимодополняющих уровня. Первый уровень — научный и методологический: поддаются ли переменные во времени межрыночные зависимости между Bitcoin и традиционными активами прогнозированию в дисциплинированных внеобразцовых рамках, и как работают модели машинного обучения по сравнению с классическими эконометрическими бенчмарками при строгой скользящей оценке? Второй уровень — прикладной: можно ли прогнозы зависимостей, получаемые на основе динамики криптовалют, преобразовать в значимый для рынка предупреждающий

сигнал, способный своевременно идентифицировать повышенный риск снижения на традиционных рынках?

Конкретнее, работа отвечает на следующие исследовательские вопросы:

1. Поддаётся ли скользящая зависимость между Bitcoin и традиционными активами внеобразцовому прогнозированию?
2. Превосходят ли модели машинного обучения защищённый от утечек бенчмарк DCC-GARCH?
3. Добавляют ли модели машинного обучения ценность сверх простых базовых моделей на основе персистентности, таких как AR1?
4. Можно ли прогнозы зависимостей на основе крипто-данных преобразовать в практически полезный сигнал предупреждения о стрессе для традиционных рынков?

1.3 Вклад работы

Для ответа на эти вопросы в работе построен воспроизводимый модульный конвейер прогнозирования, реализованный на Python. Конвейер принимает ценовые данные, вычисляет логарифмические доходности, строит скользящие корреляционные цели при различных длинах окон, конструирует лаговые и волатильностные предикторы и оценивает ряд моделей в рамках скользящего экспериментального дизайна. Набор моделей включает простые базовые модели персистентности, регуляризованные линейные методы, ансамблевые методы на основе деревьев, XGBoost и защищённую от утечек реализацию бенчмарка DCC-GARCH. Поверх этапа прогнозирования зависимостей наложен второй, инвесторо-ориентированный слой; этот слой классифицирует стрессовые режимы для традиционных активов на основе крипто-признаков и спрогнозированной динамики зависимостей.

Эмпирические результаты подтверждают содержательный, но тщательно ограниченный вывод. Внеобразцовое прогнозирование зависимостей осуществимо; цель не является непредсказуемым шумом. Однако доминирующим источником предсказуемости является сильная серийная персистентность, присущая процессу зависимостей, и, следовательно, наиболее конкурентоспособными базовыми моделями оказываются авторегрессионные и модели наивной персистентности. Этот результат не является недостатком рамки; это содержательное эмпирическое открытие. Оно устанавливает, что ценность машинного обучения в данном контексте носит инкрементальный и сравнительный, а не трансформативный характер, и что любые заявления о значительных выигрышах в прогнозировании должны оцениваться относительно надлежащих сильных базовых моделей персистентности. Модель второго слоя демонстрирует умеренную, но статистически значимую предсказательную ценность, функционируя наиболее эффективно как вспомогательный фильтр риска, а не как всесторонний направленный предиктор.

Таким образом, вклад работы тройственен. Во-первых, построена чистая, воспроизводимая рамка для прогнозирования скользящей межрыночной зависимости между крипто- и традиционными рынками активов. Во-вторых, обеспечено структурированное, методологически строгое сравнение классического эконометрического моделирования с представительным набором подходов машинного обучения в условиях скользящей оценки. В-третьих, анализ прогнозирования зависимостей расширен до прикладного инвесторского предупреждающего слоя, тем самым устанавливая явный и прозрачный мост между статистической задачей прогнозирования и практически значимым контекстом принятия решений.

1.4 Структура работы

Остальная часть работы организована следующим образом. Раздел 2 рассматривает теоретические основы моделирования переменной во времени зависимости, финансового заражения, методов прогнозирования машинного обучения и статистической рамки для сравнения моделей. Раздел 3 представляет набор данных, методологию построения целей, процедуру конструирования признаков, спецификации моделей и рамку оценки. Раздел 4 сообщает эмпирические результаты как для слоя прогнозирования зависимостей, так и для инвесторского сигнального слоя. Раздел 5 интерпретирует результаты в деталях, исследует что они означают и чего не означают, и признаёт основные ограничения исследования. Раздел 6 содержит заключение и предлагает направления для будущих исследований.

---

2 Теоретическая база и обзор литературы

2.1 Почему межрыночная зависимость важна

Межрыночная зависимость занимает центральное место в современной финансовой теории, поскольку выгоды диверсификации, распространение финансового заражения, эффективность стратегий хеджирования и измерение портфельного риска фундаментально зависят от структуры совместного движения активов. В канонической модели среднего-дисперсии зависимость резюмируется постоянным коэффициентом корреляции. Однако эмпирические данные давно установили, что такое статическое представление неадекватно. Парные корреляции переменчивы во времени, реагируют асимметрично на положительные и отрицательные шоки и, как правило, резко возрастают во время рыночных спадов — именно в те эпизоды, когда диверсификация наиболее срочно необходима. Следовательно, прогнозирование переменной во времени зависимости теоретически мотивировано и практически необходимо для управления рисками.

Актуальность динамической зависимости усиливается, когда один из рассматриваемых активов основан на криптовалюте. Bitcoin торгуется на непрерывном, глобально доступном рынке, быстро реагирует на изменения настроений и ликвидности финансирования и одновременно подвержен широкому спектру экономических нарративов: спрос на защиту от инфляции,

спекулятивный аппетит к риску, технологический оптимизм, регуляторная неопределённость и глобальное макро-позиционирование. Это множество движущих сил означает, что Bitcoin не занимает единой стабильной роли в многоактивном портфеле. В разные моменты бизнес- и кредитного цикла он может проявлять характеристики спекулятивного высокобетового инструмента роста, прокси чувствительного к ликвидности риска или идиосинкратического барометра настроений. Эта структурная нестабильность делает его взаимосвязь с традиционными активами уникально подходящей для переменного во времени аналитического подхода.

2.2 Криптовалюты и традиционные активы

Академическая литература о пересечении рынков криптовалют и традиционных классов активов существенно расширилась за последнее десятилетие, развиваясь по нескольким направлениям. Одно направление рассматривает Bitcoin как самостоятельный актив и характеризует его распределение доходностей, кластеризацию волатильности, профиль хвостового риска и степень информационной эффективности в слабой форме. Второе направление исследует портфельную диверсификацию и задаётся вопросом, обеспечивает ли Bitcoin экономически значимые преимущества диверсификации относительно фондовых индексов, золота, сырой нефти или основных фиатных валют. Третье направление, наиболее непосредственно связанное с настоящей работой, изучает связанность, финансовое заражение и переток доходностей и волатильности между рынками, с особым вниманием к кризисным и стрессовым эпизодам.

Повторяющимся выводом по всем этим направлениям является структурная нестабильность. Зависимость между Bitcoin и широкими фондовыми индексами, как правило, статистически слабая или направленно непоследовательная в спокойных рыночных условиях, но существенно усиливается в эпизоды выраженного риск-он или риск-офф позиционирования. Драгоценные металлы, включая золото, демонстрируют в целом более низкое и более вариабельное совместное движение с Bitcoin — паттерн, объясняемый их различными инвесторскими базами и устоявшейся ролью безопасной гавани в институциональных портфелях. Валютные инструменты, такие как индекс доллара США, добавляют дополнительное измерение, поскольку служат прокси для глобальной ликвидности финансирования и защитных потоков капитала, которые взаимодействуют со спросом на криптовалюту способами, пока не полностью понятными.

Эти эмпирические закономерности мотивируют стратегию моделирования, принятую в настоящей работе. Вместо навязывания статического коэффициента зависимости или оценки единственной полновыборочной корреляции работа моделирует зависимость как переменный во времени процесс. Эта спецификация учитывает постепенный дрейф режима, резкие структурные разломы и неоднородность темпа и направления изменений совместного движения по различным длинам окон и парам активов.

2.3 Скользящая корреляция как цель прогнозирования

Оценщик скользящей корреляции концептуально прозрачен и вычислительно реализуем. Для двух рядов доходностей $\{r_1,t\}$ и $\{r_2,t\}$ скользящая корреляция в момент t по окну длины w определяется стандартной формулой Пирсона, применённой к последним w наблюдениям. Проход этого оценщика по всем t даёт временной ряд, характеризующий временну́ю эволюцию межрыночного совместного движения.

Цель скользящей корреляции обладает несколькими свойствами, делающими её привлекательной в прогнозном исследовании. Она непосредственно интерпретируема: положительные значения сигнализируют о совонаправленном движении, отрицательные — о хеджеподобном соотношении. Она сопоставима по парам активов и длинам окон, обеспечивая систематический многоактивный анализ. Она концентрирует внимание на изменениях рыночной структуры, а не на уровневой динамике отдельных рядов доходностей.

Главная методологическая сложность, создаваемая этой целью, — сильная серийная персистентность. Поскольку оценщик скользящей корреляции строится из перекрывающихся окон наблюдений, последовательные оценки разделяют $w - 1$ общих наблюдений, индуцируя высокую автокорреляцию целевого ряда. Эта персистентность, вероятно, будет доминировать в прогнозной эффективности и может помешать сложным моделям машинного обучения внести существенный вклад сверх простых авторегрессионных базовых моделей. Настоящая работа трактует это свойство не как препятствие, а как аналитически важную эмпирическую характеристику процесса зависимостей.

Для улучшения статистических свойств цели в работе применяется z-преобразование Фишера, отображающее ограниченные значения корреляции $\rho \in (-1, 1)$ в приближённо неограниченную вещественнозначную величину с распределением, более близким к гауссовскому. Это преобразование является стандартной практикой при анализе корреляционноподобных величин и стабилизирует дисперсию вблизи границ единичного интервала.

2.4 Эконометрический бенчмарк: DCC-GARCH

Модель Dynamic Conditional Correlation GARCH, введённая Энглем, обеспечивает классический эконометрический бенчмарк для настоящего исследования. Рамка DCC-GARCH разлагает условную ковариационную матрицу Ht вектора доходностей rt как $H_t = D_t R_t D_t$, где Dt — диагональная матрица условных стандартных отклонений, а Rt — переменная во времени условная корреляционная матрица. Каждая условная дисперсия следует одномерному процессу GARCH(1,1). Стандартизованные остатки используются для обновления псевдо-корреляционной матрицы Qt с параметрами скорости возврата к среднему и персистентности условной корреляции; из нее затем извлекается условная корреляционная матрица Rt.

DCC-GARCH концептуально хорошо подходит для данной работы, поскольку явно моделирует переменное во времени совместное движение в условиях гетероскедастичности, характерной как для криптовалютных, так и для традиционных фондовых доходностей. Однако опора модели на конкретную параметрическую структуру может ограничивать её адаптируемость при

наличии нелинейных взаимодействий или структурных разломов в данных. Кроме того, реализации, оценивающие модель на полной выборке перед вычислением внеобразцовых прогнозов, непреднамеренно используют будущую информацию. Чтобы устранить этот источник утечки, в настоящей работе применяется строго скользящий протокол повторной оценки, при котором модель DCC-GARCH переоценивается на расширяющемся окне на каждом шаге оценки.

2.5 Подходы машинного обучения к прогнозированию

Машинное обучение актуально для прогнозирования финансовых зависимостей не потому, что гарантирует преимущество в производительности, а потому, что предлагает класс моделей, способных улавливать нелинейные паттерны, пороговую динамику и многомерные взаимодействия, которые трудно специфицировать параметрически.

2.5.1 Регуляризованные линейные модели

Регуляризованные линейные модели, включая Ridge-регрессию и Elastic Net, представляют собой сильные базовые модели в задачах прогнозирования по структурированным табличным данным. Ridge-регрессия накладывает ℓ_2-штраф на вектор коэффициентов, сжимая оценки к нулю для снижения дисперсии оценивания без введения разреженности. Elastic Net сочетает ℓ_1- и ℓ_2-регуляризацию, где ℓ_1-компонента способствует разреженности и неявному отбору переменных, что желательно при наличии многих лаговых предикторов со слабым или избыточным сигналом.

Несмотря на линейную функциональную форму, регуляризованные модели нередко конкурентоспособны в задачах прогнозирования с гладким, персистентностным сигналом. Когда отношение сигнал-шум скромное, а доминирующим признаком является лаговое значение самой цели, смещение, вносимое линейностью, часто перекрывается снижением дисперсии, достигаемым регуляризацией.

2.5.2 Ансамблевые модели на основе деревьев

Случайные леса строят ансамбль деревьев решений, каждое обучается на бутстрап-подвыборке и случайном подмножестве признаков, и агрегируют их прогнозы для снижения дисперсии и улучшения обобщаемости. Градиентный бустинг последовательно строит деревья, каждое подгоняется к псевдо-остаткам текущего ансамбля. XGBoost расширяет эту рамку бустинга аппроксимациями градиента второго порядка, ℓ_1- и ℓ_2-регуляризацией структуры деревьев и вычислительными оптимизациями.

Ансамблевые модели на основе деревьев — естественные кандидаты для данной задачи прогнозирования, поскольку взаимосвязь между криптовалютными признаками и динамической межрыночной зависимостью может включать нелинейности и взаимодействия. Тем не менее ансамблевые методы на основе деревьев не являются безусловно превосходящими при однодневном прогнозировании высокоперсистентной цели.

2.6 Скользящая оценка и утечка информации

Временной порядок финансовых временных рядов предъявляет строгие требования к дизайну оценки. Случайные разделения обучающей и тестовой выборок недопустимы в данном контексте, поскольку нарушают причинный порядок наблюдений и вносят предвзятость от заглядывания вперёд. Единственно правомерной стратегией оценки для прогнозирования временных рядов является та, которая гарантирует, что каждый прогноз формируется исключительно с использованием информации, доступной на момент прогнозирования или ранее.

Поэтому в работе применяется скользящая процедура, при которой модели обучаются на расширяющемся историческом окне, формируется прогноз на один шаг вперёд, затем окно расширяется на одно наблюдение. Для баланса между вычислительными затратами и реалистичностью повторная подгонка моделей выполняется с периодичностью, а не на каждом шаге. Этот дизайн воспроизводит операционные ограничения реального прогнозного развёртывания.

2.7 Сравнение моделей и тест Дибольда–Мариано

Ранжирование моделей по средней ошибке прогноза по внеобразцовому периоду оценки предоставляет полезную описательную информацию, но не устанавливает, являются ли наблюдаемые различия в производительности статистически отличимыми от выборочной вариации. Тест Дибольда–Мариано восполняет этот пробел, предоставляя формальный тест нулевой гипотезы о равной предсказательной точности двух конкурирующих прогнозов.

В контексте данной работы тест ДМ служит двум отдельным целям. Во-первых, он определяет, даёт ли наилучшая конфигурация машинного обучения статистически значимое улучшение по сравнению с защищённым от утечек бенчмарком DCC-GARCH. Во-вторых, он устанавливает, сохраняется ли видимое преимущество машинного обучения над простыми авторегрессионными или наивными базовыми моделями при формальной статистической проверке.

2.8 От прогнозирования зависимостей к инвесторскому сигналу

Исследование, ограниченное статистическим прогнозированием скользящей корреляции, представляло бы собой самодостаточный академический вклад. Однако практическая мотивация настоящей работы требует дополнительного аналитического слоя. Чтобы результаты прогнозирования были применимы с инвесторской точки зрения, прогнозы зависимостей должны быть переведены в релевантный для принятия решений объект, напрямую отвечающий на проблему управления рисками.

Поэтому в работе вводится второй сигнальный слой. Вместо прогнозирования направления доходности следующего дня сигнальный слой определяет вероятность того, что следующий торговый день будет принадлежать стрессовому режиму, определяемому условиями

повышенного риска снижения для рассматриваемого традиционного актива. Такая формулировка более непосредственно согласована с управлением портфельным риском.

2.9 Позиционирование настоящей работы

Настоящая работа занимает пересечение финансовой эконометрики, методологии машинного обучения и прикладного количественного анализа рисков. Она не выдвигает утверждения о том, что данные о криптовалютах способны решить проблему выбора момента входа на рынок. Напротив, она исследует более точно сформулированное и эмпирически обоснованное утверждение: ценовая динамика криптовалют содержит статистически значимую информацию об эволюции структур межрыночной зависимости, и эта информация может быть использована для построения скромного, но экономически значимого раннего предупреждающего сигнала для традиционных рынков активов.

---

3 Методология

3.1 Дизайн исследования

В работе принят многоуровневый дизайн исследования. Первый уровень — регрессионная задача прогнозирования, в которой целью является следующее значение преобразованного ряда скользящей корреляции между Bitcoin и другим активом. Второй уровень — классификационная задача, в которой выход первого уровня совместно с крипто-признаками используется для оценки вероятности стрессового дня для традиционного актива. Эта структура отражает различие между научным измерением и практическим действием.

Дизайн намеренно консервативен. Вместо оптимизации исключительно для внутривыборочного соответствия все важные решения о моделировании встроены в рамку скользящей оценки. Это касается формирования целей, выравнивания признаков, оценки бенчмарков и генерации сигналов.

3.2 Вселенная активов и источник данных

Эмпирический анализ использует ежедневные рыночные данные, полученные через интерфейс yfinance. Bitcoin, представленный тикером BTC-USD, служит базовой криптовалютой на протяжении всего исследования. Набор сравниваемых активов включает:

Тикер	Интерпретация
BTC-USD	Bitcoin, базовая криптовалюта
ETH-USD	Ethereum, крипто-ориентир
GSPC	Индекс S&P 500
IXIC	Сводный индекс NASDAQ
GLD	Gold ETF
SLV	Silver ETF
UUP	ETF-прокси индекса доллара США

Эта вселенная выбрана по содержательным, а не исключительно техническим причинам. Два фондовых индекса представляют широкие американские рисковые активы. ETF золота и серебра отражают воздействие на драгоценные металлы, нередко связанное с инфляционными ожиданиями, нарративами безопасной гавани или сентиментом на сырьевых рынках. Прокси индекса доллара отражает глобальную силу доллара и защитное макро-позиционирование. Ethereum включён в качестве дополнительного крипто-бенчмарка.

Выборка охватывает период с 9 ноября 2017 по 27 февраля 2026 года, давая 2976 ежедневных наблюдений по каждому активу. Начальная дата определяется доступностью данных о цене Ethereum на Yahoo Finance; более ранние даты не содержат наблюдений ETH-USD и исключены из выровненной панели.

3.3 Построение доходностей и предобработка

Все ценовые ряды преобразуются в ежедневные логарифмические доходности. Логарифмические доходности предпочтительны, поскольку аддитивны во времени и являются стандартными как в эконометрическом моделировании, так и в конвейерах машинного обучения для финансовых временных рядов. Для ценового ряда Pt доходность вычисляется как $r_t = \log P_t - \log P_{t-1}$.

3.4 Построение цели: скользящая зависимость

Для каждой пары, состоящей из Bitcoin и другого актива, вычисляется ряд скользящей корреляции по окнам из 14, 30, 60 и 90 торговых дней. Результирующий ряд преобразуется с использованием z-преобразования Фишера (arctanh), отображающего ограниченное корреляционное пространство $(-1, 1)$ в неограниченное вещественнозначное пространство. Ключевым следствием этого дизайна является то, что целевой ряд уже является гладким объектом — и, следовательно, гораздо более персистентным, чем сырой ряд доходностей.

3.5 Конструирование признаков

Набор признаков намеренно структурирован вокруг интерпретируемых финансовых величин. Цель состоит не в создании чрезмерно большой матрицы предикторов типа «чёрного ящика», а в конструировании компактного набора переменных, способных правдоподобно влиять на будущую динамику зависимостей.

Группа	Описание
Лаги зависимости	Недавние значения скользящей цели зависимости
Лаги доходностей	Лаговые доходности Bitcoin и парного актива
Скользящие средние	Локальное среднее доходности по коротким окнам
Скользящая волатильность	Локальное стандартное отклонение доходностей
Спред-признаки	Абсолютный и знаковый разрыв между динамикой крипто и актива
Разрыв корреляционного режима	Короткооконная минус длиннооконная корреляция

Лаги зависимости особенно важны, поскольку цель по построению персистентна. Разрыв корреляционного режима (corr_diff) фиксирует, расходится ли краткосрочная зависимость с более долгосрочным базовым уровнем, что может сигнализировать о надвигающемся сдвиге режима.

3.6 Модели прогнозирования

3.6.1 Базовые модели

В каждый эксперимент прогнозирования включены две простые базовые модели. Первая — Naive_Last, прогнозирующая следующее значение зависимости с использованием наиболее свежего наблюдения. Вторая — AR1, оценивающая однолаговую авторегрессионную структуру. Эти базовые модели существенны, поскольку цель персистентна.

3.6.2 Регуляризованные линейные модели

Линейный блок машинного обучения включает Ridge и Elastic Net. Стандартизация применяется перед подгонкой этих моделей, поскольку регуляризация коэффициентов зависит от масштабирования признаков.

3.6.3 Ансамбли деревьев

Нелинейный блок включает случайный лес, GBM и XGBoost. XGBoost пытается использовать GPU, но автоматически переключается на CPU, если среда не поддерживает запрошенную конфигурацию.

3.6.4 Бенчмарк DCC-GARCH

Защищённый от утечек бенчмарк DCC-GARCH со скользящей оценкой реализован как отдельный модуль проекта. Вместо подгонки DCC на всей выборке и последующей оценки как внеобразцовой, бенчмарк повторно оценивается только на обучающем окне и прогнозы формируются вперёд из этой точки. Это делает бенчмарк медленнее, но методологически согласованным.

3.7 Инвесторский сигнальный слой

Сигнальный слой переформулирует задачу как классификационную задачу раннего предупреждения. Целью является индикатор стрессового дня для традиционного актива. Стрессовый день определяется относительно распределения отрицательных доходностей с использованием настраиваемого сигма-порога. Оцениваются три классификатора: логистическая регрессия, классификация случайным лесом и классификация с помощью градиентного бустинга.

3.8 Рамка скользящей оценки

Все эксперименты используют скользящий дизайн с расширяющимся окном. Модели обучаются на расширяющемся историческом окне, формируется прогноз на один шаг вперёд, затем окно расширяется на одно наблюдение. Периодическая повторная подгонка используется для снижения вычислительной нагрузки при сохранении причинного порядка.

3.9 Метрики оценки

Для слоя прогнозирования зависимостей производительность оценивается с использованием средней абсолютной ошибки (MAE), среднеквадратической ошибки (RMSE) и внеобразцового коэффициента детерминации R^2. RMSE подчёркивается при ранжировании моделей, поскольку сильнее штрафует большие отклонения.

Для инвесторского сигнального слоя основными метриками являются сбалансированная точность, F1-мера для класса падений, площадь под ROC-кривой (AUC) и частота выхода. Сбалансированная точность особенно важна, поскольку классификация стрессовых дней — несбалансированная задача.

3.10 Методология сравнения моделей

Средние метрики могут вводить в заблуждение, когда различия между моделями невелики. Поэтому в работе применяется тест Дибольда–Мариано для сравнения рядов потерь прогнозов между выбранными парами моделей. Основное сравнение — между наилучшей конфигурацией машинного обучения и бенчмарком DCC-GARCH. Тест ДМ позволяет различить три уровня утверждений: поддаётся ли зависимость прогнозированию вообще; улучшает ли машинное обучение результаты по сравнению с классическим эконометрическим бенчмарком; добавляет ли машинное обучение ценность сверх персистентности.

3.11 Реализация и воспроизводимость

Весь рабочий процесс реализован на Python и организован как модульная кодовая база. Основной конвейер координирует загрузку файлов конфигурации, вычисление доходностей, генерацию целей, построение признаков, подгонку моделей, формирование файлов прогнозов, сохранение рисунков и экспорт таблиц в формате LaTeX.

3.12 Методологические ожидания

До перехода к эмпирическим результатам полезно уточнить, что считается успехом. Успех в данной работе не означает обнаружения модели, идеально предсказывающей все традиционные рынки по Bitcoin. Более уместный стандарт следующий: цель зависимости должна демонстрировать внеобразцовую предсказуемость; сравнение с бенчмарком должно выявить, улучшает ли машинное обучение DCC-GARCH; сигнальный слой должен обеспечивать ненулевые и практически интерпретируемые предупреждения о стрессе.

---

4 Эмпирические результаты

4.1 Обзор эмпирических результатов

Конвейер генерирует всесторонний, внутренне согласованный набор эмпирических артефактов: внеобразцовые метрики производительности, ранжирование моделей, результаты теста Дибольда–Мариано, статистику классификации инвесторских сигналов, ряды прогнозов и диагностические рисунки. Ширина этих результатов намеренна.

Из агрегированных данных выделяются два общих вывода. Во-первых, процесс зависимости поддаётся прогнозированию в строгих внеобразцовых скользящих рамках. Во-вторых, основным источником предсказуемости является сильная серийная персистентность скользящей корреляционной цели, а не извлечение новой межактивной информации.

4.2 Средняя производительность прогнозирования зависимостей

В таблице ниже представлены средние внеобразцовые показатели производительности основных моделей, агрегированные по всем экспериментам. Ранжирование определяется прежде всего RMSE.

Модель	Средний RMSE	Средний MAE	Средний R^2
AR1	0.0667	0.0405	0.9421
Naive_Last	0.0674	0.0396	0.9409
Ridge	0.0916	0.0637	0.8914
ElasticNet	0.0923	0.0644	0.8898
RF	0.1013	0.0711	0.8687
GBM	0.1038	0.0734	0.8622
XGB_GPU	0.1057	0.0758	0.8566
DCC_GARCH	0.2345	0.1848	0.2788

Из таблицы выделяются четыре примечательных паттерна. Во-первых, модель с наивысшим рейтингом — базовая AR1 со средним RMSE 0.0667 и внеобразцовым R^2 0.9421. Во-вторых, модель наивной персистентности практически неотличима от AR1 (разница RMSE составляет 0.0007), подтверждая, что доминирующий механизм прогнозирования авторегрессионный по своей природе. В-третьих, регуляризованные линейные модели Ridge и ElasticNet занимают промежуточный ярус с R^2 около 0.89, превосходя все ансамбли деревьев в среднем. В-четвёртых, бенчмарк DCC-GARCH занимает последнее место со значительным отрывом, с средним R^2 лишь 0.2788.

Интерпретация точна. Целевой ряд зависимости сильно персистентен, и эта персистентность составляет основной прогнозный сигнал. Улучшение относительно AR1 или наивной базовой модели требует извлечения информации сверх наиболее свежего значения зависимости; данные показывают, что ни одна из оцениваемых моделей систематически и в значимом масштабе этого не делает.

4.3 Представительный пример прогноза

Рисунок 3 представляет внеобразцовую прогнозную панель для пары Bitcoin–S&P 500 на 30-дневном скользящем окне. Эта пара выбрана как представительный пример, поскольку взаимосвязь BTC–GSPC соединяет рынок криптовалют с наиболее широким бенчмарком американского традиционного фондового риска.

Рисунок выявляет три характерные особенности задачи прогнозирования. Цель эволюционирует плавно, согласуясь с её построением из перекрывающихся окон. Сильнейшие модели отслеживают общую направленную траекторию с ограниченным систематическим смещением. Однако локальные переходы режима создают устойчивую проблему: при резком

изменении структуры зависимости все модели демонстрируют недореакцию. Это среда, в которой DCC-GARCH отстаёт наиболее значительно и в которой методы машинного обучения могут предложить относительное улучшение.

4.4 Производительность прогнозирования по классам активов

Агрегированные метрики производительности скрывают информативную кросс-секционную вариацию. Пара Bitcoin–Ethereum демонстрирует наивысшую предсказуемость: оба актива разделяют фундаментальные движущие силы ликвидности и настроений, производя особенно гладкую и автокоррелированную цель.

Пары драгоценных металлов — Bitcoin–золото и Bitcoin–серебро — занимают промежуточный ярус предсказуемости. Пары с фондовыми индексами, Bitcoin–S&P 500 и Bitcoin–NASDAQ, наиболее практически значимы. Прокси пары Bitcoin–индекс доллара демонстрирует наиболее слабую и идиосинкратическую структуру зависимости по всей выборке, фиксируя наименьшую среднюю предсказуемость.

4.5 Результат доминирования персистентности

Вывод о том, что простые модели на основе персистентности доминируют в среднем ранжировании производительности, следует интерпретировать как диагностическое свидетельство о природе цели прогнозирования, а не как ограничение подхода машинного обучения.

Результат непосредственно следует из построения цели. Скользящая корреляция Пирсона, вычисленная по окну из w торговых дней, разделяет $w - 1$ наблюдений с предшествующим окном, индуцируя сильный эффект скользящего среднего сглаживания. После преобразования Фишера результирующий ряд демонстрирует сильную серийную автокорреляцию. Это подтверждается диагностикой важности признаков случайного леса: лаговый член зависимости доминирует в ранжировании важности по всем экспериментам.

4.6 Сравнение с DCC-GARCH

Несмотря на доминирование базовых моделей персистентности в безусловном ранжировании, машинное обучение обеспечивает практически и статистически значимое улучшение относительно DCC-GARCH. Результаты теста ДМ подтверждают, что наилучшая спецификация машинного обучения статистически значимо превосходит DCC-GARCH в большинстве экспериментов. Этот результат теоретически обоснован: DCC-GARCH разработан для моделирования полной условной ковариационной структуры системы доходностей; его проекция на скользящую корреляцию Пирсона является производным, сглаженным побочным продуктом, а не непосредственно оптимизируемой целью прогнозирования. Модели машинного обучения, напротив, обучаются непосредственно минимизировать ошибку прогноза на цели, что образует структурное преимущество задачно-ориентированного обучения.

В работе поддерживается точное концептуальное различие между превосходством над бенчмарком (превосходство над DCC-GARCH) и безусловным превосходством (превосходство над AR1). Машинное обучение стабильно достигает первого; оно не достигает второго систематически.

4.7 Диагностика профиля ошибок

Средние метрики ошибок предоставляют необходимую, но неполную характеристику качества прогноза. Временна´я и распределительная диагностика выявляет, когда и как модели ошибаются. Профиль скользящего RMSE во времени для пары Bitcoin–S&P 500 показывает, что качество прогноза неоднородно во времени. В периоды постепенной эволюции зависимости все модели достигают низких уровней ошибок. В периоды резких переходов режима уровни ошибок возрастают у всех моделей, но величина и продолжительность ухудшения систематически различаются. Модели машинного обучения, как правило, восстанавливаются несколько быстрее.

Диагностика распределения ошибок прогноза дополнительно устанавливает, что доминирующим источником ошибки прогноза являются эпизодические недореакции на резкие переломные точки, а не систематическое смещение.

4.8 Инвесторский сигнальный слой: средние результаты

Модель сигнала	Сбалансированная точность	F1_down	AUC
Logit	0.506	0.209	0.508
GBM_Cls	0.501	0.033	0.520
RF_Cls	0.500	0.030	0.519

Классификационная задача сигнального слоя существенно сложнее, чем регрессионная задача первого слоя. Идентификация стрессовых дней по своей природе зашумлена, несбалансирована по классам и подвержена асимметричным издержкам ошибок классификации. Логистический классификатор стабильно достигает наивысшей F1-меры для класса стресса (0.209 в среднем), указывая на то, что он сохраняет чувствительность к подлинным стрессовым эпизодам без вырождения в поведение с почти нулевой частотой выхода. Классификаторы на основе деревьев демонстрируют заметно более низкие F1-меры (~0.03).

4.9 Наилучшие конфигурации сигнала

Наивысшая индивидуальная производительность сигнала зафиксирована для пары Bitcoin–S&P 500. На 30-дневном окне логистическая классификация достигает сбалансированной точности 0.5405 и F1-меры 0.2523 для класса падений — скромное, но статистически и практически значимое отклонение от неинформативного базового уровня 0.50.

Сигнал разработан для функционирования в качестве вероятностно управляемого индикатора предупреждения, идентифицирующего периоды повышенного риска и тем самым поддерживающего решение о снижении риска, а не направленную сделку.

4.10 Практическая интерпретация производительности сигнального слоя

Практическая полезность сигнального слоя должна оцениваться относительно явно сформулированного стандарта решения. Инвестор, оснащённый сигналом, действует избирательно. Сигнал информирует условное решение управления рисками: снизить ли рыночную экспозицию, ужесточить ли уровни стоп-лосс или увеличить ли интенсивность хеджирования в ответ на повышенную вероятность стресса.

При таком подходе частота выхода — доля торговых дней, в которые сигнал активен, — является незаменимым дополнением к классификационной точности. Логистическая модель достигает разумного баланса между чувствительностью и специфичностью, производя частоту выхода, достаточную для практической полезности, без провоцирования избыточного оборота.

4.11 Чувствительность к длине скользящего окна

Длина скользящего окна является первостепенным параметром дизайна с измеримыми последствиями для свойств цели и производительности модели. Более короткие окна производят более реагирующие, но более зашумлённые оценки зависимости; более длинные окна генерируют более гладкие, более автокоррелированные цели. Эксперименты подтверждают, что средние длины окон — в частности, w = 30 дней — обеспечивают благоприятный баланс.

4.12 Резюме эмпирических результатов

Эмпирические результаты работы резюмируются в четырёх главных утверждениях:

1. Переменная во времени межрыночная зависимость между Bitcoin и традиционными активами поддаётся внеобразцовому прогнозированию в скользящих рамках, с высокими средними значениями R^2 по всем классам моделей.
2. Доминирующим источником предсказательной силы является серийная персистентность скользящей корреляционной цели; следовательно, авторегрессионные и наивные базовые модели персистентности возглавляют среднее ранжирование производительности.
3. Модели машинного обучения часто и значимо превосходят защищённый от утечек бенчмарк DCC-GARCH, но систематически не превосходят сильнейшие базовые модели персистентности на горизонте одного шага вперёд.
4. Инвесторский сигнальный слой даёт умеренные, статистически ненулевые результаты классификации, наиболее выраженные для широких фондовых рынков, и лучше всего интерпретируется как дополнительный вклад в управление рисками, а не как самостоятельный направленный предиктор.

5 Обсуждение

5.1 Главные результаты

Наиболее устойчивый вывод, подкреплённый эмпирическими данными, состоит в том, что переменная во времени межрыночная зависимость поддаётся прогнозированию в строгом внеобразцовом смысле. Этот вывод нетривиален, поскольку значительная часть литературы рассматривает скользящую корреляцию прежде всего как ретроспективный диагностический инструмент. В настоящей рамке она операционализирована как подлинная цель прогнозирования, оцениваемая в условиях временно́го упорядочения.

Анализ одновременно устанавливает второй, столь же значимый вывод: успех прогнозирования автоматически не благоприятствует высоко гибким моделям. Среднее ранжирование производительности выявляет обратное — простые модели на основе персистентности составляют наиболее конкурентоспособных прогнозистов.

5.2 Интерпретация результата персистентности

Доминирование базовых моделей AR1 и наивного последнего наблюдения могло бы на первый взгляд показаться подрывающим вклад работы. Эта интерпретация неверна. Идентификация персистентности как основного источника предсказуемости — содержательный научный результат, а не методологическая неудача. Цель прогнозного исследования — определить истинную структуру предсказуемости, а не продемонстрировать превосходство определённого класса методов.

5.3 Инкрементальный вклад машинного обучения

Тот факт, что базовые модели персистентности доминируют, не делает методы машинного обучения излишними. Их вклад осуществляется через три отдельных канала. Во-первых, включение моделей машинного обучения расширяет класс сравнения теоретически важным образом. Во-вторых, модели машинного обучения часто достигают меньшей ошибки прогноза, чем бенчмарк DCC-GARCH. В-третьих, методы машинного обучения демонстрируют более выраженные сравнительные преимущества в задаче сигнала второго слоя, где переход от регрессии к бинарной классификации стрессовых режимов лучше согласован с сильными сторонами ансамблевых методов.

5.4 Интерпретация результата DCC-GARCH

Сравнительно слабая производительность DCC-GARCH требует тщательной интерпретации. Модель теоретически обоснована и эмпирически устоявшаяся. Однако конкретная задача данной работы — краткогоризонтное прогнозирование сглаженной, преобразованной по Фишеру скользящей корреляционной цели при скользящей повторной оценке — значительно

сложнее, чем сценарий использования, для которого DCC-GARCH был первоначально разработан.

Этот результат не следует обобщать как систематическое отвержение DCC-GARCH. Модель по-прежнему подходит для долгогоризонтного прогнозирования ковариации, портфельного конструирования и приложений хеджирования. Конкретный вывод ограничен однодневным прогнозированием скользящей парной корреляции между Bitcoin и традиционными активами.

5.5 Практические последствия для инвесторов

Эмпирические результаты не поддерживают утверждение о том, что крипто-информация обеспечивает надёжное прогнозирование направления цены на следующий день для традиционных активов. Что подтверждают данные — более точно ограниченное и обоснованное практическое утверждение: динамика криптовалют содержит информацию об эволюции структуры зависимости традиционных активов, и эта информация может быть включена в механизм раннего предупреждения о периодах повышенного риска снижения.

5.6 Межактивная неоднородность производительности сигнала

Инвесторский сигнальный слой демонстрирует неоднородную производительность по вселенной традиционных активов. Качество сигнала сильнейшее для широких фондовых индексов и ослаблено для драгоценных металлов и долларовых инструментов. Этот паттерн экономически интерпретируем: широкие фондовые рынки тесно связаны с глобальным аппетитом к риску, ликвидностью финансирования и настроениями инвесторов — теми же силами, которые оказывают материальное влияние на Bitcoin.

5.7 Методологические сильные стороны

Эмпирические выводы работы поддерживаются несколькими методологическими решениями, коллективно снижающими риск артефактных результатов: весь конвейер воспроизводим; бенчмарк DCC-GARCH реализован в той же скользящей рамке; производительность оценивается по множеству метрик; применяется тест ДМ для формального статистического сравнения.

5.8 Ограничения

Работа подвержена нескольким ограничениям. Первое касается частоты данных — анализ проводится на ежедневных данных. Второе — горизонта прогнозирования — основная задача специфицирована как однодневное прогнозирование. Третье — выбора меры зависимости — скользящая корреляция Пирсона представляет лишь один член широкого семейства мер. Четвёртое — цели стрессового режима — бинарный индикатор стресса является упрощённым представлением. Наконец, работа не включает портфельный бэктест с учётом транзакционных издержек.

5.9 Направления для будущих исследований

Несколько естественных расширений следуют из результатов. Наиболее непосредственным приоритетом является исследование более длинных горизонтов прогнозирования. Дополнительным расширением было бы обогащение набора предикторов макрофинансовыми переменными. Замена скользящей корреляции Пирсона более богатыми мерами зависимости представляет содержательное теоретическое расширение. На прикладной стороне интеграция сигнального слоя в рамку оптимизации портфеля позволила бы оценить практическую полезность сигнала.

5.10 Общая оценка

Совокупность данных поддерживает сбалансированный и эмпирически обоснованный вывод. Работа не демонстрирует, что рынки криптовалют обладают предсказательной силой над направленными движениями традиционных активов в общем смысле. Она строго демонстрирует, что динамика криптовалют содержит информацию о временно́й эволюции межрыночной зависимости, что этот процесс поддаётся внеобразцовому прогнозированию, и что полученные прогнозы могут быть операционализированы как статистически значимый, пусть и умеренный, ранний предупреждающий сигнал.

---

6 Заключение

Данная магистерская работа исследовала, содержит ли ценовая динамика криптовалют — прежде всего Bitcoin — статистически значимую информацию для прогнозирования переменных во времени структур зависимости с традиционными рынками активов, и могут ли подобные прогнозы зависимостей быть операционализированы как практически значимый ранний предупреждающий сигнал для инвесторов. Для ответа на эти вопросы разработана воспроизводимая двухуровневая аналитическая рамка, оцениваемая в строгих скользящих экспериментальных рамках. Первый уровень посвящён прямому внеобразцовому прогнозированию скользящих парных корреляций между Bitcoin и набором традиционных активов. Второй уровень преобразует выход первого этапа в бинарную задачу классификации стрессового режима.

Эмпирические данные устанавливают, что процесс межрыночной зависимости поддаётся внеобразцовому прогнозированию. Точность прогнозирования стабильно положительна по всему набору оценки, с наивысшей производительностью, зафиксированной для пар внутри криптовалют и для средне-длинных спецификаций скользящего окна. Основным источником этой предсказуемости является, однако, сильная серийная персистентность, присущая цели скользящей корреляции. Авторегрессионные и наивные базовые модели персистентности следовательно доминируют в среднем ранжировании производительности по всем парам активов.

Модели машинного обучения вносят значимый вклад в анализ, хотя и в сравнительной и структурной роли, а не как безусловные топ-перформеры. Они часто превосходят защищённый от утечек бенчмарк DCC-GARCH и предоставляют более широкий класс сравнения. Их относительное преимущество наиболее выражено в задаче сигнала второго слоя, где переход от регрессии к бинарной классификации стресса лучше согласован с сильными сторонами ансамблевых методов.

Инвесторский сигнальный слой демонстрирует, что крипто-признаки могут быть преобразованы в статистически значимый механизм раннего предупреждения для режимов стресса традиционных рынков. Сигнал умеренный по величине, а не определительный, и его практическая полезность лучше всего понимается как дополнительный вклад в управление экспозицией — скорее дополнительный инструмент управления рисками, нежели самостоятельный направленный предиктор.

Работа тем самым устанавливает обоснованный академический вклад и ограниченный, но связный практический вклад. В академическом отношении она демонстрирует, что переменная во времени межрыночная зависимость между Bitcoin и традиционными активами поддаётся внеобразцовому прогнозированию, и предоставляет систематическое сравнение базовых моделей персистентности, методов машинного обучения и классического эконометрического бенчмарка в согласованных условиях оценки. В практическом отношении она показывает, что прогнозы зависимостей на основе крипто-динамики могут поддерживать инвесторский предупреждающий механизм, с наиболее сильной и устойчивой производительностью сигнала для широких фондовых рыночных индексов.

Будущие расширения должны касаться следующих приоритетов: тестирование рамки прогнозирования на нескольких горизонтах прогнозирования; обогащение набора признаков макрофинансовыми предикторами; замена скользящей корреляции Пирсона более богатыми представлениями зависимости; интеграция сигнального слоя в рамку оптимизации портфеля. Даже в рамках своего нынешнего охвата данная работа предоставляет строгий и содержательно информативный ответ на исследовательскую проблему и вносит вклад в доказательную базу для роли крипто-динамики в прогнозировании и управлении межрыночным риском в портфелях традиционных активов.

Приложение A: Описание данных и дополнительный контекст

A.1 Описательная роль вселенной активов

Выбор активов в работе не произволен. Каждый инструмент представляет отдельное измерение традиционной финансовой системы, с которой можно сравнивать Bitcoin.

- S&P 500 используется как широкий прокси американского фондового риска и общих настроений инвесторов.

- NASDAQ Composite отражает более ориентированный на рост и технологии сегмент рынка.
- ETF золота и серебра представляют воздействие на драгоценные металлы, нередко связанное с хеджированием и инфляционными нарративами.
- Прокси индекса доллара США отражает макро-защитное позиционирование и глобальную силу доллара.
- Ethereum включён как крипто-нативный сравнительный актив для противопоставления зависимости внутри экосистемы и межрыночной зависимости.

A.2 Визуальный обзор набора данных

Нормированные ценовые траектории показывают, насколько различны исходные рыночные траектории активов. Профили скользящей волатильности выявляют, что Bitcoin и связанные крипто-активы обитают в среде значительно более высокой волатильности, чем набор традиционных активов — что подчёркивает важность изучения зависимости динамически, а не статически.

Статическая корреляционная тепловая карта и динамическая картина скользящей корреляции вместе мотивируют основной выбор моделирования работы: статических сводок недостаточно для описания межрыночных отношений, изучаемых в данной работе.

A.3 Почему используются несколько скользящих окон

В работе используются окна 14, 30, 60 и 90 дней, поскольку единственный горизонт зависимости не является универсально подходящим. Короткое окно более чувствительно к недавним шокам, но и более зашумлено. Длинное окно производит более гладкую цель с нередко более сильной персистентностью, но может медленно реагировать на сдвиг режима. Оценка нескольких окон позволяет эмпирическому анализу разделить эти эффекты.

A.4 Дополнительные замечания по реализации

Проект организован так, что каждый запуск конвейера производит согласованные выходные данные в директориях outputs/results, outputs/tables, outputs/figures и outputs/predictions. Ноутбуковая среда согласована с конвейером: введены улучшения читаемости, чтобы рисунки были интерпретируемы и бенчмарки выбирались надёжно.

Приложение B: Дополнительные результаты прогнозирования

Это приложение собирает дополнительную диагностику прогнозирования и выходные данные сравнения моделей. Приложение намеренно делает акцент на рисунках, поскольку они передают изменения в поведении моделей эффективнее, чем чрезмерно широкие таблицы.

Дополнительные рисунки подкрепляют несколько тезисов основного текста. Качество прогноза существенно зависит от выбора скользящего окна, цель остаётся сильно персистентной, а различия в производительности по семействам моделей легче интерпретировать через сравнительные визуализации, чем через единственную ранжировочную статистику.

Приложение C: Дополнительные результаты сигнального слоя

Дополнительные сигнальные рисунки показывают, что практический слой ведёт себя по-разному на различных рынках. Цели, связанные с акциями, демонстрируют более чёткие предупреждающие эпизоды, тогда как цели, связанные с металлами и долларом, более зашумлены и слабее. Эта асимметрия экономически обоснована и поддерживает интерпретацию о том, что инвесторский слой следует использовать избирательно, а не единообразно.

Итоговая таблица производительности сигнального слоя:

Модель сигнала	Сбалансированная точность	F1_down	AUC
Logit	0.506	0.209	0.508
GBM_Cls	0.501	0.033	0.520
RF_Cls	0.500	0.030	0.519

Эти сводные значения подтверждают, что сигнальный слой значим, но умерен. Его сильнейшая роль — как дополнительный предупреждающий механизм, а не как самостоятельный аллокатор.

Приложение D: Воспроизводимость и структура кода

D.1 Организация проекта

Вычислительная часть работы структурирована как воспроизводимый исследовательский проект, а не коллекция разрозненных скриптов.

```
clode9/
|-- main.py              # основная точка входа в конвейер
|-- run_all.py           # полная автоматизация: конвейер + ноутбуки + LaTeX
|-- config.yaml          # конфигурация эксперимента
|-- requirements.txt     # зависимости Python
|-- thesis_app/          # основные модули Python
|   |-- pipeline.py      # данные, признаки, скользящая оценка, метрики
|   |-- dcc_walk.py      # защищённый от утечек бенчмарк DCC-GARCH
|   |-- signal_layer.py  # инвесторский слой предупреждения о стрессе
|   |-- notebook_helpers.py  # общие функции построения графиков
|   |-- data_quality.py  # диагностика пропущенных значений и выбросов
|   `-- regime_analysis.py   # каталог исторических режимов
|-- notebooks/           # шесть Jupyter-ноутбуков (01-06)
|-- data/raw/            # кэшированные загруженные ценовые данные
|-- data/processed/      # производные доходности
|-- outputs/results/     # CSV-сводки экспериментов
|-- outputs/tables/      # экспортированные LaTeX-таблицы
|-- outputs/figures/     # все сгенерированные рисунки
`-- thesis/              # данный документ
```

D.2 Основные модули реализации

- **pipeline.py**: оркестрирует полный рабочий процесс прогнозирования зависимостей и генерации сигналов.
- **dcc_walk.py**: содержит реализацию DCC-GARCH с защищённой от утечек скользящей оценкой.
- **signal_layer.py**: определяет инвесторский предупреждающий слой и связанные метрики классификации.
- **notebook_helpers.py**: общие вспомогательные функции построения графиков и анализа.
- **data_quality.py**: выполняет диагностику пропущенных значений, выбросов и покрытия.
- **regime_analysis.py**: реализует каталог исторических режимов.

D.3 Поток выполнения

Высокоуровневый поток выполнения:

1. Загрузить конфигурацию и пути.
2. Загрузить или обновить сырые ценовые данные с Yahoo Finance.
3. Вычислить синхронизированные логарифмические доходности.
4. Сформировать скользящие корреляционные цели для каждой пары и окна.

5. Построить лаговые и волатильностные матрицы признаков.
6. Подогнать все модели в скользящем режиме и сохранить прогнозы.
7. Вычислить метрики, тесты ДМ, экспортировать таблицы и рисунки.
8. Запустить инвесторский сигнальный слой и экспортировать сигнальные рисунки.
9. Выполнить шесть Jupyter-ноутбуков для производства дополнительной диагностики.
10. Скомпилировать LaTeX-документ работы.

D.4 Конфигурация

Параметры эксперимента хранятся в config.yaml и читаются один раз при запуске конвейера. Это позволяет изменять диапазон дат, вселенную активов или набор окон без изменения исходного кода.

D.5 Верификация, выполненная при очистке проекта

В ходе доработки проекта были исправлены несколько вопросов реализации: введён защищённый от утечек бенчмарк DCC-GARCH; конвейер метрик сделан согласованным; добавлено масштабирование признаков для регуляризованных линейных моделей; блок XGBoost сделан устойчивым к сбою GPU через запасной вариант CPU; инвесторский сигнальный слой интегрирован в основной конвейер.

D.6 Как пересобрать артефакты работы

Полный рабочий процесс может быть перезапущен с нуля одной командой из корневой директории проекта:

```
python run_all.py
```

D.7 Финальное замечание о воспроизводимости

Ценность воспроизводимости в данной работе не только техническая. Поскольку предмет касается финансового прогнозирования, где случайные утечки и выборочная отчётность являются постоянными рисками, прозрачная и повторно запускаемая кодовая база напрямую укрепляет достоверность эмпирических выводов.

Список литературы

[1] François Longin и Bruno Solnik, «Extreme Correlation of International Equity Markets», в: The Journal of Finance 56.2 (2001), стр. 649–676.

[2] Robert F. Engle, «Dynamic Conditional Correlation: A Simple Class of Multivariate Generalized Autoregressive Conditional Heteroskedasticity Models», в: Journal of Business &

Economic Statistics 20.3 (2002), стр. 339–350.

[3] Hui Zou и Trevor Hastie, «Regularization and Variable Selection via the Elastic Net», в: Journal of the Royal Statistical Society: Series B 67.2 (2005), стр. 301–320.

[4] Leo Breiman, «Random Forests», в: Machine Learning 45.1 (2001), стр. 5–32.

[5] Jerome H. Friedman, «Greedy Function Approximation: A Gradient Boosting Machine», в: The Annals of Statistics 29.5 (2001), стр. 1189–1232.

[6] Tianqi Chen и Carlos Guestrin, «XGBoost: A Scalable Tree Boosting System», в: Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2016, стр. 785–794.

[7] Francis X. Diebold и Roberto S. Mariano, «Comparing Predictive Accuracy», в: Journal of Business & Economic Statistics 13.3 (1995), стр. 253–263.

[8] yfinance developers, yfinance Documentation, 2026.

[9] Ivo Welch и Amit Goyal, «A Comprehensive Look at the Empirical Performance of Equity Premium Prediction», в: The Review of Financial Studies 21.4 (2008), стр. 1455–1508.

[10] Fakultet inženjerskih nauka Univerziteta u Kragujevcu, Master radovi, 2026.

[11] scikit-learn developers, scikit-learn User Guide, 2026.

[12] XGBoost developers, XGBoost Documentation, 2026.

[13] arch developers, arch Documentation, 2026.