Факультет инженерных наук Университета в Крагуевце

Название программы: ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ
Уровень обучения: Магистерские академические студии
Предмет: Продвинутое машинное обучение
Номер индекса: 1ВИ/2023

Bogdan Babaev

Прогнозирование изменяющихся во времени межрыночных зависимостей между криптовалютами и традиционными активами с применением машинного обучения

Магистерская работа

Комиссия по рецензии и защите:

1. проф. д-р Владимир М. Милованович — научный руководитель
2. TODO: член комиссии 1
3. TODO: член комиссии 2

Дата защиты: _____
Оценка: _____

Крагуевац, 2026.

Задание на магистерскую работу

В рамках данной магистерской работы кандидат должен исследовать возможность прогнозирования изменяющихся во времени межрыночных зависимостей между криптовалютами и традиционными финансовыми активами с применением моделей машинного обучения. В рамках этого кандидат должен:

1. собрать исторические дневные цены для Bitcoin и традиционных активов (фондовых индексов, фондов драгоценных металлов, индекса доллара США, Ethereum) и выполнить соответствующую предобработку и синхронизацию набора данных;
2. разработать воспроизводимый вычислительный алгоритм для расчёта изменяющихся во времени корреляционных целей с помощью скользящих окон различной длины, а также

для построения предсказательных признаков на основе инерции зависимости, волатильности и доходности;

3. реализовать внеобучающую оценку и сравнение нескольких моделей машинного обучения (AR, ElasticNet, Ridge, Random Forest, GBM, XGBoost) с эконометрическим бенчмарком DCC-GARCH(1,1) с применением процедуры скользящего окна и теста Дибольда–Мариано для проверки статистической значимости;
4. ввести практический сигнальный слой для раннего обнаружения стрессовых дней на рынке традиционных активов на основе динамики криптовалют и прогнозов зависимостей, и оценить его с помощью метрик классификационной точности, подходящих для несбалансированных классов.

Рекомендованная литература:

[1] Robert F. Engle, «Dynamic Conditional Correlation: A Simple Class of Multivariate Generalized Autoregressive Conditional Heteroskedasticity Models», в: *Journal of Business & Economic Statistics* 20.3 (2002), стр. 339–350.

[2] Francis X. Diebold и Roberto S. Mariano, «Comparing Predictive Accuracy», в: *Journal of Business & Economic Statistics* 13.3 (1995), стр. 253–263.

[3] Hui Zou и Trevor Hastie, «Regularization and Variable Selection via the Elastic Net», в: *Journal of the Royal Statistical Society: Series B* 67.2 (2005), стр. 301–320.

[4] Jerome H. Friedman, «Greedy Function Approximation: A Gradient Boosting Machine», в: *The Annals of Statistics* 29.5 (2001), стр. 1189–1232.

[5] Tianqi Chen и Carlos Guestrin, «XGBoost: A Scalable Tree Boosting System», в: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, стр. 785–794.

Крагуевац, 10.03.2026.

Научный руководитель:
Д-р Владимир М. Милованович,
ординарный профессор

Аннотация

В данной работе исследуется вопрос о том, может ли информация, содержащаяся в динамике криптовалют, использоваться для прогнозирования изменяющихся во времени структур зависимостей с традиционными активами и, на втором этапе, для формирования сигнала раннего предупреждения для инвесторов. Bitcoin рассматривается как базовая криптовалюта, тогда как вселенная традиционных активов включает фондовые индексы, биржевые фонды драгоценных металлов, индекс доллара США и Ethereum в качестве дополнительного криптовалютного ориентира. Разработан воспроизводимый конвейер машинного обучения,

охватывающий получение данных, построение доходностей, генерацию корреляционных целей на основе скользящего окна, разработку признаков, пошаговую оценку модели на протяжении всей выборки и бенчмаркинг относительно защищённой от утечки данных спецификации DCC-GARCH. Эмпирические результаты показывают, что межрыночная зависимость поддаётся прогнозированию, однако основная прогностическая сила происходит от персистентности самого ряда зависимостей. Вследствие этого простые авторегрессионные базовые модели в среднем превосходят более сложные, тогда как модели машинного обучения всё же дают полезные улучшения относительно бенчмарка DCC-GARCH. Ориентированный на инвестора сигнальный слой на основе криптовалютных признаков и прогнозов зависимостей демонстрирует умеренные, но значимые результаты и лучше всего интерпретируется как наложение риск-менеджмента, а не как самостоятельный механизм выбора момента для входа на рынок.

Ключевые слова: криптовалюты, Bitcoin, межрыночная зависимость, корреляция, машинное обучение, DCC-GARCH, прогнозирование, управление рисками.

Резиме (на сербском языке)

У овом мастер раду разматра се проблем прогнозирања промењљивих међутржишних зависности између криптовалута и традиционалних финансијских актива. У фокусу је Bitcoin као основна криптовалута, док скуп традиционалних актива обухвата акцијске индексе, фондове везане за племените метале и индекс америчког долара. Развијен је репродуцибилан рачунарски поступак који покрива преузимање података, израчунавање логаритамских приноса, формирање временски промењљивих корелационих циљева, конструисање особина, ванузорачну процену више модела машинског учења и поређење са DCC-GARCH економетријским репером. Поред основног задатка прогнозирања зависности, уведен је и практични слој за формирање раног сигнала ризика који треба да упозори инвеститора на стресне дане на тржишту традиционалних актива. Резултати показују да је временски промењљива међутржишна зависност предвидива, али да највећи део предвидивости потиче из сопствене инерције циљне серије, dok сложенији модели машинског учења доносе ограничено додатно побољшање у односу на једноставне ауторегресионе приступе. Практични сигнални слој даје умерене резултате и има смисла пре свега као додатни филтар ризика, а не као самостални механизам за свакодневно одређивање смера тржишта.

Кључне речи: криптовалуте, Bitcoin, међутржишне зависности, корелација, машинско учење, DCC-GARCH, управљање ризиком.

Содержание

- Список сокращений

- 1 Введение
  - 1.1 Мотивация и исследовательский контекст
  - 1.2 Исследовательские вопросы
  - 1.3 Вклад работы
  - 1.4 Структура работы
- 2 Теоретическая основа и обзор литературы
  - 2.1 Почему межрыночная зависимость важна
  - 2.2 Криптовалюты и традиционные активы
  - 2.3 Скользящая корреляция как цель прогнозирования
  - 2.4 Эконометрический бенчмарк: DCC-GARCH
  - 2.5 Подходы машинного обучения к прогнозированию
  - 2.6 Пошаговая оценка и утечка информации
  - 2.7 Сравнение моделей и тест Дибольда–Мариано
  - 2.8 От прогнозирования зависимостей к инвесторским сигналам
  - 2.9 Позиционирование данной работы
- 3 Методология
  - 3.1 Дизайн исследования
  - 3.2 Вселенная активов и источник данных
  - 3.3 Построение доходностей и предобработка
  - 3.4 Построение целевой переменной: скользящая зависимость
  - 3.5 Разработка признаков
  - 3.6 Модели прогнозирования
  - 3.7 Инвесторский сигнальный слой
  - 3.8 Пошаговая схема оценки
  - 3.9 Метрики оценки
  - 3.10 Методология сравнения моделей
  - 3.11 Реализация и воспроизводимость
  - 3.12 Методологические ожидания
- 4 Эмпирические результаты
  - 4.1 Обзор эмпирического вывода
  - 4.2 Средняя эффективность прогнозирования зависимостей
  - 4.3 Репрезентативный пример прогноза

    - 4.4 Эффективность прогнозирования по классам активов
    - 4.5 Результат доминирования персистентности
    - 4.6 Сравнение с DCC-GARCH
    - 4.7 Диагностика профиля ошибок
    - 4.8 Инвесторский сигнальный слой: средние результаты
    - 4.9 Наилучшие конфигурации сигнала
    - 4.10 Практическая интерпретация эффективности сигнального слоя
    - 4.11 Чувствительность к длине скользящего окна
    - 4.12 Резюме эмпирических результатов
- 5 Обсуждение
    - 5.1 Основные результаты
    - 5.2 Интерпретация результата персистентности
    - 5.3 Инкрементальный вклад машинного обучения
    - 5.4 Интерпретация результата DCC-GARCH
    - 5.5 Практические выводы для инвесторов
    - 5.6 Межактивная неоднородность в эффективности сигнала
    - 5.7 Методологические достоинства
    - 5.8 Ограничения
    - 5.9 Направления будущих исследований
    - 5.10 Общая оценка
- 6 Заключение
- Приложение A: Описание данных и дополнительный контекст
- Приложение B: Дополнительные результаты прогнозирования
- Приложение C: Дополнительные результаты сигнального слоя
- Приложение D: Воспроизводимость и структура кода

Список сокращений

Сокращение	Полная форма
AR1	Авторегрессионная модель первого порядка
AUC	Площадь под ROC-кривой

Сокращение	Полная форма
BTC	Bitcoin (BTC-USD)
CSV	Значения, разделённые запятыми
DCC	Динамическая условная корреляция
DCC-GARCH	Динамическая условная корреляция GARCH(1,1)
DM	Дибольд–Мариано (тест)
EDA	Разведочный анализ данных
ElasticNet	Регрессия с регуляризацией Elastic Net
ETF	Биржевой инвестиционный фонд
ETH	Ethereum (ETH-USD)
F1	F1-мера (среднее гармоническое точности и полноты)
GARCH	Обобщённая авторегрессионная условная гетероскедастичность
GBM	Метод градиентного бустинга
GLD	SPDR Gold Shares ETF (GLD)
GPU	Графический процессор
GSPC	Индекс S&P 500 (GSPC)
HAR	Гетерогенная авторегрессионная модель
IXIC	Индекс NASDAQ Composite (IXIC)
MAE	Средняя абсолютная ошибка
ML	Машинное обучение
NASDAQ	Национальная ассоциация дилеров ценных бумаг (автоматизированные котировки)
OOS	Вне обучающей выборки
RF	Случайный лес
RMSE	Среднеквадратичная ошибка

Сокращение	Полная форма
ROC	Характеристическая кривая
S&P 500	Индекс Standard & Poor's 500
SLV	iShares Silver Trust ETF (SLV)
UUP	Invesco DB US Dollar Index Bullish Fund (UUP)
XGB	XGBoost (экстремальный градиентный бустинг)

1 Введение

1.1 Мотивация и исследовательский контекст

Постепенная интеграция рынков криптовалют в глобальную финансовую систему превратила их из технологического эксперимента в реальный канал межрыночной передачи рисков. Bitcoin, в частности, стал непрерывно торгуемым активом с высокой видимостью, динамика цен которого привлекает внимание не только нативных участников криптовалютного рынка, но и институциональных портфельных менеджеров, макростратегов и регуляторных наблюдателей. По мере созревания рыночной инфраструктуры и углубления институционального участия возникает существенный исследовательский вопрос: несёт ли информация, заложенная в динамике цен криптовалют, прогностическое содержание относительно будущих условий на рынках традиционных классов активов — таких как акции, металлы или валютные инструменты?

Данная работа отвечает на этот вопрос, исследуя изменяющуюся во времени межрыночную зависимость. Вместо попыток напрямую прогнозировать ценовые уровни или доходности анализ моделирует эволюционирующую взаимосвязь между Bitcoin и традиционными активами через структуры скользящей корреляции и исследует, поддаются ли эти структуры прогнозированию в строгих условиях оценки вне обучающей выборки. Это различие методологически важно. Кросс-рыночная корреляция, как хорошо задокументировано, нестационарна, демонстрируя выраженную временну´ю изменчивость в периоды, характеризующиеся стрессом ликвидности, инфляционным давлением, ужесточением денежно-кредитной политики или резкими переходами в склонности инвесторов к риску. В таких условиях знак и величина межрыночных связей могут меняться с темпами, которые традиционные долгосрочные статические предпосылки диверсификации неспособны учесть.

Практическая мотивация не менее убедительна. Ориентированный на риск портфельный менеджер не нуждается в точном прогнозе доходности на один день вперёд, чтобы извлечь полезную информацию. Во многих контекстах управления рисками более важна информация о раннем распознавании того, что рыночная среда претерпевает структурный сдвиг — что

паттерны совместного движения меняются и что условная вероятность стрессового эпизода на рынках традиционных активов растёт. Если информация, полученная из криптовалют, вносит измеримый вклад в такую способность к раннему предупреждению, то даже скромное и статистически ограниченное прогностическое преимущество представляет собой значимый вклад в количественное управление рисками.

1.2 Исследовательские вопросы

Центральная исследовательская проблема декомпозируется на два взаимодополняющих уровня. Первый уровень — научный и методологический: поддаются ли прогнозированию изменяющиеся во времени межрыночные зависимости между Bitcoin и традиционными активами в дисциплинированных условиях оценки вне обучающей выборки, и как модели машинного обучения работают относительно классических эконометрических бенчмарков при строгой пошаговой оценке? Второй уровень — прикладной: можно ли преобразовать прогнозы зависимостей, полученные на основе динамики криптовалют, в рыночно релевантный сигнал предупреждения, способный обеспечить своевременную идентификацию повышенного риска снижения на традиционных рынках?

Более конкретно, работа отвечает на следующие исследовательские вопросы:

1. Поддаётся ли скользящая зависимость между Bitcoin и традиционными активами прогнозированию вне обучающей выборки?
2. Превосходят ли модели машинного обучения защищённый от утечки бенчмарк DCC-GARCH?
3. Добавляют ли модели машинного обучения ценность сверх простых базовых моделей, основанных на персистентности, таких как AR1?
4. Можно ли преобразовать прогнозы зависимостей, полученные из криптовалютных данных, в практически полезный сигнал предупреждения о стрессе для традиционных рынков?

1.3 Вклад работы

Для ответа на эти вопросы в работе построен воспроизводимый модульный прогностический конвейер, реализованный на Python. Конвейер поглощает ценовые данные, вычисляет лог-доходности, строит цели скользящей корреляции по нескольким длинам окон, разрабатывает лагированные и основанные на волатильности предикторы, и оценивает ряд моделей в рамках пошагового экспериментального дизайна. Набор моделей охватывает простые базовые модели персистентности, регуляризованные линейные методы, ансамблевые методы на основе деревьев, XGBoost и защищённую от утечки реализацию бенчмарка DCC-GARCH. Поверх этапа прогнозирования зависимостей наложен второй, ориентированный на инвестора слой; этот слой классифицирует стрессовые режимы для традиционных активов на основе криптовалютных признаков и прогнозируемой динамики зависимостей.

Эмпирические результаты поддерживают существенный, но тщательно ограниченный вывод. Прогнозирование зависимостей вне обучающей выборки осуществимо; цель не является непредсказуемым шумом. Однако доминирующим источником предсказуемости является сильная серийная персистентность, присущая самому процессу зависимости, и, следовательно, наиболее конкурентоспособными базовыми моделями являются авторегрессионные варианты и варианты наивной персистентности. Этот результат — не недостаток системы; это существенный эмпирический результат. Он устанавливает, что ценность машинного обучения в данном контексте является инкрементальной и сравнительной, а не трансформационной, и что любое утверждение о значительных прогностических преимуществах должно оцениваться относительно достаточно сильных базовых моделей персистентности. Сигнальная модель второго слоя демонстрирует умеренную, но статистически значимую прогностическую ценность, функционируя наиболее эффективно в качестве вспомогательного фильтра риска, а не всеобъемлющего направленного предиктора.

Таким образом, вклад работы трояк. Во-первых, в ней строится чистая, воспроизводимая система для прогнозирования скользящей межрыночной зависимости между криптовалютными и традиционными рынками активов. Во-вторых, обеспечивается структурированное, методологически строгое сравнение классического эконометрического моделирования с репрезентативным набором подходов машинного обучения в условиях пошаговой оценки. В-третьих, анализ прогнозирования зависимостей распространяется на прикладной слой предупреждения инвестора, тем самым устанавливая явный и прозрачный мост между статистической задачей прогнозирования и практически релевантным контекстом принятия решений.

1.4 Структура работы

Остальная часть работы организована следующим образом. Раздел 2 посвящён обзору теоретических основ моделирования зависимостей, изменяющихся во времени, финансовой заразности, методов прогнозирования на основе машинного обучения и статистической системы сравнения моделей. Раздел 3 представляет набор данных, методологию построения целевой переменной, процедуру разработки признаков, спецификации моделей и систему оценки. Раздел 4 содержит эмпирические результаты как для слоя прогнозирования зависимостей, так и для инвесторского сигнального слоя. Раздел 5 интерпретирует полученные результаты, исследует их импликации, а также признаёт основные ограничения исследования. Раздел 6 содержит заключение и предлагает направления для будущих исследований.

---

2 Теоретическая основа и обзор литературы

2.1 Почему межрыночная зависимость важна

Межрыночная зависимость занимает центральное место в современной финансовой теории, поскольку преимущества диверсификации, распространение финансовой заразности,

эффективность стратегий хеджирования и измерение портфельного риска — всё это принципиально зависит от структуры совместного движения активов. В канонической схеме среднего и дисперсии зависимость резюмируется константным коэффициентом корреляции. Однако эмпирические данные давно установили, что это статическое представление неадекватно. Попарные корреляции изменяются во времени, асимметрично реагируют на положительные и отрицательные шоки и имеют тенденцию резко возрастать во время рыночных спадов — именно тогда, когда диверсификация наиболее срочно необходима [1]. Следовательно, прогнозирование зависимостей, изменяющихся во времени, теоретически мотивировано и практически незаменимо для управления рисками.

Актуальность динамической зависимости усиливается, когда один из изучаемых активов основан на криптовалюте. Bitcoin торгуется на непрерывном, глобально доступном рынке, быстро реагирует на изменения настроений и ликвидности финансирования, и одновременно подвержен широкому спектру экономических нарративов: спросу на защиту от инфляции, спекулятивному аппетиту к риску, технологическому оптимизму, регуляторной неопределённости и глобальному макро-позиционированию. Это множество движущих факторов означает, что Bitcoin не занимает единой, стабильной роли в многоактивном портфеле. В разные моменты делового и кредитного цикла он может проявлять характеристики спекулятивного высокобетного инструмента роста, чувствительного к ликвидности риск-прокси или идиосинкратического барометра настроений. Эта структурная нестабильность делает его взаимосвязь с традиционными активами уникально подходящей для анализа с изменяющимися во времени параметрами.

2.2 Криптовалюты и традиционные активы

Академическая литература на стыке рынков криптовалют и традиционных классов активов существенно расширилась за последнее десятилетие, развиваясь по нескольким самостоятельным исследовательским направлениям. Одно из них рассматривает Bitcoin как самостоятельный актив и характеризует его распределение доходностей, кластеризацию волатильности, профиль хвостового риска и степень информационной эффективности в слабой форме. Второе исследует портфельную диверсификацию и задаётся вопросом, обеспечивает ли Bitcoin экономически значимые преимущества диверсификации относительно фондовых индексов, золота, сырой нефти или основных фиатных валют. Третье направление, наиболее непосредственно релевантное данной работе, изучает связанность, заразность и переливы доходностей и волатильности между рынками, уделяя особое внимание кризисным и стрессовым эпизодам.

Повторяющимся результатом во всех этих направлениях является структурная нестабильность [2, 3]. Зависимость между Bitcoin и широкими фондовыми индексами, как правило, статистически слаба или направленно непоследовательна в спокойных рыночных условиях, но существенно усиливается в эпизоды выраженного «риск-он» или «риск-офф» позиционирования [4, 5]. Драгоценные металлы демонстрируют, как правило, более низкое и более переменчивое совместное движение с Bitcoin [6, 7], что объясняется различием их

инвесторских баз и устоявшейся ролью убежища. Валютные инструменты добавляют дополнительное измерение, служа прокси для глобальной ликвидности финансирования [3].

Эти эмпирические закономерности мотивируют стратегию моделирования, принятую в данной работе. Вместо того, чтобы навязывать статический коэффициент зависимости или оценивать единую полновыборочную корреляцию, работа моделирует зависимость как изменяющийся во времени процесс. Эта спецификация учитывает постепенный дрейф режима, резкие структурные разрывы и неоднородность в темпах и направлении изменений совместного движения по длинам окон и парам активов.

2.3 Скользящая корреляция как цель прогнозирования

Оценщик скользящей корреляции концептуально прозрачен и вычислительно практичен. Для двух рядов доходностей $\{r_1,t\}$ и $\{r_2,t\}$ скользящая корреляция в момент t по окну длиной w определяется как:

$$\hat{\rho}_t^{(w)} = \frac{\sum_{s=t-w+1}^{t}(r_{1,s}-\bar{r}_{1,t})(r_{2,s}-\bar{r}_{2,t})}{\sqrt{\sum_{s=t-w+1}^{t}(r_{1,s}-\bar{r}_{1,t})^2}\cdot\sqrt{\sum_{s=t-w+1}^{t}(r_{2,s}-\bar{r}_{2,t})^2}}$$

где $\bar{r}_{k,t}$ обозначает внутриоконное среднее ряда k. Обход этого оценщика по всем t даёт временной ряд $\{\hat{\rho}_t^{(w)}\}$, характеризующий временну´ю эволюцию межрыночного совместного движения.

Цель скользящей корреляции обладает несколькими свойствами, делающими её привлекательной в исследовании прогнозирования. Она непосредственно интерпретируема: положительные значения сигнализируют о сонаправленном движении, тогда как отрицательные указывают на хеджирующую взаимосвязь. Она сопоставима по парам активов и длинам окон, что обеспечивает систематический многоактивный анализ. Она фокусирует внимание на изменениях рыночной структуры, а не на динамике уровней отдельных рядов доходностей.

Основной методологической трудностью, накладываемой данной целью, является сильная серийная персистентность. Поскольку $\hat{\rho}_t^{(w)}$ строится из перекрывающихся наблюдательных окон, последовательные оценки делят $w - 1$ общих наблюдений, порождая высокую автокорреляцию в целевом ряду. Эта персистентность, по всей вероятности, будет доминировать над прогностической эффективностью и может помешать сложным моделям машинного обучения существенно превзойти простые авторегрессионные базовые модели. Данная работа рассматривает это свойство не как препятствие, а как аналитически важную эмпирическую характеристику процесса зависимости.

Для улучшения статистического поведения цели в работе применяется z-преобразование Фишера:

$$z_t^{(w)} = \frac{1}{2} \ln \left(\frac{1 + \hat{\rho}_t^{(w)}}{1 - \hat{\rho}_t^{(w)}} \right)$$

которое отображает ограниченные корреляционные значения $\hat{\rho} \in (-1, 1)$ в приблизительно неограниченную вещественнозначную величину, чьё выборочное распределение ближе к Гауссовскому. Это преобразование является стандартной практикой в анализе корреляционноподобных величин и стабилизирует дисперсию вблизи границ единичного интервала.

Важной альтернативой скользящей корреляции Пирсона является система зависимостей на основе копул [8], которая отдельно моделирует предельные распределения и структуру зависимости, тем самым улавливая хвостовую зависимость и нелинейное совместное движение, которые корреляция Пирсона не может обнаружить. Данная работа принимает скользящую корреляцию Пирсона по четырём причинам: (i) непосредственная интерпретируемость для практиков риск-менеджмента; (ii) вычислительная практичность в рамках пошаговой оценки; (iii) совместимость с бенчмарком DCC-GARCH, выходом которого является условная корреляционная матрица R_t, полученная из условной ковариационной структуры [9]; (iv) z-преобразование Фишера стабилизирует выборочное распределение вблизи границ единичного интервала. Ограничение корреляцией Пирсона признаётся как недостаток, а расширения на основе копул определены как приоритет для будущих исследований.

2.4 Эконометрический бенчмарк: DCC-GARCH

Модель динамической условной корреляции GARCH, введённая Энглом [10], обеспечивает классический эконометрический бенчмарк для данного исследования. Система DCC-GARCH разлагает условную ковариационную матрицу H_t вектора доходностей r_t согласно:

$$H_t = D_t R_t D_t$$

где $D_t = \mathrm{diag}(h_{1,t}^{1/2}, h_{2,t}^{1/2})$ — диагональная матрица условных стандартных отклонений, а R_t — изменяющаяся во времени условная корреляционная матрица. Каждая условная дисперсия $h_{k,t}$ следует одномерному процессу GARCH(1,1):

$$h_{k,t} = \omega_k + \alpha_k \varepsilon_{k,t-1}^2 + \beta_k h_{k,t-1}$$

где $\varepsilon_{k,t} = r_{k,t} / h_{k,t}^{1/2}$ — стандартизованный остаток. Стандартизованные остатки $\tilde{\varepsilon}_t = D_t^{-1} r_t$ затем используются для обновления псевдо-корреляционной матрицы Q_t:

$$Q_t = (1 - a - b)\bar{Q} + a \tilde{\varepsilon}_{t-1} \tilde{\varepsilon}_{t-1}^\top + b Q_{t-1}$$

где $\bar{Q}$ — безусловная ковариация стандартизованных остатков, а скалярные параметры a ⩾ 0, b ⩾ 0, a + b < 1 определяют скорость возврата к среднему и персистентность условной корреляции. Условная корреляционная матрица восстанавливается как:

$$R_t = \mathrm{diag}(Q_t)^{-1/2} Q_t \mathrm{diag}(Q_t)^{-1/2}$$

DCC-GARCH концептуально хорошо подходит для данной работы, поскольку явно моделирует изменяющееся во времени совместное движение в условиях гетероскедастичности, характерной как для криптовалютных, так и для традиционных фондовых доходностей. Однако зависимость модели от конкретной параметрической структуры может ограничивать её адаптируемость, когда данные демонстрируют нелинейные взаимодействия или структурные разрывы. Кроме того, реализации, оценивающие модель на полной выборке до вычисления прогнозов вне обучающей выборки, непреднамеренно используют будущую информацию. Для устранения этого источника утечки в данной работе применяется строгий протокол пошаговой переоценки, при котором модель DCC-GARCH переобучается на расширяющемся окне на каждом шаге оценки.

2.5 Подходы машинного обучения к прогнозированию

Машинное обучение релевантно для прогнозирования финансовых зависимостей не потому, что обеспечивает гарантированное преимущество в производительности, а потому, что предлагает класс моделей, способных улавливать нелинейные паттерны, пороговую динамику и многомерные эффекты взаимодействия, которые трудно задать параметрически. В данной работе методы машинного обучения оцениваются относительно как эконометрического бенчмарка DCC-GARCH, так и простых базовых моделей персистентности, с двойной целью: охарактеризовать их относительные сильные стороны и определить условия, при которых они вносят инкрементальную прогностическую ценность.

2.5.1 Модель HAR и прогнозирование на основе персистентности

Гетерогенная авторегрессионная (HAR) модель, введённая Корси [11], обеспечивает естественный бенчмарк для прогнозирования персистентных финансовых временны́х рядов. Модель HAR аппроксимирует динамику длинной памяти путём суммирования трёх авторегрессионных компонент, действующих на дневном, недельном и месячном горизонтах:

$$z_t = \varphi_0 + \varphi_d z_{t-1} + \varphi_w \bar{z}_{t-5:t-1} + \varphi_m \bar{z}_{t-22:t-1} + \varepsilon_t$$

где $\bar{z}_{t-k:t-1}$ обозначает среднеарифметическое z за предшествующие k периодов. Эта спецификация особенно хорошо подходит для целей скользящей корреляции, которые наследуют структуру сглаживания скользящей средней из перекрывающихся наблюдательных окон, используемых при их построении [12]. Отсутствие HAR в наборе моделей данной работы является признанным ограничением; её включение резервируется для будущих работ, где

систематическое сравнение HAR с AR1 и методами машинного обучения по нескольким горизонтам прогнозирования было бы информативным.

2.5.2 Регуляризованные линейные модели

Регуляризованные линейные модели, включая гребневую регрессию (Ridge) и Elastic Net, представляют собой сильные базовые модели в структурированных задачах прогнозирования по табличным данным. Гребневая регрессия накладывает штраф ℓ_2 на вектор коэффициентов, сжимая оценки к нулю для уменьшения дисперсии оценивания без введения разреженности. Elastic Net объединяет регуляризацию ℓ_1 и ℓ_2:

$$\hat{\beta} = \arg\min_{\beta} \left\{ \frac{1}{n} \sum_{i=1}^{n} (y_i - x_i^\top \beta)^2 + \lambda \left[(1-\alpha) \|\beta\|_2^2 + \alpha \|\beta\|_1 \right] \right\}$$

где $\lambda > 0$ — общая сила регуляризации, а $\alpha \in [0, 1]$ определяет относительный вклад двух штрафов [13]. Компонент ℓ_1 способствует разреженности и неявному отбору переменных, что желательно, когда многие лагированные предикторы несут слабый или избыточный сигнал. Эти модели особенно хорошо подходят к текущему набору признаков, содержащему многочисленные преобразования высоко коррелированных рядов доходностей и волатильности.

Несмотря на линейную функциональную форму, регуляризованные модели часто конкурентоспособны в задачах прогнозирования, управляемых плавной персистентностью. Когда отношение сигнал/шум скромное и доминирующим признаком является лагированное значение самой цели, смещение, вносимое линейностью, часто перевешивается уменьшением дисперсии, достигнутым за счёт регуляризации.

2.5.3 Ансамблевые модели на основе деревьев

Случайные леса строят ансамбль деревьев решений, каждое из которых обучается на бутстрапированной подвыборке и случайном подмножестве признаков, и агрегируют их прогнозы для уменьшения дисперсии и повышения обобщаемости [14]. Методы градиентного бустинга, напротив, строят деревья последовательно, причём каждое новое дерево подгоняется к псевдо-остаткам текущего ансамбля [15]. XGBoost расширяет эту схему бустинга аппроксимациями градиентов второго порядка, штрафными членами ℓ_1 и ℓ_2 на структуру дерева и вычислительными оптимизациями, обеспечивающими крупномасштабное применение [16].

Ансамблевые методы на основе деревьев являются естественными кандидатами для данной задачи прогнозирования, поскольку взаимосвязь между криптовалютными признаками и динамической межрыночной зависимостью может включать нелинейности и эффекты взаимодействия. Предельное влияние реализованной волатильности Bitcoin на будущую зависимость с акциями, например, может существенно отличаться в зависимости от того, уже ли повышен текущий корреляционный режим. Ансамбли деревьев могут обнаруживать и

использовать такие условные паттерны без необходимости заранее задавать структуру взаимодействия.

Тем не менее ансамблевые методы на основе деревьев не являются однозначно лучшими в одношаговом прогнозировании высокоперсистентной цели. Когда цель в подавляющей степени определяется своим наиболее недавним лагированным значением, более гибкие модели могут вносить пренебрежимо малый дополнительный сигнал, неся при этом более высокий штраф за дисперсию оценивания. Это является основной мотивацией дисциплинированного пошагового сравнения, представленного в работе.

2.6 Пошаговая оценка и утечка информации

Временно´й порядок финансовых временны´х рядов накладывает строгие требования на дизайн оценки. Случайные разбиения на обучающую и тестовую выборки недопустимы в данном контексте, поскольку они нарушают причинный порядок наблюдений и вводят предвзятость прогноза в будущее, позволяя модели, обученной на данных периода $t + k$, предсказывать результаты периода t. Единственной обоснованной стратегией оценки для прогнозирования временны´х рядов является та, при которой каждый прогноз генерируется исключительно с использованием информации, доступной на момент или до момента прогнозирования.

Поэтому в работе применяется пошаговая процедура, при которой модели обучаются на расширяющемся историческом окне, производится одношаговый прогноз, после чего окно расширяется на одно наблюдение. Для балансировки вычислительных затрат и реализма переобучение модели выполняется с периодическими интервалами, а не на каждом единственном шаге. Этот дизайн отражает операционные ограничения реального прогностического развёртывания и исключает возможность непреднамеренной утечки.

Протокол оценки наделяется той же степенью важности, что и отбор моделей. Сложная модель, оцениваемая с неявной утечкой, может казаться значительно превосходящей более простого, правильно оцениваемого конкурента, порождая вводящее в заблуждение сравнение бенчмарков. Поскольку цель работы — дать обоснованные эмпирические выводы, методологическая целостность оценки рассматривается как безусловное требование.

2.7 Сравнение моделей и тест Дибольда–Мариано

Ранжирование моделей по средней ошибке прогнозирования за период оценки вне обучающей выборки предоставляет полезную описательную информацию, но не устанавливает, являются ли наблюдаемые различия в производительности статистически отличимыми от выборочной вариации. Тест Дибольда–Мариано устраняет этот пробел, предоставляя формальный критерий нулевой гипотезы о равной прогностической точности двух конкурирующих прогнозов [17].

Пусть e_1,t и e_2,t обозначают ошибки прогнозирования моделей 1 и 2 в момент t, а $d_t = g(e_1,t) - g(e_2,t)$ — дифференциал потерь при функции потерь $g(\cdot)$ (обычно квадратической или абсолютной ошибки). Статистика теста ДМ:

$$DM = \frac{\bar{d}}{\sqrt{\hat{V}(\bar{d})/T}} \xrightarrow{d} N(0,1)$$

где $\bar{d} = T^{-1}\sum_{t=1}^{T} d_t$ — среднее дифференциала потерь, $\hat{V}(\bar{d})$ — оценщик дисперсии, гетероскедастичности- и автокорреляционно-устойчивый (HAC), а T — количество периодов оценки. При нулевой гипотезе равной прогностической точности статистика асимптотически стандартно нормальна.

В контексте данной работы тест ДМ служит двум различным выводным целям. Первая — определить, даёт ли наилучшая конфигурация машинного обучения статистически значимое улучшение по сравнению с защищённым от утечки бенчмарком DCC-GARCH. Вторая — установить, выдерживает ли какое-либо кажущееся преимущество машинного обучения над простыми авторегрессионными или наивными базовыми моделями персистентности формальную статистическую проверку. Это второе сравнение критически важно: провал в статистически значимом превышении базовой линии AR(1) будет означать, что основная часть прогнозируемости происходит от серийной персистентности целевого ряда, а не от межактивного обучения признаков.

2.8 От прогнозирования зависимостей к инвесторским сигналам

Исследование, ограниченное статистическим прогнозированием скользящей корреляции, представляло бы собой самодостаточный академический вклад. Однако практическая мотивация данной работы требует дополнительного аналитического слоя. Для того чтобы результаты прогнозирования стали полезными с точки зрения инвестора, прогнозы зависимостей должны быть переведены в объект, релевантный для принятия решений, который напрямую адресует задачу управления рисками.

Поэтому в работе вводится второй этап — сигнальный слой. Вместо прогнозирования направления доходности следующего дня для традиционного актива сигнальный слой определяет вероятность того, что следующий торговый день будет принадлежать стрессовому режиму, определяемому условиями повышенного нижнестороннего риска для рассматриваемого традиционного актива. Такая постановка более непосредственно согласована с портфельным управлением рисками, где основная цель состоит не в предсказании каждого дневного колебания, а в своевременном заблаговременном предупреждении об ухудшении рыночных условий.

Разделение прогнозирования и сигнализации на отдельные этапы также отражает более широкую эпистемологическую точку зрения. Модель, являющаяся научно информативной — в смысле снижения ошибки прогнозирования относительно бенчмарка, — не обязательно непосредственно реализуема как торговое правило, и, наоборот, модель, спроектированная для бинарной классификации рыночного стресса, может жертвовать статистической точностью ради теоретико-решенческой релевантности. Делая это разделение явным, работа

устанавливает прозрачный и интеллектуально честный мост между академической задачей прогнозирования и прикладным контекстом портфельного управления рисками.

2.9 Позиционирование данной работы

Данная работа занимает пересечение финансовой эконометрики, методологии машинного обучения и прикладного количественного анализа рисков. Она не выдвигает утверждения о том, что криптовалютные данные способны решить проблему выбора момента для входа на рынок. Скорее, она рассматривает более точно сформулированное и эмпирически обоснованное утверждение: что динамика цен криптовалют содержит статистически значимую информацию об эволюции структур межрыночной зависимости, и что эта информация может использоваться для построения скромного, но экономически значимого сигнала раннего предупреждения для рынков традиционных активов.

Это позиционирование принципиально важно для интерпретации результатов. Основной научный вклад работы состоит в установлении прогнозируемости динамической межрыночной зависимости и в строгом сравнении базовых моделей персистентности, методов машинного обучения и эконометрического бенчмарка DCC-GARCH в рамках последовательного протокола пошаговой оценки. Инвесторский сигнальный слой расширяет этот вклад в практическом направлении, оставаясь при этом заземлённым на том, что эмпирические данные могут законно поддерживать.

---

3 Методология

3.1 Дизайн исследования

В работе принят многоуровневый дизайн исследования. Первый уровень — задача прогнозирования регрессионного типа, в которой цель — следующее значение преобразованного ряда скользящей корреляции между Bitcoin и другим активом. Второй уровень — задача классификационного типа, в которой выход первого уровня вместе с криптовалютными признаками используется для оценки вероятности стрессового дня для традиционного актива. Эта структура отражает различие между научным измерением и практическим действием.

Дизайн намеренно консервативен. Вместо оптимизации исключительно для подгонки внутри выборки все важные решения по моделированию встроены в пошаговую схему оценки. Это включает формирование целевой переменной, выравнивание признаков, оценку бенчмарка и генерацию сигнала. Цель — сохранить временну´ю реалистичность и минимизировать риск случайной предвзятости прогноза в будущее.

3.2 Вселенная активов и источник данных

Эмпирический анализ использует дневные рыночные данные, полученные через интерфейс

yfinance [18]. Bitcoin, представленный как BTC-USD, служит базовой криптовалютой на протяжении всего исследования. Сравнительный набор включает следующие активы:

Таблица 1: Вселенная активов, используемых в работе.

Тикер	Описание
BTC-USD	Bitcoin, базовая криптовалюта
ETH-USD	Ethereum, криптовалютный ориентир
GSPC	Индекс S&P 500
IXIC	Индекс NASDAQ Composite
GLD	ETF на золото
SLV	ETF на серебро
UUP	Прокси ETF на индекс доллара США

Эта вселенная выбрана по содержательным, а не исключительно техническим причинам. Два фондовых индекса представляют широкие рисковые активы США. ETF на золото и серебро улавливают экспозицию к драгоценным металлам, часто связанную с инфляционными опасениями, нарративами безопасного убежища или настроениями в сырьевом секторе. Прокси индекса доллара отражает глобальную силу доллара и защитное макропозиционирование. Ethereum включён в качестве дополнительного криптовалютного ориентира для сопоставления внутрикриптовалютной зависимости с зависимостью криптовалют к традиционным активам.

Выборка охватывает период с 9 ноября 2017 года по 27 февраля 2026 года, давая 2 976 дневных наблюдений по каждому активу. Эффективная дата начала определяется доступностью данных по цене Ethereum на Yahoo Finance; более ранние даты не содержат наблюдений по ETH-USD и поэтому исключаются из выровненной панели. Полученный набор данных сбалансирован: все семь тикеров имеют идентичный временной индекс без пропущенных наблюдений после выравнивания и прямого заполнения пробелов неторговых дней до двух последовательных календарных дней.

Рисунок 1: Нормализованная динамика цен всех семи активов за полный период выборки (2017–2026). Ряды масштабированы к общей базе, равной 1 на начальную дату, для визуального сравнения относительной доходности.

3.3 Построение доходностей и предобработка

Все ценовые ряды преобразуются в дневные лог-доходности. Лог-доходности предпочтительны,

поскольку они аддитивны во времени и являются стандартными как в эконометрическом моделировании, так и в конвейерах машинного обучения для финансовых временны́х рядов. Для ценового ряда P_t доходность вычисляется как:

$$r_t = \log P_t - \log P_{t-1}$$

Пропущенные наблюдения обрабатываются путём выравнивания по доступным датам, и все последующие цели и признаки строятся только после синхронизации матрицы доходностей.

В кодовой базе используется кэш-осведомлённый рабочий процесс предобработки. Если необработанные ценовые данные уже существуют, они повторно используются для обеспечения воспроизводимости. Если структура цен или вселенная тикеров меняется, обработанные доходности пересчитываются. Это позволяет избежать устаревших промежуточных файлов, сохраняя при этом эффективность рабочего процесса.

3.4 Построение целевой переменной: скользящая зависимость

Для каждой пары, состоящей из Bitcoin и другого актива, ряд скользящей корреляции вычисляется по окнам длиной 14, 30, 60 и 90 торговых дней. Пусть $r_t^{(b)}$ обозначает доходность Bitcoin, а $r_t^{(a)}$ — доходность другого актива. Для заданной длины окна w цель зависимости в момент t:

$$\rho_t^{(w)} = \operatorname{corr}\left(r_{t-w+1:t}^{(b)}, r_{t-w+1:t}^{(a)}\right)$$

Полученный ряд затем преобразуется с помощью преобразования Фишера:

$$z_t^{(w)} = \frac{1}{2}\log\left(\frac{1+\rho_t^{(w)}}{1-\rho_t^{(w)}}\right) = \operatorname{arctanh}\left(\rho_t^{(w)}\right)$$

которое отображает ограниченную корреляционную область $(-1, 1)$ в неограниченное вещественнозначное пространство. В эмпирической реализации одношаговое значение преобразованной зависимости используется как основная цель прогнозирования. Реализация отсекает сырую корреляцию от границы для предотвращения численного переполнения:

```
python
```

```python
def fisher_z(r: pd.Series, eps: float = 1e-6) -> pd.Series:
    # Отсечь от +/-1 для предотвращения переполнения arctanh
    return np.arctanh(r.clip(-1 + eps, 1 - eps))

def build_target(returns, base, other, window, horizon):
    corr = returns[base].rolling(window).corr(returns[other]).dropna()
    # Сдвиг на horizon для получения одношаговой цели
    target = corr.shift(-horizon).dropna()
    return fisher_z(target)
```

Ключевая импликация этого дизайна состоит в том, что цель уже является сглаженным объектом. Следовательно, она значительно более персистентна, чем сырой ряд доходностей. Эта персистентность является одной из определяющих эмпирических характеристик работы и непосредственно отражается в последующих результатах.

Рисунок 2: Скользящая зависимость между Bitcoin и каждым из пяти традиционных активов по всем четырём длинам окон (14, 30, 60, 90 дней). Ряд после z-преобразования Фишера иллюстрирует сильную временну´ю изменчивость и персистентность, мотивирующие систему прогнозирования.

3.5 Разработка признаков

Набор признаков намеренно структурирован вокруг интерпретируемых финансовых величин. Цель состоит не в создании чрезмерно большой матрицы предикторов типа «чёрного ящика», а в разработке компактного набора переменных, которые могут правдоподобно влиять на будущую динамику зависимостей.

Признаки делятся на несколько групп:

Таблица 2: Основные группы предикторов, используемых в слое прогнозирования зависимостей.

Группа	Описание
Лаги зависимости	Недавние значения целевого ряда скользящей зависимости
Лаги доходностей	Лагированные доходности Bitcoin и парного актива
Скользящие средние	Локальное среднее доходности за короткие периоды
Скользящая волатильность	Локальное стандартное отклонение доходностей
Спред-признаки	Абсолютные и знаковые разрывы между поведением криптовалюты и актива
Разрыв корреляционного режима	Корреляция по короткому окну минус корреляция по длинному окну

Лаги зависимости особенно важны, поскольку цель по конструкции персистентна. Лаги доходностей позволяют моделям реагировать на недавнюю направленную информацию. Меры скользящих средних и волатильности резюмируют локальные условия режима. Разрыв корреляционного режима (corr_diff) улавливает, расходится ли краткосрочная зависимость с более долгосрочной базой, что может сигнализировать о надвигающемся смене режима.

```python
# Лаги зависимости: наиболее важная группа предикторов
for lag in [1, 2, 5, 10]:
    features[f"dep_lag{lag}"] = y_current.shift(lag)

# Скользящая волатильность обоих активов
features["vol_base"] = returns[base].rolling(window).std().reindex(idx)
features["vol_other"] = returns[other].rolling(window).std().reindex(idx)

# Лаги доходностей для обоих активов
for lag in [1, 2, 5]:
    features[f"r_base_lag{lag}"] = returns[base].shift(lag).reindex(idx)
    features[f"r_other_lag{lag}"] = returns[other].shift(lag).reindex(idx)

# Разрыв корреляционного режима: корреляция по короткому окну минус по длинному
corr_short = rolling_corr(returns[base], returns[other],
                          max(5, window // 4)).reindex(idx)
corr_long = rolling_corr(returns[base], returns[other],
                         window).reindex(idx)
features["corr_diff"] = corr_short - corr_long
```

Инвесторский сигнальный слой наследует наилучший доступный прогноз зависимости для пары и объединяет его с криптовалютными предикторами для формирования меньшего набора признаков, ориентированного на классификацию. На практике это означает, что второй слой информируется как текущим состоянием крипторынка, так и оцениваемым направлением процесса зависимостей.

3.6 Модели прогнозирования

3.6.1 Базовые модели

В каждый эксперимент прогнозирования включены две простые базовые модели. Первая — **Naive_Last**, которая предсказывает следующее значение зависимости, используя самое последнее наблюдённое значение зависимости. Вторая — **AR1**, оценивающая одно-лаговую авторегрессионную структуру. Эти базовые модели существенны, поскольку цель персистентна. Поэтому любая более сложная модель должна обосновывать себя относительно этих весьма сильных простых альтернатив.

3.6.2 Регуляризованные линейные модели

Линейный блок машинного обучения включает **Ridge** и **Elastic Net**. Перед обучением этих моделей применяется стандартизация, поскольку регуляризация коэффициентов зависит от масштаба признаков. Ожидается, что Ridge хорошо работает, когда многие предикторы слабые, но коррелированные. Elastic Net более агрессивен и может быть предпочтительным, если только подмножество переменных содержит стабильную информацию.

3.6.3 Ансамбли деревьев

Нелинейный блок включает **Random Forest**, **GBM** и **XGBoost**. Эти модели обучаются в пошаговых условиях с периодическими переобучениями. XGBoost пытается использовать GPU при его наличии, но автоматически переключается в режим CPU, если окружение не поддерживает запрошенную конфигурацию. Это делает конвейер более надёжным и предотвращает сбой из-за аппаратно-специфической проблемы.

```python
```

```
models = {
    "Naive_Last": None,  # базовая модель персистентности (не требует обучения)
    "AR1": LinearRegression(),
    "Ridge": make_pipeline(StandardScaler(), Ridge(alpha=1.0)),
    "ElasticNet": make_pipeline(
        StandardScaler(),
        ElasticNet(alpha=0.01, l1_ratio=0.5, max_iter=5000)
    ),
    "RF": RandomForestRegressor(
        n_estimators=300, max_depth=8, n_jobs=-1
    ),
    "GBM": GradientBoostingRegressor(
        n_estimators=300, max_depth=4, learning_rate=0.05
    ),
    "XGB": xgb.XGBRegressor(
        device="cuda", n_estimators=300,
        max_depth=5, learning_rate=0.05,
        subsample=0.8, colsample_bytree=0.8
    ),
}
```

3.6.4 Бенчмарк DCC-GARCH

Защищённый от утечки пошаговый бенчмарк DCC-GARCH реализован как отдельный модуль в проекте. Это ключевая методологическая корректировка по сравнению со многими упрощёнными сравнениями, встречающимися в исследовательских работах. Вместо того, чтобы подгонять DCC по полной выборке, а затем оценивать его, как если бы это было вне обучающей выборки, бенчмарк повторно оценивается на обучающем окне и прогнозы производятся вперёд от этой точки. Это делает бенчмарк медленнее, но методологически последовательным.

3.7 Инвесторский сигнальный слой

Сигнальный слой переформулирует задачу как задачу классификации для раннего предупреждения. Цель — не общее направление следующего дня, а индикатор стрессового дня для традиционного актива. Стрессовый день определяется относительно распределения отрицательных доходностей с использованием настраиваемого порога на основе стандартных отклонений. Такой дизайн цели намеренно консервативен и лучше согласован с практической целью нижнестороннего защиты.

В этом слое оцениваются три классификатора: логистическая регрессия, классификация случайным лесом и классификация методом градиентного бустинга. Вероятностный выход каждой модели сравнивается с порогом для решения, следует ли инвестору расценивать следующий день как повышенного риска. Это делает выход интерпретируемым как

вероятностно-управляемое предупреждение, а не бинарная инструкция торгового «чёрного ящика».

3.8 Пошаговая схема оценки

Во всех экспериментах используется пошаговый дизайн с расширяющимся окном. Пусть начальная обучающая выборка содержит первые T_0 наблюдений. Для каждого момента прогнозирования $t \geqslant T_0$ модель обучается на наблюдениях до момента t включительно, после чего используется для прогноза на $t + 1$. Процесс продолжается до конца выборки. Периодическое переобучение используется для снижения вычислительной нагрузки при сохранении причинного порядка.

```python
for t in range(min_train, n_obs):
    train_idx = np.arange(0, t)

    # Периодически переобучать все модели на расширяющемся обучающем окне
    if (t - last_refit) >= refit_every:
        last_refit = t
        for name, model in model_specs.items():
            if model is not None:
                model.fit(X_values[train_idx], y_values[train_idx])
                fitted[name] = model

    # Одношаговый прогноз — использует только информацию до момента t
    for name in fitted:
        preds[name][t] = fitted[name].predict(X_values[[t]])[0]
```

Этот дизайн имеет несколько преимуществ. Он отражает реальные условия прогнозирования, поддерживает справедливые сравнения бенчмарков и генерирует полный временной ряд ошибок прогнозирования вне обучающей выборки. Последнее полезно не только для средних метрик, но и для диагностики скользящих ошибок и тестирования Дибольда-Мариано.

3.9 Метрики оценки

Для слоя прогнозирования зависимостей производительность оценивается с помощью средней абсолютной ошибки (MAE), среднеквадратичной ошибки (RMSE) и внеобучающего коэффициента детерминации R^2. RMSE акцентируется в ранжировании моделей, поскольку сильнее штрафует за крупные отклонения и хорошо подходит для плавных непрерывных целей.

Для инвесторского сигнального слоя основными метриками являются сбалансированная точность (Balanced Accuracy), F1-мера для нижестороннего класса, площадь под ROC-кривой (AUC) и частота выхода (exit rate). Сбалансированная точность особенно важна, поскольку классификация стрессовых дней — задача с несбалансированными классами. F1 для

нижнестороннего класса фокусирует внимание на качестве обнаружения негативных событий. Частота выхода измеряет, как часто сигнал выводил бы инвестора с рынка, тем самым соединяя качество прогноза с практической частотой использования.

3.10 Методология сравнения моделей

Средние метрики сами по себе могут вводить в заблуждение, когда различия между моделями невелики. Поэтому в работе применяется тест Дибольда–Мариано для сравнения рядов потерь прогнозирования между избранными парами моделей. Основное интересующее сравнение — между наиболее сильной конфигурацией машинного обучения, не являющейся бенчмарком, и бенчмарком DCC-GARCH. Вторичное сравнение противопоставляет эту модель машинного обучения наивной базовой модели персистентности.

Эта конфигурация намеренно прозрачна. Работа не скрывает того факта, что наилучшая общая модель может оказаться простой базовой. Вместо этого система ДМ используется для различения трёх уровней утверждений:

1. поддаётся ли зависимость вообще прогнозированию;
2. улучшает ли машинное обучение результаты по сравнению с классическим эконометрическим бенчмарком;
3. добавляет ли машинное обучение ценность сверх персистентности.

Эмпирические выводы работы организованы именно вокруг этих трёх уровней.

3.11 Реализация и воспроизводимость

Весь рабочий процесс реализован на Python и организован как модульная кодовая база. Основной конвейер координирует загрузку конфигурационных файлов, вычисление доходностей, генерацию целей, построение признаков, обучение моделей, производство файлов прогнозов, сохранение рисунков и экспорт таблиц, готовых для LaTeX. Специализированные модули используются для пошагового бенчмаркинга DCC, поддержки блокнотов и инвесторского сигнального слоя. Эта модульная структура важна, поскольку работа — не только концептуальное исследование, но и воспроизводимый вычислительный артефакт.

Выходные данные хранятся в структурированной иерархии каталогов. Метрики, результаты тестов ДМ и сигнальные результаты сохраняются в CSV-файлах; таблицы, готовые для диссертации, экспортируются в LaTeX; визуальная диагностика сохраняется в виде рисунков. Этот дизайн сокращает ручную постобработку и помогает согласовать исследовательский рабочий процесс с процессом написания.

3.12 Методологические ожидания

Прежде чем перейти к эмпирическим результатам, полезно прояснить, что следует считать успехом. Успех в данной работе не означает обнаружение модели, которая идеально предсказывает все традиционные рынки по данным Bitcoin. Это был бы нереалистичный

стандарт для любого серьёзного исследования в области финансового прогнозирования. Более подходящий стандарт таков:

- целевой показатель зависимости должен демонстрировать прогнозируемость вне обучающей выборки;
- сравнение с бенчмарком должно выявить, улучшает ли машинное обучение результаты по сравнению с DCC-GARCH;
- инвесторский сигнальный слой должен обеспечивать ненулевые и практически интерпретируемые предупреждения о стрессе.

Эти критерии скромны, но научно обоснованы. Они позволяют работе делать утверждения, одновременно эмпирически подтверждённые и интеллектуально честные.

---

4 Эмпирические результаты

4.1 Обзор эмпирического вывода

Конвейер генерирует всестороннее, внутренне последовательное множество эмпирических артефактов: метрики производительности вне обучающей выборки, ранжирование моделей, результаты тестов Дибольда–Мариано, статистику классификации инвесторских сигналов, ряды прогнозов и диагностические рисунки. Широта этого вывода намеренна. Эмпирический вклад работы не может быть сведён к единой таблице; он опирается на согласованность и перекрёстную последовательность доказательств, рассмотренных с нескольких взаимодополняющих углов — средней точности прогнозирования, статистической значимости различий в производительности, временно́й динамики ошибок и практического качества предупреждения о стрессе.

Из агрегированных данных вытекают два всеобъемлющих результата. Первый: процесс зависимости поддаётся прогнозированию в строгих условиях пошаговой оценки вне обучающей выборки. Второй: основным источником прогнозируемости является сильная серийная персистентность цели скользящей корреляции, а не извлечение новой межактивной информации. Эти два результата взаимодополняемы: вместе они точно характеризуют, чем является задача прогнозирования и чем она не является.

4.2 Средняя эффективность прогнозирования зависимостей

Таблица 3 сообщает среднюю производительность вне обучающей выборки основных моделей, агрегированную по всем экспериментам прогнозирования зависимостей. Ранжирование определяется в первую очередь по RMSE — метрике, наиболее чувствительной к крупным отклонениям в плавной, ограниченной цели.

Таблица 3: Средняя производительность прогнозирования вне обучающей выборки по всем экспериментам прогнозирования зависимостей.

Модель	Средний RMSE	Средний MAE	Средний R^2
AR1	0,0665	0,0405	0,9423
Naive_Last	0,0672	0,0395	0,9411
Ridge	0,0914	0,0636	0,8917
ElasticNet	0,0921	0,0643	0,8902
RF	0,1009	0,0709	0,8694
GBM	0,1035	0,0732	0,8630
XGB_GPU	0,1043	0,0744	0,8605
DCC_GARCH	0,2147	0,1687	0,3814

Примечание: результаты усреднены по всем комбинациям пар активов и длин окон. RMSE и R^2 вычислены на пошаговых прогнозах вне обучающей выборки. Наилучшая модель за исключением DCC-GARCH — AR1.

Из Таблицы 3 вытекают четыре примечательных паттерна. Первый: наивысшую позицию занимает базовая модель AR1 со средним RMSE 0,0665 и внеобучающим $R^2 = 0{,}9423$. Второй: наивная модель персистентности практически неотличима от AR1 (разница RMSE составляет 0,0007), подтверждая, что доминирующий механизм прогнозирования авторегрессионен по своей природе. Третий: регуляризованные линейные модели Ridge и ElasticNet занимают промежуточный уровень со значениями R^2 около 0,89, превосходя все ансамблевые методы на основе деревьев в среднем. Четвёртый: бенчмарк DCC-GARCH занимает последнее место со значительным отрывом, показывая средний R^2 лишь 0,3814, что указывает на то, что параметрическая модель условной корреляции не является конкурентоспособной в прямом одношаговом прогнозировании цели скользящей корреляции после z-преобразования Фишера.

Интерпретация точна. Цель зависимости сильно персистентна, и эта персистентность составляет основной прогностический сигнал. Улучшение по сравнению с AR1 или наивной базовой моделью персистентности требует извлечения информации сверх самого последнего значения зависимости; данные показывают, что ни одна из оцениваемых здесь моделей не делает этого систематически и в значимом масштабе.

4.3 Репрезентативный пример прогноза

Рисунок 3 представляет панель прогнозов вне обучающей выборки для пары Bitcoin–S&P 500

при 30-дневном скользящем окне. Эта пара выбрана как репрезентативный пример, поскольку взаимосвязь BTC–GSPC соединяет криптовалютный рынок с наиболее широким бенчмарком риска традиционных акций США.

Рисунок 3: Наблюдаемая и прогнозируемая зависимость после z-преобразования Фишера для пары Bitcoin–S&P 500 при 30-дневном скользящем окне. Ряды прогнозов генерируются в условиях строгой пошаговой оценки без использования будущей информации.

Рисунок выявляет три характерные черты задачи прогнозирования. Цель эволюционирует плавно, что согласуется с её построением из перекрывающихся наблюдательных окон. Наиболее сильные модели отслеживают широкую направленную траекторию с ограниченным систематическим смещением. Однако локальные смены режима представляют устойчивую трудность: когда структура зависимости резко смещается, все модели демонстрируют недостаточную реакцию, причём величина различается по семействам моделей. Именно в этой среде DCC-GARCH наиболее сильно отстаёт и методы машинного обучения могут предложить относительное улучшение, даже не достигая безусловной точности простых базовых моделей персистентности.

4.4 Эффективность прогнозирования по классам активов

Агрегированные метрики производительности скрывают информативную поперечную изменчивость. Пара Bitcoin–Ethereum демонстрирует наибольшую прогнозируемость: оба актива разделяют фундаментальные движущие факторы ликвидности и настроений, порождая особенно плавную и автокоррелированную цель. Соответственно, эта пара показывает наивысшие внеобучающие значения R^2, причём производительность дополнительно усиливается при больших длинах окон.

Пары с драгоценными металлами — Bitcoin–золото и Bitcoin–серебро — занимают промежуточный уровень прогнозируемости. Скользящая корреляция демонстрирует режимно-зависимую структуру, чередуя близкие к нулю и слабоположительные или слабоотрицательные значения совместного движения. Несмотря на эту нестабильность, цели поддаются прогнозированию, причём базовые модели персистентности продолжают доминировать.

Пары фондовых индексов — Bitcoin–S&P 500 и Bitcoin–NASDAQ — наиболее практически значимы. Они связывают динамику криптовалют с широкими условиями аппетита к риску и демонстрируют выраженную режимную чувствительность: в эпизоды «риск-он» совместное движение усиливается; в периоды рыночных дислокаций оно может усиливаться или резко разворачиваться. Эта чувствительность составляет основной источник сложности прогнозирования для пар акций.

Пара Bitcoin–прокси индекса доллара демонстрирует наиболее слабую и наиболее идиосинкратическую структуру зависимости по выборке, фиксируя наименьшую среднюю прогнозируемость. Тем не менее она аналитически ценна как тест того, доступны ли каналы защитной макроинформации для набора признаков на основе криптовалют.

Для оценки того, является ли преимущество пар акций над непарными активами статистически значимым, а не артефактом выборки, объединённые ряды потерь вне обучающей выборки для пар акций (S&P 500, NASDAQ) сравниваются с нефондовыми парами (золото, серебро, индекс доллара) с использованием двухвыборочного теста Дибольда–Мариано [17].

4.5 Результат доминирования персистентности

Результат о том, что простые базовые модели персистентности доминируют в среднем ранжировании производительности, следует интерпретировать как диагностическое свидетельство о природе цели прогнозирования, а не как ограничение подхода машинного обучения.

Результат непосредственно вытекает из конструкции целевой переменной. Скользящая корреляция Пирсона, вычисленная по окну из w торговых дней, разделяет $w - 1$ наблюдений с предшествующим окном, индуцируя сильный эффект сглаживания скользящей средней. После z-преобразования Фишера полученный ряд демонстрирует сильную серийную автокорреляцию, при которой лаг первого порядка улавливает подавляющее большинство предсказуемой дисперсии. Любая модель, обусловленная в первую очередь на самом последнем значении зависимости, будет поэтому структурно достигать высокого внеобучающего R^2.

Эта интерпретация подтверждается диагностикой важности признаков случайного леса. Лагированный член зависимости доминирует в рейтинге важности по всем экспериментам, тогда как лаги доходностей, меры скользящей волатильности и разрыв корреляционного режима вносят вклад лишь незначительно. Данные устанавливают, что задача поддаётся прогнозированию главным образом потому, что цель имеет память, а не потому, что набор предикторов содержит сильные межактивные сигналы, независимые от недавней динамики зависимостей.

4.6 Сравнение с DCC-GARCH

Несмотря на доминирование базовых моделей персистентности в безусловном ранжировании, машинное обучение обеспечивает практически и статистически значимое улучшение по сравнению с DCC-GARCH. Рисунок 4 представляет сравнение Дибольда–Мариано между наилучшей моделью машинного обучения и бенчмарком DCC по всем экспериментам.

Рисунок 4: Результаты теста Дибольда–Мариано, сравнивающего наилучшую модель машинного обучения с DCC-GARCH по всем комбинациям пар активов и длин окон. Более тёмные ячейки указывают на более сильное и статистически значимое свидетельство превосходства машинного обучения.

Результаты ДМ подтверждают, что наилучшая спецификация машинного обучения превосходит DCC-GARCH со статистической значимостью в большинстве экспериментов. Этот результат теоретически обоснован: DCC-GARCH разработан для моделирования полной условной ковариационной структуры системы доходностей; его проекция на скользящую корреляцию Пирсона является производным, сглаженным побочным продуктом, а не

напрямую оптимизированной целью прогнозирования. Модели машинного обучения, напротив, обучаются напрямую минимизировать ошибку прогнозирования на цели после z-преобразования Фишера, что составляет структурное преимущество выравнивания задачи в данном экспериментальном дизайне.

Важно признать фундаментальное несоответствие измерений, присущее этому сравнению. Цель скользящей корреляции Пирсона является сглаженной, ретроспективной величиной, чья серийная персистентность механически индуцируется конструкцией на основе перекрывающегося окна. DCC-GARCH, напротив, моделирует мгновенную условную ковариацию как параметрический перспективный объект; его проекция в пространство скользящей корреляции Пирсона вводит систематический лаг, который является не сбоем модели, а определенческой несовместимостью [9, 12]. Эта оговорка не делает сравнение недействительным — оба объекта являются законными мерами зависимости, — но означает, что величину разрыва в производительности следует интерпретировать с надлежащей осторожностью, а не как безусловное осуждение системы DCC-GARCH.

Работа сохраняет точное концептуальное различие между *превосходством над бенчмарком* — превышением DCC-GARCH — и *безусловным превосходством* — превышением AR1. Машинное обучение последовательно достигает первого; оно систематически не достигает второго. Оба вывода информативны, и их сосуществование определяет вклад машинного обучения в данном контексте.

4.7 Диагностика профиля ошибок

Агрегированные метрики ошибок предоставляют необходимую, но неполную характеристику качества прогноза. Временная и распределительная диагностика раскрывает, когда и как модели ошибаются. Рисунок 5 показывает скользящий профиль RMSE для репрезентативного эксперимента Bitcoin–S&P 500.

Рисунок 5: Скользящий RMSE вне обучающей выборки во времени для эксперимента прогнозирования зависимости Bitcoin–S&P 500. Эпизоды повышенной ошибки соответствуют периодам резкого перехода режима в процессе зависимости.

Скользящий профиль ошибок показывает, что качество прогноза неоднородно во времени. В периоды постепенной эволюции зависимости все модели достигают низких уровней ошибок, поскольку доминирующий сигнал персистентности хорошо улавливается любой разумной спецификацией. Во время резких переходов режима уровни ошибок возрастают по всем моделям, но величина и продолжительность ухудшения систематически различаются. Модели машинного обучения склонны восстанавливаться несколько быстрее, что согласуется с их большей гибкостью в адаптации к структурным изменениям в соотношении признак–цель.

Диагностика распределения ошибок прогноза дополнительно устанавливает, что доминирующим источником ошибки прогнозирования является эпизодическая недостаточная реакция на резкие поворотные точки, а не систематическое смещение. Модели надёжно улавливают низкочастотный, персистентный компонент эволюции зависимости; они

испытывают трудности с высокочастотным, разрывным компонентом. Эта асимметрия имеет прямые последствия для инвесторского сигнального слоя, где своевременная идентификация периодов начала стресса является центральной целью.

4.8 Инвесторский сигнальный слой: средние результаты

Второй эмпирический слой переформулирует выход прогнозирования зависимостей как задачу классификации для предупреждения о стрессе. Таблица 4 сообщает среднюю классификационную производительность по семейству моделей, агрегированную по всем парам активов и длинам окон.

Таблица 4: Средняя производительность инвесторского сигнала по семействам классификаторов, агрегированная по всем экспериментам.

Сигнальная модель	Сбал. точность	F1_down	AUC
Logit	0,506	0,209	0,509
GBM_Cls	0,504	0,141	0,512
RF_Cls	0,500	0,030	0,517

Примечание: результаты усреднены по всем парам активов и длинам окон. Сбалансированная точность корректирует дисбаланс классов. F1_down измеряет качество обнаружения только для стрессового класса.

Задача классификации сигнального слоя значительно более требовательна, чем задача регрессии первого слоя. Идентификация стрессового дня по своей природе зашумлена, несбалансирована по классам и подвержена асимметричным издержкам неправильной классификации. Логистический классификатор последовательно достигает наивысшей F1-меры для стрессового класса (в среднем 0,209), что свидетельствует о сохранении чувствительности к реальным стрессовым эпизодам без вырождения в поведение с низкой частотой выхода.

Ансамблевые классификаторы на основе деревьев демонстрируют существенно более низкие F1-меры: GBM достигает в среднем 0,141, тогда как случайный лес почти обнуляется (0,030), обнаруживая расхождение в том, как два ансамблевых метода справляются с задачей несбалансированных классов. Близкая к нулю F1 случайного леса свидетельствует о вырожденном поведении с низкой частотой выхода, делающем его практически неинформативным, несмотря на номинально адекватные значения AUC.

Близкая к нулю F1-мера случайного леса заслуживает более детального диагностического изучения. Анализ распределений прогнозируемых вероятностей показывает, что случайный лес производит выходы, сконцентрированные в узком диапазоне, делая классификатор

нечувствительным к изменениям порога, тогда как GBM достигает умеренной, но ненулевой F1 (0,141). Коллапс случайного леса объясняется двумя совокупными факторами: во-первых, сильным дисбалансом классов между стрессовыми и нестрессовыми днями; во-вторых, отсутствием калибровки вероятностей — известно, что ансамблевые методы производят плохо откалиброванные оценки вероятностей без явной постобработки, такой как масштабирование Платта или изотонная регрессия [19]. В будущих работах калибровка должна быть включена в качестве обязательного этапа постобработки перед извлечением сигнала на основе порога.

Относительное преимущество логистической модели согласуется с теоретическим ожиданием того, что в бинарной классификации с низким отношением сигнал/шум и коррелированными предикторами регуляризованная линейная граница решения обеспечивает лучшее обобщение вне обучающей выборки, чем ансамблевые методы высокой ёмкости, подверженные раздуванию дисперсии.

4.9 Наилучшие конфигурации сигнала

Наивысшая индивидуальная производительность сигнала зафиксирована для пары Bitcoin–S&P 500. При 30-дневном окне логистическая классификация достигает сбалансированной точности 0,5361 и F1-меры 0,2492 для нижестороннего класса — скромное, но статистически и практически значимое отклонение от неинформативной базы 0,50.

Рисунок 6 представляет выход сигнала для этой конфигурации, иллюстрируя временно́е распределение предсказанных стрессовых флагов относительно реализованных стрессовых событий.

Рисунок 6: Сигнал предупреждения инвестора о стрессе для пары Bitcoin–S&P 500 при 30-дневном окне. Верхняя панель отображает предсказанную вероятность стресса от логистического классификатора вместе с порогом решения; нижняя панель отмечает сфлагированные и пропущенные стрессовые события.

Сигнал разработан для функционирования в качестве вероятностно-управляемого индикатора предупреждения, идентифицирующего периоды повышенного риска, тем самым поддерживая решение о снижении риска, а не направленную сделку. Для NASDAQ профиль производительности в целом схож. Для драгоценных металлов и прокси индекса доллара производительность более ослаблена и менее последовательна, что отражает более слабую и менее стабильную связь между динамикой криптовалют и стрессом на этих рынках.

4.10 Практическая интерпретация эффективности сигнального слоя

Практическая полезность сигнального слоя должна оцениваться относительно явно сформулированного стандарта решения. Инвестор, вооружённый сигналом, действует избирательно, а не при каждом наблюдении. Сигнал информирует условное решение по управлению рисками: снижать ли рыночную экспозицию, ужесточать ли стоп-лосс пороги или увеличивать интенсивность хеджирования в ответ на повышенную вероятность стресса.

В рамках этой постановки частота выхода — доля торговых дней, в которые сигнал активен, — является незаменимым дополнением к классификационной точности. Сигнал, который никогда не активен, не имеет практической полезности вне зависимости от формальной точности; сигнал, чрезмерно активный, порождает излишние транзакционные издержки и разбавляет информационное содержание. Логистическая модель достигает обоснованного баланса между чувствительностью и специфичностью, производя частоту выхода, достаточную для практической полезности без индуцирования чрезмерной оборачиваемости, характерной для сверхчувствительных классификаторов.

4.11 Чувствительность к длине скользящего окна

Длина скользящего окна является параметром дизайна первого порядка с измеримыми последствиями для свойств цели и производительности модели. Короткие окна дают более отзывчивые, но более зашумлённые оценки зависимости; более длинные окна генерируют более плавные, более автокоррелированные цели, которые легче прогнозировать, но медленнее отражают реальные структурные изменения.

Эксперименты подтверждают, что средние длины окон — в частности, $w = 30$ дней — обеспечивают благоприятный баланс. При этой спецификации цели достаточно плавны для поддержания высоких внеобучающих значений R^2, сохраняя при этом достаточную отзывчивость для информирования обнаружения стресса. При более длинных окнах эффект персистентности усиливается, сжимая разрыв в производительности между простыми базовыми моделями и более сложными. Это взаимодействие между длиной окна и производительностью модели составляет важный структурный результат, который информирует выбор горизонта оценки в смежных будущих работах.

4.12 Резюме эмпирических результатов

Эмпирические результаты работы резюмируются в четырёх основных утверждениях:

1. Изменяющаяся во времени межрыночная зависимость между Bitcoin и традиционными активами поддаётся прогнозированию в условиях пошаговой оценки вне обучающей выборки с высокими средними значениями R^2 по всем классам моделей.
2. Доминирующим источником прогностической силы является серийная персистентность цели скользящей корреляции; следовательно, авторегрессионные базовые модели и модели наивной персистентности возглавляют среднее ранжирование производительности.
3. Модели машинного обучения часто и значимо превосходят защищённый от утечки бенчмарк DCC-GARCH, но систематически не превосходят наиболее сильные базовые модели персистентности на одношаговом горизонте.
4. Инвесторский сигнальный слой даёт умеренные, статистически ненулевые результаты классификации, наиболее выраженные для широких рынков акций, и лучше всего

интерпретируется как дополнительный вклад в управление рисками, а не как самостоятельный направленный предиктор.

Эти результаты взаимно согласованы и коллективно достаточны для поддержки как научного, так и прикладного вклада работы. Их более широкие импликации рассмотрены в следующем разделе.

---

5 Обсуждение

5.1 Основные результаты

Наиболее надёжным выводом, поддержанным эмпирическими данными, является то, что изменяющаяся во времени межрыночная зависимость поддаётся прогнозированию в строгом смысле вне обучающей выборки. Этот результат нетривиален, поскольку значительная часть литературы рассматривает скользящую корреляцию прежде всего как ретроспективный диагностический инструмент. В данной системе она операционализируется как реальная цель прогнозирования и оценивается в условиях ограничений временного порядка, исключающих любое использование будущей информации. Данные демонстрируют, что цель сохраняет достаточную статистическую структуру для поддержания значимой средней точности вне обучающей выборки по нескольким парам активов и длинам окон.

Анализ одновременно устанавливает второй, столь же важный результат: прогностический успех автоматически не благоприятствует высокогибким моделям. Среднее ранжирование производительности обнаруживает обратное — простые базовые модели персистентности составляют наиболее конкурентоспособных прогнозистов. Этот результат отражает фундаментальное свойство цели. Скользящая зависимость, построенная из перекрывающихся наблюдательных окон и затем преобразованная Фишером, демонстрирует сильную серийную автокорреляцию. Любая модель, не учитывающая этот доминирующий авторегрессионный сигнал, скорее всего, будет производить субоптимальные прогнозы вне зависимости от её репрезентационной ёмкости.

5.2 Интерпретация результата персистентности

Доминирование базовых моделей AR1 и наивного последнего наблюдения может показаться при первом рассмотрении подрывающим вклад работы. Эта интерпретация неверна. Идентификация персистентности как основного источника прогнозируемости является существенным научным результатом, а не методологическим провалом. Цель прогностического исследования — определить истинную структуру предсказуемости, а не продемонстрировать превосходство конкретного класса методов.

Эмпирические данные предполагают два конкретных вывода о процессе зависимости. Во-первых, структура зависимости между Bitcoin и традиционными активами проявляет значимую память: текущее состояние скользящей корреляции информативно относительно её

ближайшего будущего состояния. Во-вторых, инкрементальная информация, вносимая межактивными признаками и моделями более высокой ёмкости, невелика относительно этого авторегрессионного сигнала, по меньшей мере в пределах изученного одношагового горизонта. Этот результат согласуется с более широкой литературой по предсказуемости доходностей и корреляций, которая последовательно документирует, что отношение сигнал/шум в финансовом прогнозировании низко, а персистентность часто составляет доминирующий компонент предсказуемости [20].

Методологическая целостность пошаговой оценки усиливает достоверность этого результата. Исследования финансового прогнозирования подвержены инфляционному смещению, когда внутривыборочная гибкость ошибочно принимается за реальную прогностическую ценность вне обучающей выборки. Данная работа противостоит этой тенденции и демонстрирует, что при честном протоколе оценки простые авторегрессионные базовые модели остаются грозными конкурентами.

5.3 Инкрементальный вклад машинного обучения

Результат о том, что базовые модели персистентности доминируют в среднем ранжировании производительности, не делает методы машинного обучения излишними в данной системе. Их вклад реализуется через три различных канала.

Во-первых, включение моделей машинного обучения расширяет класс сравнения теоретически важным образом: оно допускает прямое эмпирическое тестирование того, могут ли нелинейные методы, способные к взаимодействию, извлекать прогностический сигнал из набора признаков, недоступный линейным авторегрессионным моделям. Данные по этому вопросу информативны, даже когда ответ состоит в том, что они не могут делать это систематически.

Во-вторых, модели машинного обучения часто достигают меньшей ошибки прогнозирования, чем бенчмарк DCC-GARCH, даже когда уступают базовым моделям персистентности. Это значимый результат, поскольку DCC-GARCH является теоретически мотивированным и широко применяемым эконометрическим стандартом, а его превышение указывает на то, что гибкие методы, управляемые данными, способны улучшить параметрический бенчмарк в данной конкретной задаче прогнозирования.

В-третьих, методы машинного обучения демонстрируют более выраженные сравнительные преимущества во второй-слойной задаче сигнализации, где цель переходит от прямого прогнозирования зависимостей к бинарной классификации стрессовых режимов. Этот сдвиг в дизайне задачи лучше согласуется с сильными сторонами ансамблевых методов, которые могут моделировать сложные границы решения и более гибко справляться с дисбалансом классов, чем авторегрессионные спецификации.

Вклад машинного обучения в данной работе, следовательно, является сравнительным и структурным: в работе выявлены условия, при которых гибкие методы полезны и нет, тем самым добавляя аналитическую ценность, выходящую за рамки простого ранжирования производительности.

5.4 Интерпретация результата DCC-GARCH

Сравнительно слабая производительность DCC-GARCH заслуживает тщательной интерпретации. Модель является теоретически обоснованным и эмпирически устоявшимся бенчмарком для оценки динамической ковариации, и её концептуальная уместность для задач, связанных с изменяющимся во времени совместным движением, не подвергается сомнению. Однако конкретная эмпирическая задача данной работы — краткосрочное точечное прогнозирование сглаженной, преобразованной Фишером цели корреляции в условиях пошаговой переоценки — значительно более требовательна, чем сценарий использования, для которого DCC-GARCH был первоначально разработан.

Несколько факторов вносят вклад в его недостаточную производительность в этих условиях. Параметрическая структура DCC-GARCH относительно негибка в реагировании на быстрые или нелинейные локальные изменения зависимости, особенно когда истинный процесс отклоняется от предположений уравнений обновления. Интересующая цель — не сама условная ковариационная матрица, а производная, сглаженная скалярная величина, что вводит несоответствие между выходом модели и целью прогнозирования. Кроме того, защищённая от утечки пошаговая реализация лишает бенчмарк любого преимущества, которое возникло бы из оценки по полной выборке, а периодическое переобучение на коротких окнах может давать нестабильные оценки параметров для модели с несколькими степенями свободы.

Этот результат не следует обобщать как систематическое отвержение DCC-GARCH. Модель остаётся уместной для долгосрочного прогнозирования ковариаций, построения портфелей и приложений хеджирования рисков, где полная условная ковариационная структура является предметом интереса. Конкретный вывод ограничен одношаговым прогнозированием попарной скользящей корреляции между Bitcoin и традиционными активами — задачей, для которой базовые модели персистентности и методы машинного обучения демонстрируют превосходящую эмпирическую производительность.

5.5 Практические выводы для инвесторов

Инвесторская мотивация работы требует тщательной квалификации. Эмпирические результаты не поддерживают сильное утверждение о том, что информация, полученная из криптовалют, обеспечивает надёжное прогнозирование направления доходности следующего дня для традиционных классов активов. Такое утверждение было бы несовместимо с данными и с уровнем рыночной эффективности, характеризующей ликвидные традиционные рынки.

Что данные действительно поддерживают — это более точно ограниченное и обоснованное практическое утверждение: динамика криптовалют содержит информацию об эволюционирующей структуре зависимости традиционных активов, и эта информация может быть включена в механизм раннего предупреждения о периодах повышенного нижнестороннего риска. Поэтому сигнальный слой формулируется как *наложение риска* — дополнительный вклад в процесс управления рисками, а не самостоятельный направленный торговый сигнал.

В практическом портфельном контексте такой сигнал будет функционировать совместно с, а не вместо, фундаментальной оценки, макроэкономического анализа и стратегического распределения активов. Его операционная роль состояла бы в повышении порога вероятности для принятия риска, в побуждении к сокращению валовой экспозиции или в ужесточении динамических лимитов риска, когда классифицированная вероятность стрессового режима повышена. Для инвестора, ориентированного на риск, чья функция потерь непропорционально взвешивает тяжёлые просадки, умеренный, но статистически значимый сигнал предупреждения может генерировать положительную ожидаемую полезность даже при несовершенной классификационной точности.

5.6 Межактивная неоднородность в эффективности сигнала

Инвесторский сигнальный слой демонстрирует неоднородную производительность по вселенной традиционных активов. Качество сигнала наибольшее для широких фондовых индексов и ослабевает для драгоценных металлов и инструментов, связанных с долларом. Этот паттерн экономически интерпретируем.

Широкие фондовые рынки тесно связаны с глобальным аппетитом к риску, ликвидностью финансирования и настроениями инвесторов — тем же набором макрофинансовых сил, которые оказывают существенное влияние на Bitcoin. Следовательно, набор криптовалютных признаков улавливает значимую долю информации, движущей стрессовыми эпизодами на рынке акций.

Драгоценные металлы и инструменты, связанные с индексом доллара, реагируют на более широкий набор структурных макроэкономических сил — включая реальные процентные дифференциалы, спрос на убежище и геополитические риск-премии, — которые не полностью представлены в наборе предикторов, ориентированном на криптовалюты. Ослабленная производительность сигнала для этих инструментов, следовательно, согласуется с гипотезой информационного разрыва: набор признаков хорошо специфицирован для стресса акций, но неполен относительно движущих факторов стресса в других классах активов.

Это наблюдение подразумевает, что сигнальный слой наиболее уместно применять в качестве криптовалютно-информированного индикатора риска для чувствительных к росту и аппетиту к риску традиционных рынков. Обобщение его как универсальной системы предупреждения по всем классам активов преувеличивало бы охват эмпирических данных.

5.7 Методологические достоинства

Эмпирические выводы данной работы поддержаны рядом методологических решений, которые в совокупности снижают риск артефактных результатов.

Во-первых, весь конвейер от поглощения данных до оценки модульный и воспроизводимый, что допускает независимую верификацию всех результатов. Во-вторых, бенчмарк DCC-GARCH реализован в той же пошаговой системе, что и модели машинного обучения, устраняя асимметричное информационное преимущество, возникающее при оценке бенчмарка по

полной выборке. В-третьих, производительность модели оценивается по нескольким взаимодополняющим метрикам — RMSE, MAE, R^2, сбалансированная точность, F1, AUC и интерпретация частоты выхода, — снижая чувствительность к любой единственной функции потерь. В-четвёртых, тест Дибольда–Мариано применяется для определения победителя между конкурирующими моделями в соответствии с формальным статистическим критерием, а не с опорой на точечные оценки средней ошибки.

Эти решения в совокупности ограничивают вероятность того, что сообщённые выводы отражают выбор конкретной модели, конкретной метрики или конкретного реализационного упрощения, а не лежащую в основе структуру задачи прогнозирования.

5.8 Ограничения

Работа имеет ряд ограничений, которые должны быть признаны для определения области допустимых выводов.

Первое ограничение касается частоты данных. Все анализы проводятся на дневных рядах доходностей. Это разрешение соответствует вселенной активов, охватывающей как ликвидные традиционные рынки, так и криптовалютные биржи, и согласовано с горизонтом ежедневной перебалансировки, подразумеваемым в сигнальном слое. Однако дневные данные по необходимости исключают внутридневные информационные потоки и очень краткосрочные переливы волатильности, которые могут быть релевантны в контекстах высокочастотной торговли.

Второе ограничение касается горизонта прогнозирования. Основная задача прогнозирования зависимостей специфицирована как одношаговое прогнозирование вперёд. Это естественный исходный дизайн, но он структурно благоприятствует моделям, управляемым персистентностью, и не освещает, улучшается ли относительная производительность методов машинного обучения на многодневных или многонедельных горизонтах, где авторегрессионный сигнал может затухать быстрее.

Третье ограничение касается выбора меры зависимости. Скользящая корреляция является практичным и интерпретируемым оценщиком, но представляет лишь одного члена более широкого семейства мер зависимости. Коэффициенты хвостовой зависимости, меры согласованности на основе копул, оценщики реализованной ковариации и динамические частичные корреляции могут раскрывать структурные особенности совместного распределения, которые не адекватно улавливаются системой корреляции Пирсона.

Четвёртое ограничение касается цели стрессового режима. Бинарный индикатор стресса, используемый в сигнальном слое, экономически мотивирован, но является упрощённым представлением сложного и многомерного феномена рыночного стресса. Альтернативные операционализации — включая события максимальной просадки по скользящему окну, пороги превышения реализованной дисперсии или одновременные нижнесторонние эпизоды для нескольких активов — могут давать качественно иные характеристики сигнала.

Наконец, работа не включает портфельный бэктест с учётом транзакционных издержек. Это упущение намеренно: сигнальный слой представлен как инструмент мониторинга рисков, а не как полная торговая стратегия, и основной критерий оценки — статистическая прогностическая точность, а не реализованная портфельная производительность. Расширение на уровень портфеля потребует явной спецификации правил позиционирования, ограничений оборачиваемости и предположений о транзакционных издержках, выходящих за рамки данного исследования.

5.9 Направления будущих исследований

Из результатов данной работы вытекает ряд естественных расширений. Наиболее непосредственным приоритетом является исследование более длинных горизонтов прогнозирования для определения того, является ли сравнительное преимущество методов машинного обучения более выраженным, когда задача выходит за пределы режима персистентности на один шаг. Дополняющим расширением стало бы обогащение набора предикторов макрофинансовыми переменными — включая временны́е спреды, спреды свопов кредитного дефолта, индексы подразумеваемой волатильности акций и метрики он-чейн для криптовалют, — для оценки того, вносят ли эти переменные инкрементальную информацию сверх используемых здесь признаков на основе доходностей криптовалют.

Замена более богатыми мерами зависимости скользящей корреляции Пирсона представляет собой существенное теоретическое расширение. Структуры зависимости на основе копул, в частности, допускают раздельное моделирование предельных распределений и интенсивности совместного движения, а коэффициенты хвостовой зависимости обеспечивают более целевую характеристику поведения при совместных экстремальных доходностях.

На прикладной стороне интеграция сигнального слоя в систему оптимизации портфеля с явными ограничениями оборачиваемости и транзакционными издержками позволила бы оценить практическую полезность сигнала с точки зрения метрик производительности, релевантных для полезности, таких как уменьшение максимальной просадки, контроль нижнесторонней волатильности и улучшение коэффициента Калмара или Сортино. Такое расширение закрыло бы разрыв между статистической оценкой, проводимой в данной работе, и экономической оценкой, необходимой для обоснования оперативного развёртывания сигнала.

5.10 Общая оценка

Совокупность данных поддерживает взвешенный и эмпирически обоснованный вывод. Работа не демонстрирует, что криптовалютные рынки обладают прогностической силой над направленными движениями традиционных активов в общем смысле. Она строго демонстрирует, что динамика криптовалют содержит информацию о временно́й эволюции межрыночной зависимости, что этот процесс зависимости поддаётся прогнозированию вне обучающей выборки и что полученные прогнозы могут быть операционализированы как статистически значимый, пусть и умеренный, сигнал раннего предупреждения о повышенном нижнестороннем риске на традиционных рынках.

Основной вклад работы состоит именно в точности этого утверждения. Результаты не являются тривиально подтверждающими и не являются неправдоподобно сильными. Они откалиброваны по данным, основаны на строгой методологической системе и практически интерпретируемы в рамках того, что данные могут законно поддерживать.

---

6 Заключение

В данной работе исследовалось, содержит ли динамика цен криптовалют — Bitcoin в частности — статистически значимую информацию для прогнозирования изменяющихся во времени структур зависимости с традиционными рынками активов, и могут ли такие прогнозы зависимостей быть операционализированы в качестве практически релевантного сигнала раннего предупреждения для инвесторов. Для ответа на эти вопросы была разработана и оценена воспроизводимая двухуровневая аналитическая система в рамках строгого пошагового экспериментального дизайна. Первый уровень занимался прямым прогнозированием вне обучающей выборки скользящих попарных корреляций между Bitcoin и набором традиционных активов. Второй уровень конвертировал выход первого этапа в задачу бинарной классификации стрессовых режимов, генерируя обращённый к инвестору сигнал предупреждения о повышенном нижнестороннем риске.

Эмпирические данные устанавливают, что процесс межрыночной зависимости поддаётся прогнозированию вне обучающей выборки. Точность прогнозирования последовательно положительна по набору оценки, причём наивысшая производительность зафиксирована для межкриптовалютных пар и для среднесрочных–долгосрочных спецификаций скользящих окон. Однако основным источником этой предсказуемости является сильная серийная персистентность, присущая цели скользящей корреляции. Базовые авторегрессионные модели и модели наивной персистентности вследствие этого доминируют в среднем ранжировании производительности по парам активов. Этот результат не подрывает работу; скорее, он точно характеризует структуру задачи прогнозирования и предоставляет методологически честный отчёт о том, что данные могут поддерживать. Он устанавливает, что процесс зависимости обладает памятью и что доминирующий прогностический сигнал содержится в недавнем пути ряда корреляций.

Модели машинного обучения вносят значимый вклад в анализ, хотя и в сравнительной и структурной роли, а не как безусловные лидеры производительности. Они часто превосходят защищённый от утечки бенчмарк DCC-GARCH и обеспечивают более широкий класс сравнения, относительно которого можно оценить пределы чисто персистентного прогнозирования. Их относительное преимущество наиболее выражено во второй-слойной задаче сигнализации, где переход от регрессии к бинарной классификации стресса лучше согласуется с сильными сторонами ансамблевых методов. Инвесторский сигнальный слой демонстрирует, что криптовалютные признаки можно трансформировать в статистически значимый механизм раннего предупреждения о стрессовых режимах традиционных рынков.

Сигнал умеренен по величине, а не однозначен, и его практическая полезность лучше всего понимается как *наложение управления рисками* — дополнительный вклад в управление экспозицией и установку риск-лимитов, — а не как самостоятельный направленный предиктор.

Таким образом, работа устанавливает обоснованный академический вклад и ограниченный, но связный практический вклад. В академическом отношении она демонстрирует, что изменяющаяся во времени межрыночная зависимость между Bitcoin и традиционными активами поддаётся прогнозированию в строгих условиях оценки вне обучающей выборки, и предоставляет систематическое сравнение базовых моделей персистентности, методов машинного обучения и классического эконометрического бенчмарка в последовательных условиях оценки. В практическом отношении она показывает, что прогнозы зависимостей, информированные криптовалютной динамикой, могут поддерживать обращённый к инвестору механизм предупреждения, причём наиболее сильная и надёжная производительность сигнала наблюдается для широких фондовых индексов.

Будущие расширения данной работы должны адресовать следующие приоритеты: тестирование системы прогнозирования по нескольким горизонтам прогнозирования для оценки того, получают ли методы машинного обучения относительно базовых моделей персистентности по мере увеличения горизонта прогноза; дополнение набора признаков макрофинансовыми предикторами — такими как индексы подразумеваемой волатильности, кредитные спреды, переменные временно́й структуры и он-чейн метрики для криптовалют; замена цели скользящей корреляции Пирсона более богатыми представлениями зависимости, включая меры на основе копул и коэффициенты хвостовой зависимости; и интеграция сигнального слоя в систему оптимизации портфеля с явными транзакционными издержками и ограничениями оборачиваемости, что позволит проводить оценку по критериям производительности, релевантным для полезности. Даже в рамках текущего охвата данная работа предоставляет строгий и содержательно информативный ответ на исследовательскую проблему и вносит вклад в доказательную базу о роли динамики криптовалют в прогнозировании и управлении кросс-рыночным риском в традиционных портфелях активов.

Приложение A: Описание данных и дополнительный контекст

Данное приложение расширяет эмпирический контекст работы и предоставляет дополнительный фон, поддерживающий основной текст. Поскольку основная часть работы сосредоточена на аргументации и интерпретации, в приложение собран описательный материал, который иначе прерывал бы изложение центрального нарратива.

A.1 Описательная роль вселенной активов

Выбор активов в работе не произволен. Каждый инструмент представляет самостоятельное измерение традиционной финансовой системы, с которым можно сопоставить Bitcoin.

- **S&P 500** используется как широкий прокси для риска фондового рынка США и общих инвесторских настроений.
- **NASDAQ Composite** охватывает более ориентированный на рост и технологически тяжёлый рыночный сегмент, что делает его особенно интересным в отношении криптоактивов.
- **ETF на золото и серебро** представляют экспозицию к драгоценным металлам — области, часто ассоциируемой с хеджированием, инфляционными нарративами и дебатами о безопасном убежище.
- **Прокси индекса доллара США** отражает макро-защитное позиционирование и глобальную силу доллара.
- **Ethereum** включён в качестве криптовалютного сравнительного актива для сопоставления зависимости внутри одной экосистемы с кросс-рыночной зависимостью.

Полученный набор данных охватывает активы, различающиеся по базе инвесторов, условиям ликвидности, макрочувствительности и экономической интерпретации. Это разнообразие помогает избежать чрезмерно узких выводов.

A.2 Визуальный обзор набора данных

Рисунок 7 представляет нормализованные ценовые траектории для вселенной активов. Цель рисунка — не прямое сравнение уровней, а предоставление интуиции о том, насколько различаются лежащие в основе рыночные траектории.

Рисунок 7: Нормализованные цены активов, включённых в исследование.

Рисунок 8 показывает профили скользящей волатильности. Они показывают, что Bitcoin и связанные криптоактивы существуют в значительно более высоковолатильной среде, чем набор традиционных активов, что усиливает важность изучения зависимости динамически, а не статически.

Рисунок 8: Скользящая волатильность по вселенной активов.

Рисунок 9 предоставляет статическую тепловую карту корреляции, а рисунок 10 иллюстрирует динамическую структуру скользящей корреляции. Вместе они мотивируют основной выбор моделирования в работе: статические резюме недостаточны для описания кросс-рыночных взаимосвязей, рассматриваемых в исследовании.

Рисунок 9: Статическая тепловая карта корреляции ряда доходностей.

Рисунок 10: Обзор скользящей корреляции по вселенной активов.

A.3 Почему используются несколько скользящих окон

В работе используются 14-дневные, 30-дневные, 60-дневные и 90-дневные окна, поскольку ни

один горизонт зависимости не является универсально подходящим. Короткое окно более чувствительно к недавним шокам, но также более зашумлено. Более длинное окно производит более плавную цель и часто более сильную персистентность, но может медленно реагировать на смену режима. Оценка нескольких окон позволяет эмпирическому анализу разделить эти эффекты.

Результаты указывают, что выбор окна существенно формирует профиль прогнозируемости. Более длинные окна, как правило, легче прогнозировать, поскольку они более плавные, но их прогностический успех также более управляем персистентностью. Более короткие окна реагируют быстрее и поэтому более информативны относительно локальной нестабильности, хотя и ценой более зашумлённого поведения цели.

A.4 Дополнительные замечания по реализации

Проект организован таким образом, что каждый запуск конвейера производит последовательные выходы в каталогах `outputs/results`, `outputs/tables`, `outputs/figures` и `outputs/predictions`. Эта структура полезна не только для воспроизводимости, но и для написания. Поскольку таблицы и рисунки генерируются непосредственно из кодового конвейера, разрыв между выполнением эксперимента и написанием работы сокращается.

Другой полезной деталью реализации является то, что блокнотная среда согласована с конвейером. В блокноты внесены улучшения читаемости, так что рисунки интерпретируемы, бенчмарки выбраются надёжно, а вспомогательные функции могут повторно использоваться без хрупких предположений о путях. Это важно, поскольку на практике исследовательские блокноты часто становятся слабым звеном в академических проектах, если они отрываются от основного конвейера.

A.5 Резюме

Приложение подтверждает важный методологический момент: эмпирическая среда, изучаемая в данной работе, неоднородна, нестационарна в экономической интерпретации и достаточно богата для обоснования системы зависимостей, изменяющихся во времени. Описательные данные поддерживают стратегию моделирования, используемую в основной части работы.

Приложение B: Дополнительные результаты прогнозирования

Данное приложение собирает дополнительную диагностику прогнозирования и выходы сравнения моделей, которые дополняют основное эмпирическое обсуждение. Приложение намеренно акцентирует рисунки, поскольку они сообщают об изменениях в поведении модели более эффективно, чем чрезмерно широкие таблицы.

B.1 Рисунки сравнения моделей

Рисунок 11: Сравнение среднего RMSE по семействам моделей.

Рисунок 12: Сравнение R^2 моделей для 30-дневного окна.

Рисунок 13: Улучшение относительно наивной базовой модели.

B.2 Диагностика гиперпараметров и признаков

Рисунок 14: RMSE кросс-валидации при поиске по сетке для репрезентативной задачи прогнозирования Bitcoin–S&P 500.

Рисунок 15: Путь регуляризации для гребневой спецификации прогнозирования.

Рисунок 16: Читаемый вид важности признаков для модели случайного леса.

B.3 Диагностические графики для репрезентативной пары акций

Рисунок 17: Чувствительность к окну для слоя прогнозирования на основе XGBoost.

Рисунок 18: Диагностика рассеивания прогнозов для эксперимента зависимости Bitcoin–S&P 500.

Рисунок 19: Распределение ошибок прогноза для репрезентативного эксперимента зависимости Bitcoin–S&P 500.

B.4 Чувствительность по парам активов

Рисунок 20: Анализ чувствительности для пары Bitcoin–NASDAQ.

Рисунок 21: Анализ чувствительности для пары Bitcoin–золото.

Рисунок 22: Анализ чувствительности для пары Bitcoin–серебро.

Рисунок 23: Анализ чувствительности для пары Bitcoin–UUP.

Рисунок 24: Анализ чувствительности для пары Bitcoin–Ethereum.

B.5 Интерпретация

Дополнительные рисунки подкрепляют несколько положений, высказанных в основном тексте. Качество прогнозирования существенно зависит от выбора скользящего окна, цель остаётся сильно персистентной, а различия в производительности по семействам моделей легче интерпретировать через сравнительные визуализации, чем через единую статистику ранжирования.

Приложение C: Дополнительные результаты сигнального слоя

Данное приложение представляет дополнительные материалы для ориентированного на инвестора слоя предупреждения.

C.1 Рисунки сигнала по активам

Рисунок 25: Выход сигнального слоя для взаимосвязи Bitcoin–NASDAQ при 30-дневном окне.

Рисунок 26: Выход сигнального слоя для взаимосвязи Bitcoin–золото при 30-дневном окне.

Рисунок 27: Выход сигнального слоя для взаимосвязи Bitcoin–серебро при 30-дневном окне.

Рисунок 28: Выход сигнального слоя для взаимосвязи Bitcoin–UUP при 30-дневном окне.

C.2 Интерпретация кросс-рыночного предупреждения

Дополнительные рисунки сигнала показывают, что практический слой ведёт себя по-разному на различных рынках. Цели, связанные с акциями, демонстрируют несколько более чёткие эпизоды предупреждения, тогда как цели, связанные с металлами и долларом, более зашумлены и слабее. Эта асимметрия экономически обоснована и поддерживает интерпретацию того, что инвесторский слой следует применять избирательно, а не единообразно.

C.3 Сводная таблица

Таблица 5: Средняя производительность сигнального слоя по семействам классификаторов.

Сигнальная модель	Сбал. точность	F1_down	AUC
Logit	0,506	0,209	0,509
GBM_Cls	0,504	0,141	0,512
RF_Cls	0,500	0,030	0,517

Эти итоговые значения подтверждают, что сигнальный слой значим, но умерен. Его наиболее сильная роль — как дополнительного механизма предупреждения, а не самостоятельного распределителя.

Рисунок 29: Дополнительный сигнал предупреждения S&P 500 при 14-дневном окне.

Рисунок 30: Дополнительный сигнал предупреждения S&P 500 при 60-дневном окне.

Рисунок 31: Дополнительный сигнал предупреждения S&P 500 при 90-дневном окне.

Рисунок 32: Дополнительный сигнал предупреждения NASDAQ при 14-дневном окне.

Рисунок 33: Дополнительный сигнал предупреждения NASDAQ при 60-дневном окне.

Приложение D: Воспроизводимость и структура кода

D.1 Организация проекта

Вычислительная часть работы структурирована как воспроизводимый исследовательский проект, а не как набор несвязанных скриптов. Основные каталоги организованы следующим образом:

```
clode9/
|-- main.py                 # основная точка входа конвейера
|-- run_all.py              # полная автоматизация: конвейер + блокноты + LaTeX
|-- config.yaml             # конфигурация эксперимента
|-- requirements.txt        # зависимости Python
|-- thesis_app/             # основные модули Python
|   |-- pipeline.py         # данные, признаки, пошаговый режим, метрики
|   |-- dcc_walk.py         # бенчмарк DCC-GARCH, защищённый от утечки
|   |-- signal_layer.py     # инвесторский слой предупреждения о стрессе
|   |-- notebook_helpers.py # общие вспомогательные функции и стиль
|   |-- data_quality.py     # диагностика пропущенных значений и выбросов
|   `-- regime_analysis.py  # исторический каталог режимов
|-- notebooks/              # семь блокнотов Jupyter (01-07)
|-- data/raw/               # кэшированные скачанные ценовые данные
|-- data/processed/         # производные доходности
|-- outputs/results/        # CSV-резюме экспериментов
|-- outputs/tables/         # таблицы, экспортированные в LaTeX
|-- outputs/figures/        # все сгенерированные рисунки
`-- thesis/                 # данный документ
```

D.2 Основные модули реализации

Следующие модули составляют ядро системы прогнозирования:

- **pipeline.py**: оркестрирует полный рабочий процесс прогнозирования зависимостей и генерации сигналов.
- **dcc_walk.py**: содержит защищённую от утечки пошаговую реализацию DCC-GARCH.
- **signal_layer.py**: определяет инвесторский слой предупреждения и соответствующие метрики классификации.
- **notebook_helpers.py**: общие вспомогательные функции построения графиков, последовательный стиль и утилиты анализа, используемые во всех блокнотах.
- **data_quality.py**: выполняет диагностику пропущенных значений, выбросов и покрытия для сырого набора данных.

- **regime_analysis.py**: реализует исторический каталог режимов и условную по режиму статистику.

Это разделение ответственности полезно как научно, так и практически. Научно оно делает логику рабочего процесса легче поддающейся аудиту. Практически оно позволяет тестировать или улучшать отдельные модули без перезаписи всей системы.

D.3 Поток выполнения

Полный конвейер запускается через единую точку входа, координирующую получение данных, обучение моделей, выполнение блокнотов и компиляцию документа:

```python
import subprocess, sys
from pathlib import Path

BASE = Path(__file__).parent

def run_step(cmd, label):
    print(f"\n=== {label} ===")
    subprocess.run([sys.executable] + cmd, cwd=BASE, check=True)

# Шаг 1: основной конвейер (скачивание данных, модели, таблицы, рисунки)
run_step(["main.py"], "Pipeline")

# Шаг 2: выполнить все блокноты в алфавитном порядке
notebooks = sorted((BASE / "notebooks").glob("*.ipynb"))
for nb in notebooks:
    print(f" Executing {nb.name}")
    subprocess.run(
        ["jupyter", "nbconvert", "--to", "notebook",
         "--execute", str(nb), "--inplace"],
        cwd=BASE, check=True
    )

# Шаг 3: скомпилировать PDF диссертации
subprocess.run(
    ["latexmk", "-pdf", "-interaction=nonstopmode", "main.tex"],
    cwd=BASE / "thesis", check=True
)
```

На высоком уровне поток выполнения можно резюмировать следующим образом:

1. Загрузить конфигурацию и настройки путей.

2. Загрузить или обновить сырые ценовые данные с Yahoo Finance.
3. Вычислить синхронизированные лог-доходности.
4. Сгенерировать цели скользящей корреляции для каждой пары активов и окна.
5. Построить лагированные и основанные на волатильности матрицы признаков.
6. Обучить все модели в пошаговом режиме и сохранить прогнозы.
7. Вычислить метрики, тесты ДМ и экспортировать таблицы и рисунки.
8. Запустить инвесторский сигнальный слой и экспортировать сигнальные рисунки.
9. Выполнить семь блокнотов Jupyter для генерации дополнительной диагностики.
10. Скомпилировать документ диссертации в LaTeX.

Основное преимущество этого дизайна в том, что каждый рисунок и резюме, приведённые в работе, могут быть прослежены до последовательной вычислительной процедуры.

D.4 Конфигурация

Параметры эксперимента хранятся в `config.yaml` и считываются один раз при запуске конвейера. Это позволяет легко изменять диапазон дат, вселенную активов или набор окон без изменения исходного кода:

yaml

```yaml
start_date: "2016-01-01"  # эффективная дата начала: 2017-11-09 (доступность ETH)
end_date: null             # null = загружать до сегодняшнего дня

assets:
  crypto: ["BTC-USD", "ETH-USD"]
  traditional: ["^GSPC", "^IXIC", "GLD", "SLV", "UUP"]

base_asset: "BTC-USD"
rolling_windows: [14, 30, 60, 90]
forecast_horizon: 1
use_fisher_transform: true
min_train_size: 800
refit_every: 20
xgb_device: "cuda"
random_state: 42
```

D.5 Верификация, выполненная в ходе доработки проекта

В процессе доработки проекта был исправлен ряд проблем реализации для приведения кода в соответствие со стандартами уровня диссертации.

- Введён защищённый от утечки пошаговый бенчмарк DCC для устранения полновыборочного загрязнения взглядом вперёд.
- Конвейер метрик сделан последовательным, так что все релевантные модели, включая DCC, оцениваются через одно и то же итоговое разложение.
- Добавлено масштабирование признаков для регуляризованных линейных моделей.
- Блок XGBoost сделан устойчивым к отказу GPU через откат на CPU.
- Инвесторский сигнальный слой интегрирован в основной конвейер и экспортирован в специализированные таблицы и рисунки.
- Стабилизированы импорты блокнотов и логика построения графиков для представления и интерпретации.

Эти улучшения важны, поскольку диссертация оценивается не только по концептуальной идее, но и по тому, является ли её эмпирическая реализация надёжной, воспроизводимой и внутренне согласованной.

D.6 Как пересобрать артефакты работы

Практическим преимуществом текущего состояния проекта является то, что полный рабочий процесс можно повторно запустить с нуля одной командой из корня проекта:

```bash
python run_all.py
```

Или три этапа могут выполняться по отдельности:

1. Запустить основной конвейер:

```bash
python main.py
```

Генерирует CSV прогнозов, метрики, результаты тестов ДМ и большинство рисунков.

2. Выполнить блокноты по порядку:
   - `01_EDA_Dataset.ipynb` — обзор набора данных и рисунки EDA.
   - `02_GridSearch.ipynb` — поиск гиперпараметров с кросс-валидацией.
   - `03_Model_Comparison.ipynb` — таблица ранжирования моделей и тепловые карты.
   - `04_DM_Tests_Visuals.ipynb` — тепловая карта теста ДМ и ключевые рисунки прогнозов.

- `05_XGB_vs_DCC.ipynb` — скользящий RMSE, рассеивание и рисунки распределения ошибок.
- `06_Regime_Analysis.ipynb` — каталог режимов и диагностика качества данных.
- `07_Robustness_Checks.ipynb` — чувствительность переобучения, чувствительность порога стресса, бутстрап-доверительные интервалы, диагностика сигнала и кросс-активный тест ДМ.

3. Пересобрать PDF-документ из каталога `thesis/`:

```bash
pdflatex main.tex && biber main && pdflatex main.tex && pdflatex main.tex
```

Шаги 1 и 2 должны быть завершены до шага 3, поскольку ряд рисунков, используемых в работе, производится блокнотами. Это делает написанную работу поддерживаемой даже при обновлении лежащих в основе рыночных данных.

D.7 Итоговое замечание о воспроизводимости

Ценность воспроизводимости в данной работе не только техническая. Поскольку предмет касается финансового прогнозирования, где случайная утечка и избирательная отчётность являются постоянными рисками, прозрачная и повторно выполнимая кодовая база непосредственно укрепляет достоверность эмпирических выводов.

Список литературы

[1] François Longin и Bruno Solnik, «Extreme Correlation of International Equity Markets», в: *The Journal of Finance* 56.2 (2001), стр. 649–676.

[2] Elie Bouri et al., «On the hedge and safe haven properties of Bitcoin: Is it really more than a diversifier?», в: *Finance Research Letters* 20 (2017), стр. 192–198.

[3] Shaen Corbet et al., «Exploring the dynamic relationships between cryptocurrencies and other financial assets», в: *Economics Letters* 165 (2018), стр. 28–34.

[4] Qiang Ji et al., «Network causality structures among Bitcoin and other financial assets», в: *The Quarterly Review of Economics and Finance* 70 (2018), стр. 203–213.

[5] Ladislav Kristoufek, «What are Bitcoin's main drivers?», в: *PLOS ONE* 10.4 (2015), e0123923.

[6] Anne Haubo Dyhrberg, «Bitcoin, gold and the dollar — A GARCH volatility analysis», в: *Finance Research Letters* 16 (2016), стр. 85–92.

[7] Tony Klein, Hien Pham Thu и Thomas Walther, «Bitcoin is not the new gold — A comparison of volatility, correlation, and portfolio performance», в: *International Review of Financial Analysis* 59 (2018), стр. 105–116.

[8] Andrew J. Patton, «Modelling asymmetric exchange rate dependence», в: *International Economic Review* 47.2 (2006), стр. 527–556.

[9] Robert F. Engle и Kevin Sheppard, «Theoretical and empirical properties of dynamic conditional correlation multivariate GARCH», в: *NBER Working Paper* 8554 (2001).

[10] Robert F. Engle, «Dynamic Conditional Correlation: A Simple Class of Multivariate Generalized Autoregressive Conditional Heteroskedasticity Models», в: *Journal of Business & Economic Statistics* 20.3 (2002), стр. 339–350.

[11] Fulvio Corsi, «A simple approximate long-memory model of realized volatility», в: *Journal of Financial Econometrics* 7.2 (2009), стр. 174–196.

[12] Torben G. Andersen et al., «Modeling and forecasting realized volatility», в: *Econometrica* 71.2 (2003), стр. 579–625.

[13] Hui Zou и Trevor Hastie, «Regularization and Variable Selection via the Elastic Net», в: *Journal of the Royal Statistical Society: Series B* 67.2 (2005), стр. 301–320.

[14] Leo Breiman, «Random Forests», в: *Machine Learning* 45.1 (2001), стр. 5–32.

[15] Jerome H. Friedman, «Greedy Function Approximation: A Gradient Boosting Machine», в: *The Annals of Statistics* 29.5 (2001), стр. 1189–1232.

[16] Tianqi Chen и Carlos Guestrin, «XGBoost: A Scalable Tree Boosting System», в: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, стр. 785–794.

[17] Francis X. Diebold и Roberto S. Mariano, «Comparing Predictive Accuracy», в: *Journal of Business & Economic Statistics* 13.3 (1995), стр. 253–263.

[18] yfinance developers, *yfinance Documentation*, 2026, https://ranaroussi.github.io/yfinance/ (просмотрено 10.03.2026).

[19] Marcos Lopez de Prado, *Advances in Financial Machine Learning*, Wiley, 2018.

[20] Ivo Welch и Amit Goyal, «A Comprehensive Look at the Empirical Performance of Equity Premium Prediction», в: *The Review of Financial Studies* 21.4 (2008), стр. 1455–1508.

[21] Fakultet inžinjerskih nauka Univerziteta u Kragujevcu, *Master radovi*, 2026, https://www.cis.kg.ac.rs/master/ (просмотрено 10.03.2026).

[22] elektrotehnika, *nlatex: nthesis dokument klasa*, 2026, https://github.com/elektrotehnika/finlatex (просмотрено 10.03.2026).

[23] scikit-learn developers, *scikit-learn User Guide*, 2026, https://scikit-learn.org/stable/user_guide.html (просмотрено 10.03.2026).

[24] XGBoost developers, *XGBoost Documentation*, 2026, https://xgboost.readthedocs.io/en/stable/ (просмотрено 10.03.2026).

[25] arch developers, *arch Documentation*, 2026, https://bashtage.github.io/arch/ (просмотрено 10.03.2026).

[26] Shihao Gu, Bryan Kelly и Dacheng Xiu, «Empirical asset pricing via machine learning», в: *The Review of Financial Studies* 33.5 (2020), стр. 2223–2273.

[27] Satoshi Nakamoto, «Bitcoin: A peer-to-peer electronic cash system», в: *Decentralized Business Review* (2008).