МАГИСТЕРСКАЯ ДИССЕРТАЦИЯ — РУССКИЙ ПЕРЕВОД

Университет в Крагуевце

ПРОГНОЗИРОВАНИЕ МЕЖРЫНОЧНОЙ ЗАВИСИМОСТИ БИТКОИНА
С ПОМОЩЬЮ МЕТОДОВ МАШИННОГО ОБУЧЕНИЯ

Студент: Богдан Бабаев
Научный руководитель: Владимир М. Милованович, ванредный профессор

Члены комиссии:

1. Александр Пеулич, профессор
2. Ясна Радулович, профессор
3. Милан Чабаркапа, доцент
4. Иван Крстич, ванредный профессор
5. Владимир М. Милованович, ванредный профессор (ментор)

Крагуевац, 2026

АННОТАЦИЯ (на английском)

В данной диссертации исследуется возможность прогнозирования изменяющейся во времени зависимости между Биткоином и традиционными финансовыми активами с использованием методов машинного обучения. В качестве целевой переменной используется скользящая корреляция Пирсона (с преобразованием Фишера-z) между дневными логарифмическими доходностями Биткоина и шести обычных активов: S&P 500, NASDAQ, золото, серебро, Ethereum, индекс доллара США.

Эмпирическая оценка проводится в режиме пошагового обучения (walk-forward) на данных с ноября 2017 по май 2026 года (3053 наблюдения). Рассматривается десять моделей: персистентный базис (Naive_Last), AR1, HAR, Ridge, ElasticNet, случайный лес (RF), градиентный бустинг (GBM), XGBoost, ансамбль (Ensemble) и эконометрический ориентир DCC-GARCH(1,1). Эксперименты проводятся для шести пар активов и четырёх длин скользящего окна (14, 30, 60, 90 дней) — итого 24 настройки.

Главный результат: зависимость предсказуема с высоким качеством (средний R^2 выше 0,93 для лучшего кластера моделей). Доминирующий источник предсказательной силы — серийная персистентность скользящей корреляции, а не наличие сложных нелинейных закономерностей в данных. Ridge, AR1 и HAR образуют почти неразличимый верхний кластер (RMSE ≈ 0,066), тогда как методы на основе деревьев уступают заметно. Все методы машинного обучения значимо превосходят DCC-GARCH по статистике Дибольда-Мариано.

Практический уровень сигнала переформулирует задачу как бинарную классификацию стрессовых событий. Логистическая регрессия даёт сбалансированную точность 0,511 и F1=0,214 для класса «стресс» на паре Биткоин–S&P 500. Результаты умеренные — в среднем чуть выше случайного уровня, без формальной проверки значимости — и лучше всего интерпретируются как вспомогательный индикатор управления рисками, а не как самостоятельный торговый сигнал.

Ключевые слова: Биткоин, зависимость активов, машинное обучение, скользящая корреляция, DCC-GARCH, пошаговое прогнозирование, управление рисками

СОДЕРЖАНИЕ

1. Введение

1.1 Мотивация 1.2 Постановка исследовательской задачи 1.3 Вклад работы 1.4 Структура диссертации

2. Теоретические основы

2.1 Зависимость между криптоактивами и традиционными активами 2.2 Динамическая условная корреляция (DCC-GARCH) 2.3 Линейные авторегрессионные модели (AR1 и HAR) 2.4 Регуляризованные линейные модели 2.5 Методы на основе деревьев 2.6 Пошаговая оценка 2.7 Тест Дибольда-Мариано 2.8 Инвесторский сигнальный уровень 2.9 Позиционирование в литературе

3. Методология

3.1 Вселенная активов 3.2 Диапазон данных и синхронизация 3.3 Целевая переменная 3.4 Преобразование Фишера-z 3.5 Инженерия признаков 3.6 Спецификации моделей 3.7 Пошаговая схема оценки 3.8 Метрики качества прогноза 3.9 Инвесторский сигнальный уровень 3.10 Доверительные интервалы 3.11 Анализ чувствительности 3.12 Методологические ожидания

4. Эмпирические результаты

4.1 Обзор результатов 4.2 Средняя эффективность прогнозирования зависимости 4.3 Репрезентативный пример прогноза 4.4 Эффективность по классу активов 4.5 Результат доминирования персистентности 4.6 Сравнение с DCC-GARCH 4.7 Диагностика профиля ошибок 4.8 Инвесторский сигнальный уровень: средние результаты 4.9 Лучшие конфигурации сигнала 4.10 Практическая интерпретация эффективности сигнального уровня 4.11 Чувствительность к длине скользящего окна 4.12 Резюме эмпирических результатов

5. Обсуждение

5.1 Что на самом деле говорят результаты 5.2 Почему доминируют простые модели, и что это означает 5.3 ML против DCC-GARCH: более честное сравнение 5.4 Инвесторский сигнал: что работает, а что нет 5.5 Методологические выборы, которые имели значение 5.6 Чего не говорят результаты 5.7 Итеративная разработка модели: что менялось по версиям 5.8 Ограничения, честно изложенные

6. Заключение

Приложения A. Описание данных и дополнительный контекст B. Дополнительные результаты прогнозирования C. Дополнительные результаты сигнального уровня D. Воспроизводимость и структура кода E. Дополнительные статистические тесты

Список литературы

СПИСОК СОКРАЩЕНИЙ

AR1 — авторегрессионная модель первого порядка AUC — площадь под ROC-кривой BTC — Биткоин (BTC-USD) DCC — динамическая условная корреляция DM — тест Дибольда-Мариано ETH — Ethereum (ETH-USD) GBM — гистограммный градиентный бустинг (HistGradientBoosting) GLD — ETF на золото HAR — гетерогенная авторегрессионная модель HLN — поправка Харви-Лейборна-Ньюболда MAE — средняя абсолютная ошибка ML — машинное обучение OLS — метод наименьших квадратов OOS — на данных вне обучающей выборки RF — случайный лес (Random Forest) RMSE — среднеквадратичная ошибка прогноза R^2 — коэффициент детерминации SLV — ETF на серебро UUP — ETF-прокси индекса доллара США XGB — XGBoost (eXtreme Gradient Boosting) ^GSPC — индекс S&P 500 ^IXIC — индекс NASDAQ Composite

ГЛАВА 1. ВВЕДЕНИЕ

1.1 Мотивация

Биткоин вошёл в финансовую систему как предположительно независимый актив — не привязанный к бизнес-циклу, не коррелирующий с фондовыми рынками, потенциально пригодный в качестве хеджа и защитного актива [1, 2]. Эта характеристика была верна в ранний период его существования. К 2020 году ситуация изменилась. В период краха COVID в марте 2020 года Биткоин упал вместе с акциями. В 2022 году он снизился вместе с NASDAQ. Динамика перестала быть стабильной.

Это делает вопрос о характере зависимости практически значимым. Портфельный менеджер, рассматривающий криптоактивы, должен понимать не только среднюю корреляцию (которая мало что говорит), но и то, как эта корреляция меняется, и предсказуема ли она. Ответ на последний вопрос — предсказуема ли зависимость — является центральной темой данной диссертации.

1.2 Постановка исследовательской задачи

Диссертация ставит конкретный вопрос: можно ли прогнозировать изменяющуюся во времени зависимость между Биткоином и обычными активами, и помогают ли для этого методы машинного обучения?

Задача разбивается на два уровня:

1. РЕГРЕССИОННЫЙ УРОВЕНЬ: для каждой пары активов и каждой длины скользящего

окна прогнозируется следующее значение скользящей корреляции Пирсона (после преобразования Фишера-z) на основе доступных признаков.

2. СИГНАЛЬНЫЙ УРОВЕНЬ: прогноз зависимости переводится в вероятность того, что

обычный актив завтра испытает стресс (падение ниже заданного порога). Это бинарная задача классификации, ориентированная на практику инвестора.

1.3 Вклад работы

Диссертация вносит три конкретных вклада:

- Систематическая сравнительная оценка десяти спецификаций моделей в строгом

пошаговом режиме с расширяющимся окном, без какой-либо утечки данных в будущее. Это включает первое применение HAR-модели (разработанной для реализованной волатильности) к задаче прогнозирования скользящей корреляции.

- Надлежащая реализация DCC-GARCH в пошаговом режиме в качестве эконометрического

ориентира. Предшествующая практика применения DCC на полной выборке с последующим извлечением прогнозов в выборке предоставляет модели несправедливое преимущество.

- Двухуровневая структура: прогноз зависимости как регрессионная задача плюс

сигнал управления рисками как задача классификации, с отдельной оценкой каждого уровня.

1.4 Структура диссертации

Глава 2 излагает теоретическую базу. Глава 3 описывает методологию в деталях. Глава 4 представляет эмпирические результаты. Глава 5 обсуждает выводы в более широком контексте. Глава 6 завершает работу. Приложения A–E содержат дополнительные материалы: описание данных, диагностические графики, дополнительные результаты и информацию о воспроизводимости.

ГЛАВА 2. ТЕОРЕТИЧЕСКИЕ ОСНОВЫ

2.1 Зависимость между криптоактивами и традиционными активами

Академическая литература по зависимости Биткоина и традиционных активов делится на два лагеря: работы, утверждающие, что Биткоин предлагает диверсификационные преимущества [2, 3], и работы, фиксирующие нарастающую интеграцию с традиционными рынками [4, 5]. Этот разрыв частично отражает методологические различия, но главным образом — нестабильность зависимости во времени.

Скользящая корреляция документирует эпизоды конвергенции (2020, 2022) и дивергенции (2019, 2023). Волатильность корреляции означает, что статическое число — корреляция на полной выборке — не описывает значимо связь между активами. Это и является мотивацией для изучения предсказуемости изменяющейся корреляции.

Литература по динамической зависимости исторически использовала параметрические модели — DCC-GARCH [9, 10], копулы [8] — для описания этой эволюции. Данная диссертация дополняет эту традицию, задав вопрос о предсказуемости и применив методы машинного обучения для этой задачи.

2.2 Динамическая условная корреляция (DCC-GARCH)

Модель DCC-GARCH [10], предложенная Энглом (2002), оценивает условную корреляцию в два этапа: сначала подбираются одномерные GARCH-процессы для каждого актива, затем оценивается корреляционный процесс второго этапа. Условная матрица ковариаций записывается как:

$$H_t = D_t \cdot R_t \cdot D_t,$$

где D_t — диагональная матрица условных стандартных отклонений, R_t — матрица условных корреляций. Процесс корреляции определяется через вспомогательную матрицу Q_t:

$$Q_t = (1 - \alpha - \beta)\cdot \bar{Q} + \alpha\cdot\varepsilon_{t-1}\cdot\varepsilon_{t-1}' + \beta\cdot Q_{t-1}, \quad R_t = \mathrm{diag}(Q_t)^{-1/2} \cdot Q_t \cdot \mathrm{diag}(Q_t)^{-1/2},$$

где $\bar{Q}$ — безусловная матрица корреляций, α и β — параметры модели.

В данной работе DCC-GARCH используется как эконометрический ориентир. Принципиально важно, что он реализован в пошаговом режиме (walk-forward) с расширяющимся окном — точно так же, как и все модели машинного обучения. Это единственный корректный способ сравнения: полновыборочный DCC предоставляет модели информацию о будущем, что недопустимо.

2.3 Линейные авторегрессионные модели (AR1 и HAR)

Базовая авторегрессионная модель первого порядка (AR1) задаётся как:

$$\hat{\rho}_{t+1} = \alpha + \beta\cdot\rho_t + \varepsilon_t,$$

где ρ_t — текущее значение зависимости (корреляции в пространстве Фишера-z). Несмотря на простоту, AR1 — сильный ориентир для сильно

персистентных рядов.

Гетерогенная авторегрессионная модель (HAR) [11] использует три временных масштаба одновременно:

$$\hat{\rho}_{t+1} = \alpha + \beta_d \cdot \rho_t + \beta_w \cdot \bar{\rho}_t^{(5)} + \beta_m \cdot \bar{\rho}_t^{(22)} + \varepsilon_t,$$

где $\bar{\rho}_t^{(k)}$ — равновзвешенное среднее предыдущих k наблюдений. Изначально разработанная для реализованной волатильности, HAR хорошо подходит для скользящих корреляций, поскольку перекрывающиеся окна создают естественную гетерогенную память на дневном, недельном и месячном горизонтах.

2.4 Регуляризованные линейные модели

Ridge-регрессия минимизирует:

$$L(\beta) = ||y - X\beta||^2 + \alpha \cdot ||\beta||^2,$$

что сжимает коэффициенты к нулю, снижая дисперсию оценки за счёт небольшого смещения. Параметр α контролирует степень регуляризации.

ElasticNet объединяет штрафы L1 и L2:

$$L(\beta) = ||y - X\beta||^2 + \alpha \cdot [\lambda \cdot ||\beta||_1 + (1-\lambda) \cdot ||\beta||^2],$$

обеспечивая и отбор признаков (как Lasso), и стабильность при мультиколлинеарных признаках (как Ridge).

В данной работе оба метода применяются с предварительным масштабированием признаков (StandardScaler). Это существенно для Ridge: регуляризация иначе несправедливо штрафует признаки с большим разбросом.

2.5 Методы на основе деревьев

Случайный лес (Random Forest) [14] обучает B деревьев на случайных бутстрэп-подвыборках данных с дополнительной рандомизацией выбора признаков в каждом узле. Прогноз — среднее по всем деревьям.

Гистограммный градиентный бустинг (GBM) [15] строит деревья последовательно: каждое следующее дерево обучается на остатках предыдущего. Гистограммная дискретизация признаков ускоряет вычисления в 10 раз по сравнению с базовым GBM.

XGBoost [16] — масштабируемая реализация градиентного бустинга с регуляризацией L1/L2 и GPU-ускорением. В данной работе используется на GPU с резервным переходом на CPU при его недоступности.

Адаптивный ансамбль взвешивает каждую составляющую модель обратно пропорционально её RMSE на последних 60 прогнозах вне обучающей выборки, позволяя весам обновляться по мере смены рыночных режимов.

2.6 Пошаговая схема оценки

Чтобы исключить утечку информации из будущего, все модели оцениваются в строгом пошаговом режиме (walk-forward) с расширяющимся окном:

Обучение: данные с начала до t−1 Прогноз: одно наблюдение на t Сдвиг: окно расширяется на один шаг Переобучение: каждые 20 шагов (refit_every = 20)

Начальный размер обучающей выборки — 800 наблюдений. При пересечении этого порога модели переобучаются. Прогнозы для более ранних точек отбрасываются. Итого оценивается 24 комбинации (6 пар × 4 окна), каждая — для всех 10 моделей.

2.7 Тест Дибольда-Мариано (DM)

Тест DM [17] проверяет, статистически значимо ли отличается точность прогнозов двух моделей. Статистика теста:

S = d̄ / sqrt(V̂(d̄)),

где d_t = e_{1t}² - e_{2t}² — разность потерь (квадратов ошибок), d̄ — её среднее, V̂(d̄) — дисперсия HAC (Ньюи-Уэст). Статистика S при нулевой гипотезе равной точности асимптотически стандартно нормальна.

В данной работе тест применяется для всех ML-моделей по отношению к двум ориентирам: DCC-GARCH и Naive_Last. Отрицательное значение DM означает, что первая модель (ML) лучше второй (ориентира).

2.8 Инвесторский сигнальный уровень

Задача управления рисками требует не числового прогноза, а двоичного сигнала: является ли завтрашний день стрессовым? «Стрессовый» день определяется как дни, когда доходность обычного актива падает ниже своего 25-го перцентиля. Три классификатора используют признаки зависимости для предсказания этих событий:

- Логистическая регрессия (Logit): линейная граница решений, хорошо откалибрована
- Классификационный GBM (GBM_Cls): ансамблевый метод с регуляризацией
- Классификационный RF (RF_Cls): случайный лес

Задача сложнее, чем регрессия: классы несбалансированы, стрессовые события зашумлены, а стоимость ошибок асимметрична.

2.9 Позиционирование в литературе

Данная диссертация отличается от существующих работ тремя аспектами: строгой пошаговой схемой без утечек, включением HAR как теоретически обоснованного ориентира и двухуровневой структурой, которая связывает прогнозирование зависимости с практическим управлением рисками. Большинство предшествующих исследований либо ограничивается полновыборочными или скользящими оценками (с утечками в пошаговом сравнении), либо сосредотачивается на прогнозировании доходностей, а не зависимости.

ГЛАВА 3. МЕТОДОЛОГИЯ

3.1 Вселенная активов

Диссертация охватывает семь активов:

Тикер	Описание
BTC-USD	Биткоин (базовый актив)
ETH-USD	Ethereum (крипто-нативное сравнение)
^GSPC	Индекс S&P 500
^IXIC	Индекс NASDAQ Composite
GLD	ETF на золото SPDR
SLV	ETF на серебро iShares
UUP	Прокси индекса доллара США

Выбор охватывает акции (^GSPC, ^IXIC), драгоценные металлы (GLD, SLV), валютный рынок (UUP) и криптоактивы (BTC-USD, ETH-USD). Это позволяет протестировать различные каналы передачи зависимости.

3.2 Диапазон данных и синхронизация

Данные загружены через yfinance [18]. Эффективная дата начала — 9 ноября 2017 года (первая дата с данными по Ethereum), конечная — 16 мая 2026 года. Итого 3053 наблюдения. Синхронизация достигается методом прямого заполнения (forward-fill) для нерабочих дней бирж ETF. Пропущенные значения отсутствуют для всех тикеров.

3.3 Целевая переменная

Для пары активов (BTC-USD, актив j) и окна w целевой переменной является:

ρ_{t,w} = Pearson(r_BTC[t-w+1..t], r_j[t-w+1..t]),

где r — логарифмические дневные доходности. Это значение вычисляется для каждого дня t в выборке. Используются четыре значения w: 14, 30, 60, 90 дней.

3.4 Преобразование Фишера-z

Скользящая корреляция Пирсона ограничена интервалом (-1, 1) и подвержена сжатию дисперсии у границ. Преобразование Фишера-z:

z_t = arctanh(ρ_t) = 0.5 · ln[(1+ρ_t)/(1-ρ_t)]

отображает цель на всю числовую прямую, стабилизирует дисперсию и делает распределение более симметричным, приближая его к нормальному. Все модели обучаются и оцениваются в пространстве Фишера-z; обратное преобразование применяется только для визуализации.

[Рисунок 15: Распределение 30-дневной скользящей корреляции до и после преобразования Фишера-z для пары BTC-USD vs S&P 500. Преобразование улучшает нормальность и устраняет сжатие у границ.]

3.5 Инженерия признаков

Для каждой пары активов и каждого дня формируется вектор примерно из 35 признаков. Основные группы:

АВТОРЕГРЕССИОННЫЕ ЛАГИ ЗАВИСИМОСТИ: dep_lag1 — значение z_{t-1} (самый важный признак) dep_lag5 — значение z_{t-5} dep_lag20 — значение z_{t-20}

dep_lag60 — значение z_{t-60}

СКОЛЬЗЯЩИЕ СРЕДНИЕ ЗАВИСИМОСТИ (для HAR): avg5 — среднее за последние 5 дней avg22 — среднее за последние 22 дня

МОМЕНТУМ И Z-ОЦЕНКА: dep_mom_5 — изменение за 5 дней dep_mom_20 — изменение за 20 дней dep_zscore — стандартизированное отклонение от 60-дневного среднего

ВОЛАТИЛЬНОСТЬ: vol_base — 30-дневная скользящая волатильность BTC-USD vol_other — 30-дневная скользящая волатильность актива j vol_other_60 — 60-дневная скользящая волатильность актива j vol_ratio — отношение vol_base к vol_other

ДОХОДНОСТИ (лаги 1-5 для обоих активов): ret_base_{1..5}, ret_other_{1..5}

ДОПОЛНИТЕЛЬНЫЕ: mean_base, mean_other — скользящие средние доходности sq_ret_base, sq_ret_other — прокси реализованной волатильности

3.6 Спецификации моделей

Десять моделей прогнозирования:

1. Naive_Last — персистентный базис: ρ̂_{t+1} = z_t. Не обучается.
2. AR1 — линейная регрессия только на dep_lag1.
3. HAR — OLS на dep_lag1, avg5, avg22 (три временных масштаба).
4. Ridge — конвейер StandardScaler + Ridge(alpha=0.5) на всех ~35 признаках.
5. ElasticNet — StandardScaler + ElasticNet(alpha=0.005, l1_ratio=0.5, max_iter=5000).
6. RF — RandomForestRegressor(n_estimators=200, max_depth=10, min_samples_leaf=5).
7. GBM — HistGradientBoostingRegressor(max_iter=300, max_depth=4, learning_rate=0.02, min_samples_leaf=5, l2_regularization=0.1).
8. XGB_GPU — XGBRegressor(device="cuda", n_estimators=500, max_depth=6, learning_rate=0.02, subsample=0.8, colsample_bytree=0.8).
9. Ensemble — адаптивное взвешивание по обратному RMSE за последние 60 прогнозов.
10. DCC_GARCH — двухэтапный DCC-GARCH(1,1), реализованный в пошаговом режиме.

Листинг 3 (Python):

```
model_specs = {
    "Naive_Last": None,         # персистентный базис
    "AR1":        LinearRegression(),
    "HAR":        None,         # HAR — OLS на lag1, avg5, avg22
    "Ridge":      make_pipeline(StandardScaler(), Ridge(alpha=0.5)),
    "ElasticNet": make_pipeline(StandardScaler(),
                    ElasticNet(alpha=0.005, l1_ratio=0.5, max_iter=5000)),
    "RF":    RandomForestRegressor(n_estimators=200, max_depth=10,
                 min_samples_leaf=5, n_jobs=-1),
    "GBM":   HistGradientBoostingRegressor(max_iter=300, max_depth=4,
                 learning_rate=0.02, min_samples_leaf=5, l2_regularization=0.1),
    "XGB_GPU": xgb.XGBRegressor(device="cuda", n_estimators=500,
                 max_depth=6, learning_rate=0.02, subsample=0.8,
```

```
                colsample_bytree=0.8),
}
# "Ensemble": адаптивное взвешивание за 60 последних OOS-прогнозов
```

3.7 Пошаговая схема оценки

Для каждой из 24 конфигураций (6 пар × 4 окна):

- Минимальный размер обучающей выборки: 800 наблюдений
- Переобучение каждые 20 шагов (refit_every = 20)
- Прогноз горизонта h = 1 (следующий день)
- Расширяющееся окно: каждый новый прогноз использует все доступные исторические данные

Это гарантирует, что ни один прогноз не использует информацию из будущего.

3.8 Метрики качества прогноза

- RMSE (среднеквадратичная ошибка): основная метрика, измеряемая в единицах

пространства Фишера-z.

- R^2 (коэффициент детерминации): доля объяснённой дисперсии.
- MAE (средняя абсолютная ошибка): менее чувствительна к выбросам.
- Тест DM: формальная проверка значимости разницы в точности.

3.9 Инвесторский сигнальный уровень

Для каждой точки прогноза:

1. Получить $\hat{\rho}_{t+1}$ от лучшего регрессора.
2. Добавить к вектору признаков: $\hat{\rho}_{t+1}$, z_t, dep_mom_5, dep_mom_20,

vol_base, vol_other, dep_zscore.

3. Обучить классификатор (Logit, GBM_Cls, RF_Cls) на бинарной метке:

y = 1, если r_other_{t+1} < 25-й перцентиль доходностей.

4. Классификаторы оцениваются в том же пошаговом режиме.

Метрики: сбалансированная точность (Balanced Accuracy, BA), F1-мера для класса «стресс» (F1_down), AUC (площадь под ROC-кривой), доля активных дней (exit rate).

3.10 Доверительные интервалы Bootstrap

500-кратный бутстрэп применяется к RMSE и R^2 для каждой пары и окна. Интервалы строятся методом перцентилей. Ширина интервалов типично < 0,01, что подтверждает высокую стабильность результатов.

3.11 Анализ чувствительности

Дополнительно проверяется чувствительность к параметру refit_every: тестируется {5, 10, 20, 42, 63} дня. Результаты практически не изменяются, что подтверждает, что refit_every=20 — не специально подобранный параметр.

3.12 Методологические ожидания

Исходя из теории и структуры задачи можно ожидать:

a) Высокий OOS R^2 для всех разумных моделей: скользящие корреляции с перекрытием

очень персистентны по построению.

b) AR1, HAR и Ridge должны быть близки: все три используют одну и ту же доминирующую

информацию — последнее значение корреляции. Конвергенция — это находка, а не случайность.

c) Методы на основе деревьев должны уступать: у них нет встроенного авторегрессионного

индуктивного смещения, и их преимущество в захвате нелинейных зависимостей здесь не реализуется, поскольку структура задачи почти линейная.

d) DCC-GARCH должен уступать ML: DCC оценивает мгновенную условную ковариацию,

а не сглаженную скользящую корреляцию. Систематическое смещение неизбежно.

ГЛАВА 4. ЭМПИРИЧЕСКИЕ РЕЗУЛЬТАТЫ

4.1 Обзор результатов

Эмпирические результаты охватывают 24 комбинации (6 пар × 4 окна), каждую из которых оценивают 10 моделей прогнозирования. Это 240 оценок RMSE и R^2. Дополни- тельно проводится 336 тестов DM (168 сравнений ML vs DCC-GARCH + 168 vs Naive_Last) и 480 оценок сигнального уровня (3 классификатора × 6 пар × 4 окна × 2 пола).

4.2 Средняя эффективность прогнозирования зависимости

Таблица 3 суммирует среднюю производительность по всем 24 экспериментам.

ТАБЛИЦА 3: Средняя эффективность модели по всем 24 конфигурациям (6 пар × 4 окна). Метрики — среднеквадратичная ошибка (RMSE) и коэффициент детерминации (R^2) в пространстве преобразования Фишера-z. Модели отсортированы по RMSE.

Модель	RMSE	R^2	MAE	Ранг DM vs DCC	Ранг DM vs Naive
Ridge	0.0656	0.9432	0.0419	Лучше***	Хуже***
AR1	0.0659	0.9424	0.0403	Лучше***	Хуже***
HAR	0.0659	0.9424	0.0405	Лучше***	Хуже***
Naive_Last	0.0666	0.9412	0.0395	Лучше***	–
ElasticNet	0.0669	0.9411	0.0434	Лучше***	Хуже***
Ensemble	0.0694	0.9365	0.0462	Лучше***	Хуже***
GBM	0.0886	0.8983	0.0625	Лучше***	Хуже***
RF	0.0905	0.8936	0.0636	Лучше***	Хуже***
XGB_GPU	0.1241	0.7923	0.0864	Лучше***	Хуже***
DCC_GARCH	0.2136	0.3715	0.1683	–	Хуже***

Примечание: *** — p < 0.001 по тесту Дибольда-Мариано с оценкой дисперсии HAC.

Ключевые наблюдения:

1. ВЕРХНИЙ КЛАСТЕР: Ridge (0.0656), AR1 (0.0659), HAR (0.0659) практически

неразличимы по качеству. Разница между ними в 0.0003 RMSE не является решающей победой машинного обучения — это конвергенция.

2. ПЕРСИСТЕНТНЫЙ БАЗИС: Naive_Last (0.0666) находится прямо за топ-кластером,

подтверждая, что серийная память является главным механизмом прогнозирования.

3. ВТОРОЙ КЛАСТЕР: ElasticNet и Ensemble имеют R^2 выше 0.93. Методы на основе

деревьев — GBM, RF, XGBoost — существенно уступают (RMSE 0.09–0.12, R^2 < 0.90).

4. DCC-GARCH последний с большим отрывом (R^2 = 0.3715) — почти в три раза хуже

по RMSE, чем Ridge.

4.3 Репрезентативный пример прогноза

[Рисунок 5: Наблюдаемая и предсказанная зависимость (в пространстве Фишера-z) для пары BTC-USD vs S&P 500 при 30-дневном скользящем окне. Верхняя панель —

сравнение прогнозов (Naive_Last, HAR, AR1, DCC-GARCH). Нижняя панель — значения Pearson ρ. Прогнозные ряды создаются в строгом пошаговом режиме без использования информации из будущего. 2018–2026.]

На рисунке 5 видны три характерные черты задачи прогнозирования:

- Цель эволюционирует плавно (из-за перекрывающихся окон)
- Сильнейшие модели отслеживают широкое направленное движение с минимальным

систематическим смещением

- Локальные смены режима — главная трудность: при резких разрывах все модели

реагируют с запозданием

4.4 Эффективность по классу активов

Пара BTC-USD vs ETH-USD даёт наивысшую предсказуемость: оба актива имеют общие фундаментальные драйверы ликвидности и настроения, создавая гладкий и сильно автокоррелированный целевой ряд. Более длинные окна дополнительно усиливают производительность.

Пары с драгоценными металлами (BTC–золото, BTC–серебро) занимают промежуточный уровень предсказуемости. Корреляция меняет знак между режимами, но персистентные базисы продолжают доминировать.

Пары с индексами акций (BTC–S&P 500, BTC–NASDAQ) наиболее практически значимы. В стабильные рыночные периоды зависимость плавная и сильно автокоррелированная. Однако эти пары также демонстрируют выраженную чувствительность к режимам: во время риск-он эпизодов совместное движение усиливается; при рыночных дислокациях — резко меняется. Это главный краткосрочный вызов для прогнозирования.

Пара BTC–индекс доллара (UUP) показывает наименьшую предсказуемость: макро-защитная структура UUP менее связана с крипто-динамикой.

4.5 Результат доминирования персистентности

Доминирование персистентных базисов — это диагностическая информация о структуре задачи, а не ограничение подхода машинного обучения.

Скользящая корреляция Пирсона по w торговым дням имеет w-1 общих наблюдений с предыдущим окном, создавая сильный скользяще-средний эффект. После преобразования Фишера-z первый лаг захватывает подавляющее большинство предсказуемой дисперсии. Любая модель, условно опирающаяся прежде всего на самое последнее значение зависимости, структурно достигает высокого OOS R^2.

Это подтверждается диагностикой важности признаков Random Forest: лаговый признак dep_lag1 доминирует в рейтинге важности во всех экспериментах.

Проблема принципиально предсказуема, потому что цель помнит прошлое — а не потому, что предикторный набор содержит сильные межрыночные сигналы, независимые от недавней динамики зависимости.

4.6 Сравнение с DCC-GARCH

[Рисунок 6: Тепловая карта результатов теста Дибольда-Мариано, сравнивающего Ridge (лучший по среднему RMSE среди всех моделей) против DCC-GARCH по всем парам активов и длинам окон. Более тёмные ячейки означают более сильное и статистически значимое превосходство Ridge. Все 24 ячейки тёмно-зелёные.]

Несмотря на доминирование персистентных базисов в безусловном ранжировании, машинное обучение обеспечивает практически и статистически значимое улучшение по сравнению с DCC-GARCH. Тест DM подтверждает: Ridge значимо превосходит DCC во всех 24 экспериментах. Статистики DM варьируются от 24 до 35 ($p < 0.001$).

Важно понимать принципиальную причину: DCC-GARCH предназначен для оценки полной условной структуры ковариации; его проекция на скользящую корреляцию Пирсона вводит систематическое запаздывание. ML-модели напрямую минимизируют ошибку прогноза для целевой переменной — это структурное преимущество выравнивания задачи.

Диссертация чётко разграничивает два утверждения:

- ПРЕВОСХОДСТВО НАД ОРИЕНТИРОМ: ML превосходит DCC-GARCH. Это достигнуто.

- БЕЗУСЛОВНОЕ ПРЕВОСХОДСТВО: ML превосходит AR1. Это НЕ достигнуто систематически.

4.7 Диагностика профиля ошибок

[Рисунок 7: Скользящая среднеквадратичная ошибка (60 дней) за период 2021–2026 для эксперимента BTC-USD vs S&P 500. Синяя линия — HAR, голубая — DCC-GARCH, серая пунктирная — Naive_Last. Периоды повышенной ошибки соответствуют резким сменам режима зависимости.]

Скользящий профиль ошибок показывает, что качество прогноза неоднородно во времени. В периоды постепенной эволюции зависимости все модели дают низкие ошибки. Во время резких смен режима ошибки растут у всех, но магнитуда и длительность ухудшения различаются. ML-модели несколько быстрее восстанавливаются.

Главный источник ошибки — эпизодическая недостаточная реакция на резкие поворотные точки, а не систематическое смещение.

4.8 Инвесторский сигнальный уровень: средние результаты

ТАБЛИЦА 4: Средняя эффективность инвесторского сигнала по семейству классификаторов, усреднённая по всем парам активов и длинам окон.

Модель	Balanced Accuracy	F1_down	AUC
Logit	0.511	0.214	0.513
GBM_Cls	0.508	0.158	0.517
RF_Cls	0.502	0.042	0.519

Примечание: Результаты усреднены по всем парам и длинам окон. Balanced Accuracy корректирует дисбаланс классов. F1_down измеряет качество обнаружения стресса.

Задача классификации существенно сложнее регрессии. Логистическая регрессия неизменно достигает наилучшей F1-меры (0.214), что отражает её способность сохранять чувствительность к реальным стрессовым эпизодам. GBM даёт сопоставимую BA (0.508), но ниже F1 (0.158). Random Forest деградирует до почти нулевой F1 (0.042), демонстрируя вырожденное поведение с низкой долей активных дней.

Причина вырождения RF — дисбаланс классов и отсутствие калибровки вероятностей. Плэтт-скалинг или изотоническая регрессия могли бы это исправить — направление для будущей работы.

4.9 Лучшие конфигурации сигнала

Наилучший индивидуальный результат сигнала записан для пары BTC-USD vs S&P 500. При 30-дневном окне логистическая классификация достигает Balanced Accuracy=0.5308 и F1=0.2430 для нисходящего класса — скромное, но реальное отклонение от неинформативного базиса 0.50. Это наилучшая из двадцати четырёх конфигураций «пара–окно», поэтому результат следует считать ориентировочным, а не формально значимым: для сигнального уровня не приводится тест значимости, а отбор конфигурации не скорректирован на множественные сравнения. Защищаемое утверждение — усреднённое: сигнал в среднем чуть выше случайного для пар с широкими индексами акций, а не доказанное преимущество в этой единственной точке.

[Рисунок 8: Инвесторский сигнал стресса для пары BTC-USD vs S&P 500 при 30-дневном окне (2022-07 — 2026-07). Верхняя панель: предсказанная вероятность стресса от логистического классификатора с порогом решения (0.55). Нижняя панель: помеченные (красный) и пропущенные (синий) стрессовые события.]

Сигнал функционирует как вероятностный предупредительный индикатор, выявляющий периоды повышенного риска, поддерживая решение о снижении риска, а не направленную торговлю.

4.10 Практическая интерпретация эффективности сигнального уровня

Полезность сигнала следует оценивать относительно явно сформулированного стандарта принятия решений. Инвестор, оснащённый сигналом, действует избирательно. Сигнал информирует о условном решении по управлению рисками: снизить ли рыночную экспозицию, ужесточить ли стоп-лоссы, увеличить ли интенсивность хеджирования.

Ключевой параметр — доля активных дней (exit rate). Сигнал, который никогда не активируется, имеет нулевую практическую ценность; чрезмерно активный сигнал генерирует излишние транзакционные издержки. Логистическая модель достигает защитимого баланса.

Для NASDAQ сигнал заметно слабее: sectoral concentration NASDAQ вводит идиосинкратический шум, который криптодинамика не захватывает.

4.11 Чувствительность к длине скользящего окна

Длина скользящего окна — параметр первого порядка. Более короткие окна дают более отзывчивые, но более шумные оценки зависимости. Более длинные

окна сглаживают цель и усиливают персистентность.

Подтверждено: w=30 дней — оптимальный баланс. При этой спецификации цели достаточно гладкие для высоких OOS R^2, сохраняя при этом достаточно отзывчивости для стрессовой сигнализации.

4.12 Резюме эмпирических результатов

Четыре главных утверждения:

1. Изменяющаяся во времени межрыночная зависимость между Биткоином и

традиционными активами ПРЕДСКАЗУЕМА в пошаговом режиме с высокими средними значениями R^2 по всем классам моделей.

2. Доминирующий источник предсказательной силы — серийная персистентность

скользящей корреляции. Ridge, AR1 и HAR образуют почти неразличимый верхний кластер, используя эту персистентность через разные механизмы, тогда как методы на основе деревьев существенно уступают.

3. ML-модели часто и статистически значимо превосходят защищённый от утечек

ориентир DCC-GARCH на сглаженной целевой переменной; как подчёркивается в разделах 4.6 и 5.3, это сравнение структурно смещено в пользу ML, поскольку цель — сглаженная скользящая корреляция, а DCC-GARCH оценивает мгновенную условную корреляцию. Ridge достигает наилучшего среднего RMSE (0.0656) по всем 24 экспериментам.

4. Инвесторский сигнальный уровень даёт умеренные результаты классификации —

в среднем чуть выше случайного, без формальной проверки значимости — наиболее выраженные для широких рынков акций; лучше интерпретировать его как дополнительный вход для управления рисками, а не как самостоятельный направленный предиктор.

ГЛАВА 5. ОБСУЖДЕНИЕ

5.1 Что на самом деле говорят результаты

Скользящая межрыночная зависимость между Биткоином и обычными активами действительно предсказуема вне выборки. Это не артефакт переобучения — это реальный сигнал, выживающий при строгих ограничениях временного порядка по всем шести парам и четырём длинам окна.

И эта предсказуемость почти полностью объясняется персистентностью: скользящая корреляция не переключается хаотично. Она помнит вчерашний день.

Эти два наблюдения связаны. Ни одно из них не подрывает другое.

5.2 Почему доминируют простые модели, и что это означает

Почти неразличимая производительность Ridge, AR1 и HAR на вершине рейтинга — это не провал машинного обучения. Это говорит кое-что конкретное о процессе генерации данных.

Скользящая корреляция Пирсона по w дням имеет w-1 общих наблюдений с предыдущим окном, что механически создаёт сильную автокорреляцию. После преобразования Фишера-z первый лаг захватывает подавляющее большинство предсказуемой дисперсии. При таких условиях любая разумная модель сильно опирается на последнее значение — и будет очень трудно побита.

То, что Ridge опережает AR1 на 0.0003 RMSE (0.0656 vs 0.0659) — это не решающая победа ML. Это лишь говорит, что регуляризованная линейная регрессия, при правильном масштабировании, воспроизводит тот же авторегрессионный сигнал через немного более богатый набор признаков.

HAR связывает AR1 точно, используя три временных масштаба (дневной, недельный, месячный), которые естественно согласуются со структурой памяти перекрывающихся окон. Конвергенция трёх структурно разных методов к одному уровню точности — само по себе находка: она подтверждает, что задача прогнозирования имеет почти линейную авторегрессионную структуру.

Это задокументированная закономерность в финансовом прогнозировании [20]. Соотношения сигнал/шум низки. Инкрементальная информация во вспомогательных признаках часто подавляется авторегрессионным компонентом.

Тем не менее, методы на основе деревьев, показывающие существенно худшие результаты, не бесполезны. Это означает: машинное обучение полезно по другой причине — исключение более гибких альтернатив. Тот факт, что хорошо настроенные XGBoost и RF не могут сравниться с Ridge или AR1 — сам по себе информативен. Это говорит: процесс зависимости не содержит эксплуатируемой нелинейной структуры на горизонте одного шага, по крайней мере не в данном наборе признаков.

5.3 ML против DCC-GARCH: более честное сравнение

Ridge и ElasticNet неизменно опережают DCC-GARCH. Разрыв значителен — средний RMSE 0.066 против 0.214 для Ridge, разрыв больше трёх. Статистики DM положительны с p-значениями на нижнем пределе двойной точности.

Правильная интерпретация не в том, что DCC-GARCH — плохая модель. Это теоретически последовательная модель условной ковариации, разработанная для другой задачи. Её выходные данные — мгновенная условная корреляция, а не сглаженное скользящее среднее. Проекция одного на другое вводит систематическое запаздывание, которое модель никогда не предназначалась устранить.

ML-модели, напрямую обученные на преобразованной Фишером-z целевой переменной, не имеют этого рассогласования. Они оптимизированы для правильного объекта с самого начала.

Это честное объяснение разрыва производительности. Его следует чётко указывать в диссертации, а не праздновать как будто ML как-то победил эконометрику на её же поле.

5.4 Инвесторский сигнал: что работает, а что нет

Сигнальный уровень даёт умеренные результаты по всем измерениям: AUC в диапазоне от 0.46 до 0.55, сбалансированная точность от ниже 0.50 до около 0.545 в зависимости от пары и окна, доля активных дней 15–35%.

Ни одно из этих чисел не впечатляет по отдельности. Вместе они описывают сигнал, который стабильно выбирает правильное направление чаще случайного, срабатывает с разумной частотой и более информативен для стресса на рынке акций, чем для стресса, связанного с драгоценными металлами или индексом доллара.

Результат по рынку акций экономически интерпретируем: Биткоин и S&P 500 имеют общую экспозицию к глобальному аппетиту к риску, условиям фондирования и сентиментальным циклам. Когда зависимость между ними растёт или меняется, это часто отражает более широкие переходы рыночных режимов.

Для золота и серебра сигнал слабее, потому что эти рынки реагируют на более широкий набор сил — реальные ставки, инфляционные ожидания, геополитические премии, спрос на защитные активы — которые плохо представлены биткоин-динамикой.

На практике сигнал следует трактовать как вспомогательный индикатор риска, а не как систему оповещения. Лучше всего использовать его наряду с фундаментальной оценкой, макроанализом и правилами управления позицией.

5.5 Методологические выборы, которые имели значение

Несколько решений по проектированию оказались существенными:

- ПОШАГОВАЯ ОЦЕНКА ДЛЯ DCC-GARCH ТОЖЕ. Запуск DCC на полной выборке перед

созданием прогнозов вне выборки предоставил бы ему нечестное преимущество. Применение одного и того же протокола расширяющегося окна для всех

моделей уравняло сравнение.

• ПРЕОБРАЗОВАНИЕ ФИШЕРА-Z ЦЕЛЕВОЙ ПЕРЕМЕННОЙ. Без него ограниченная природа

корреляции Пирсона вблизи ±1 искажает ошибки у экстремумов. Фишера-z приближает цель к нормальному распределению и делает RMSE более разумной функцией потерь.

• НЕСКОЛЬКО ОКОН. Использование только 30-дневного окна недооценило бы, насколько

сильно предсказуемость зависит от структуры автокорреляции. Прогресс от w=14 до w=90 показывает эффект автокорреляции систематически.

• НЕСКОЛЬКО МЕТРИК. Опора только на RMSE упустила бы то, что DCC-GARCH хуже

не только в среднем, но и для каждой пары, при каждом окне, со статистической значимостью. Тест DM добавляет этот уровень уверенности.

5.6 Чего не говорят результаты

Несколько важных оговорок:

- БИТКОИН НЕ ПРЕДСКАЗЫВАЕТ ДОХОДНОСТИ АКЦИЙ. Он (частично) предсказывает

эволюирующую ЗАВИСИМОСТЬ между Биткоином и акциями — это более слабое и более точное утверждение. Сигнальный уровень предсказывает повышенную вероятность нисходящего риска, но не направление, не магнитуду и не тайминг.

- РЕЗУЛЬТАТЫ ОСНОВАНЫ НА ПРОГНОЗИРОВАНИИ НА ОДИН ШАГ ВПЕРЁД. Производительность

с несколькими шагами могла бы существенно отличаться, особенно для ML, где авторегрессионное преимущество слабеет с увеличением горизонта.

- АНАЛИЗ ТРАНЗАКЦИОННЫХ ИЗДЕРЖЕК НЕ ПРОВОДИЛСЯ. Генерирует ли сигнал

риск-скорректированную прибыль в реальном портфеле после издержек — неизвестно.

5.7 Итеративная разработка модели: что менялось по версиям

Финальная модель — результат нескольких месяцев итеративного совершенствования.

ВЕРСИЯ 1 (Сентябрь 2025): минимальный базис. Семь моделей: Naive_Last, AR1, Ridge, ElasticNet, RF, GBM, XGBoost. Минимальная инженерия признаков: четыре авторегрессионных лага, короткооконная волатильность, лаговые доходности до лага 5. Без DCC-GARCH. Гиперпараметры ad hoc: Ridge α=1.0, ElasticNet α=0.01, XGBoost 1000 оценок, lr=0.05. Лучший RMSE для BTC-USD vs S&P 500 при w=30: Ridge 0.0897.

ВЕРСИЯ 2 (Ноябрь 2025): DCC-GARCH и сигнальный уровень. Введён пошаговый DCC-GARCH как ориентир. Это критическое исправление корректности: более ранний полновыборочный DCC давал бы несправедливое преимущество.

Добавлен сигнальный уровень. Гиперпараметры и признаки без изменений.

ВЕРСИЯ 3 (Февраль 2026): стабилизация. Фокус на надёжности: переход XGBoost GPU→CPU при сбое, улучшение обработки исключений, согласованный экспорт метрик. Результаты OOS практически идентичны версии 2.

ВЕРСИЯ 4 (Май 2026): расширение признаков, пересмотр регуляризации, HAR.

- ПРИЗНАКИ РАСШИРЕНЫ С ≈15 ДО ≈35. Новые признаки: моментум и z-оценка скользящей

корреляции (dep_mom_5, dep_mom_20, dep_zscore), расширенные лаги (dep_lag20, dep_lag60), 60-дневное окно волатильности, отношение волатильностей, прокси реализованной волатильности, краткосрочный моментум корреляции.

- ДОБАВЛЕНА МОДЕЛЬ HAR. Введена как теоретически обоснованная альтернатива AR1,

использующая три временных масштаба. HAR связывает AR1 точно.

- ПЕРЕСМОТРЕНА ФИЛОСОФИЯ РЕГУЛЯРИЗАЦИИ. Ridge: α снижен с 1.0 до 0.5,

добавлен StandardScaler. Эффект: RMSE Ridge для BTC vs S&P 500 при w=30 улучшился с 0.0897 до 0.0651. Для XGBoost, напротив, регуляризация УСИЛИЛАСЬ (lr: 0.05→0.02), поскольку расширенный набор признаков увеличил риск переобучения.

- АДАПТИВНЫЙ АНСАМБЛЬ с динамическими весами по обратному RMSE (60 последних).
- БУТСТРЭП-ДОВЕРИТЕЛЬНЫЕ ИНТЕРВАЛЫ И АНАЛИЗ ЧУВСТВИТЕЛЬНОСТИ к refit_every.

ЧТО ИТЕРАЦИИ НАУЧИЛИ. Самый важный урок: расширение набора признаков с 15 до 35 переменных НЕ помогло методам на основе деревьев. RMSE XGBoost практически не изменился или немного ухудшился. Ridge, напротив, улучшился существенно. Это согласуется с центральной находкой: задача имеет почти линейную авторегрессионную структуру.

Лучшие признаки маловероятно закроют оставшийся разрыв между AR1 и ML. Улучшения скорее придут от принципиально другого подхода — многошаговых горизонтов, высокочастотных данных или совместного моделирования нескольких пар корреляций одновременно.

5.8 Ограничения, честно изложенные

Главные ограничения:

- Дневная частота (без внутридневных данных)
- Горизонт один шаг вперёд
- Корреляция Пирсона как единственная мера зависимости
- Единственная базовая криптовалюта (Биткоин)
- Отсутствие портфельного бэктеста

Каждое представляет собой естественное расширение, которое могло бы уточнить или осложнить выводы. Ни одно из них не отменяет основные

эмпирические результаты в рамках того, что было реально протестировано.

ГЛАВА 6. ЗАКЛЮЧЕНИЕ

Данная диссертация ставила конкретный вопрос: помогает ли информация об эволюирующей зависимости между Биткоином и обычными активами прогнозировать эту зависимость, и можно ли превратить такие прогнозы во что-то полезное для управления рисками? Короткий ответ — да на оба вопроса, с важными оговорками о том, что означает «полезное».

Процесс зависимости предсказуем вне выборки. Этот результат подтверждается для шести пар активов, четырёх длин скользящего окна и нескольких семейств моделей при строгом пошаговом протоколе. Чем длиннее окно, тем сглаженнее и сильнее автокоррелирована цель, и тем выше OOS R^2. При 90-дневном окне даже простейшая AR(1)-модель достигает $R^2 > 0.98$ для нескольких пар.

Последнее наблюдение — также центральное ограничение. Задача прогнозирования в значительной мере решается персистентностью. Поскольку 30-дневная скользящая корреляция имеет 29 общих точек с предыдущим окном, трудно побить модель, которая просто говорит «завтрашняя корреляция будет очень похожа на сегодняшнюю». Ridge, AR(1) и HAR образуют статистически неразличимый топ-кластер; наивный базис — сразу за ними. RF, GBM и XGBoost показывают существенно хуже. Машинное обучение в форме деревьев не преодолевает авторегрессионный базис — но Ridge это делает, и все ML-модели надёжно превосходят DCC-GARCH — теоретически мотивированный эконометрический ориентир.

Это сравнение информативно: гибкие, управляемые данными методы лучше параметри- ческой альтернативы для этой конкретной задачи, даже когда они не могут превзойти простую персистентность.

Инвесторский сигнальный уровень более нюансирован. Сбалансированная точность 50–54% и AUC 0.50–0.55 умеренны; результаты выше случайного для большинства, но не всех конфигураций. Качество сигнала наиболее сильно для пары BTC–S&P 500, где крипто-набор признаков лучше всего согласуется с макрофинансовыми силами, управляющими широким стрессом акций. Для золота, серебра и индекса доллара сигнал слабее — что экономически обоснованно.

Честный практический вывод: этот тип сигнала следует рассматривать как один дополнительный вход в процесс управления рисками, а не как самостоятельный сигнал тревоги. Он не предсказывает доходности на завтра. Он даёт статистически согласованный сдвиг к осторожности, когда структура зависимости меняется — и это обоснованный сценарий использования.

Будущая работа должна протестировать фреймворк на более длинных горизонтах прогноза (где преимущества персистентности могут слабнуть быстрее), с более богатыми наборами признаков, включающими онлайн-метрики и макрофинансовые переменные, и против мер хвостовой зависимости, которые точнее отражают совместное экстремальное поведение, чем скользящая корреляция Пирсона. Портфельный бэктест с явными транзакционными издержками закрыл бы разрыв между статистической и экономической производительностью. Эти расширения остаются открытыми; данная

диссертация закладывает фундамент.

ПРИЛОЖЕНИЕ A: ОПИСАНИЕ ДАННЫХ И ДОПОЛНИТЕЛЬНЫЙ КОНТЕКСТ

A.1 Описательная роль вселенной активов

Выбор активов не произволен. Каждый инструмент представляет отдельное измерение обычной финансовой системы, с которым Биткоин может сравниваться:

- S&P 500 — широкий прокси риска рынка акций США и общего настроения инвесторов.
- NASDAQ Composite — более ориентированный на рост и технологии сегмент рынка,

особенно интересный в связи с криптоактивами.

- ETF на золото и серебро — экспозиция на драгоценные металлы, область, часто

связанная с хеджированием, инфляционными нарративами и дискуссиями о защитных активах.

- Прокси индекса доллара США — отражает макро-защитное позиционирование и

глобальную силу доллара.

- Ethereum — криптонативный сравнительный актив для контраста зависимости

внутри экосистемы с межрыночной зависимостью.

Итоговый датасет охватывает активы с разной базой инвесторов, условиями ликвидности, макро-чувствительностью и экономической интерпретацией.

A.2 Визуальный обзор датасета

[Рисунок 9: Нормализованные ценовые траектории всех активов (база = 1 на начальную дату). BTC-USD и ETH-USD показывают взрывной рост до 2021 и 2024, достигая 10–17.5x. Традиционные активы — в диапазоне 1–3x. Временной период: 2018–2026.]

[Рисунок 10: Скользящая волатильность по вселенной активов (годовая, 30-дневное окно). Биткоин и Ethereum демонстрируют значительно более высокую волатильность (периодически >100% годовых) по сравнению с традиционными активами.]

[Рисунок 11: Статическая тепловая карта корреляций ряда доходностей (полная выборка). BTC-ETH: 0.76. BTC-^GSPC: 0.28. BTC-^IXIC: 0.30. BTC-GLD: 0.10. BTC-SLV: 0.15. BTC-UUP: -0.09.]

[Рисунок 12: Обзор скользящей корреляции для всей вселенной активов — по 6 панелям для каждой пары BTC vs другой актив, при всех 4 длинах окна. Хорошо видна нестабильность корреляции во времени.]

A.3 Валидация датасета и диагностика качества

Все ценовые ряды проходят систематическую проверку качества перед любым шагом моделирования. Диагностика охватывает четыре измерения: покрытие наблюдений, частоту пропущенных значений, экстремальные доходности и

форму распределения.

ТАБЛИЦА 5: Сводка качества данных по тикеру.

Тикер	Первое набл.	Последнее набл.	N	% пропущ.	Разрывы>2д	Нул.дох.	Асим.	Эксц.	ГодВолат.%
BTC-USD	2017-11-09	2026-05-16	3053	0.00	0	0	-0.73	13.48	55.88
ETH-USD	2017-11-09	2026-05-16	3053	0.00	0	0	-0.74	10.86	72.40
GLD	2017-11-09	2026-05-16	3053	0.00	0	920	-0.87	13.63	13.88
SLV	2017-11-09	2026-05-16	3053	0.00	0	955	-2.69	49.30	28.49
UUP	2017-11-09	2026-05-16	3053	0.00	0	1001	-0.03	8.56	5.84
^GSPC	2017-11-09	2026-05-16	3053	0.00	0	914	-0.74	22.67	16.15
^IXIC	2017-11-09	2026-05-16	3053	0.00	0	915	-0.46	12.66	19.62

Примечание: «Нул.дох.» — нулевые доходности ETF в нерабочие дни биржи (артефакт торгового календаря и прямого заполнения). Криптоактивы торгуются круглосуточно, поэтому нулевых доходностей нет. Все выявленные выбросы — подлинные ценовые события, не требующие удаления.

[Рисунок 13: Окно покрытия наблюдений по тикеру. Все активы имеют идентичный согласованный диапазон дат после начала данных ETH-USD в ноябре 2017.]

[Рисунок 14: Ряды логарифмических доходностей с выбросами (|z-score| > 5σ),

отмеченными красным. Криптоактивы имеют спорадические, но крупные выбросы; традиционные активы более сдержаны, но не свободны от выбросов.]

A.4 Преобразование Фишера-z целевой переменной

[Рисунок 15: Распределение 30-дневной скользящей корреляции до и после преобразования Фишера-z для пары BTC-USD vs S&P 500. Левый график: исходная корреляция Пирсона — левостороннее распределение, ограниченное значениями (-1,1). Правый: после arctanh — более симметричное, примерно нормальное.]

A.5 Почему используются несколько скользящих окон

14-дневное, 30-дневное, 60-дневное и 90-дневное окна используются потому, что ни один горизонт зависимости не является универсально подходящим. Короткое окно более чувствительно к недавним шокам, но зашумленнее. Длинное окно даёт более гладкую цель с часто более сильной персистентностью, но медленно реагирует на смену режима.

Результаты показывают: выбор окна существенно формирует профиль предсказуемости. Длинные окна, как правило, легче прогнозировать, но их предсказательный успех также более персистентно управляемый.

A.6 Дополнительные замечания по реализации

Проект организован так, что каждый запуск пайплайна производит согласованные выходные данные в каталогах outputs/results, outputs/tables, outputs/figures, outputs/predictions. Таблицы и рисунки генерируются непосредственно из кодового пайплайна, что снижает разрыв между выполнением экспериментов и написанием диссертации.

A.7 Резюме

Приложение подтверждает важный методологический пункт: эмпирическая среда, изученная в данной диссертации, гетерогенна, нестационарна в экономической интерпретации и достаточно богата для обоснования фреймворка изменяющейся во времени зависимости.

ПРИЛОЖЕНИЕ B: ДОПОЛНИТЕЛЬНЫЕ РЕЗУЛЬТАТЫ ПРОГНОЗИРОВАНИЯ

B.1 Сравнительные рисунки по моделям

[Рисунок 16: Среднее RMSE по семействам моделей для пары BTC-USD vs ^GSPC, при всех четырёх длинах окна (14, 30, 60, 90 дней). DCC-GARCH выделяется значительно более высокими значениями RMSE при окне 14 (~0.30). Топ-кластер (Ridge, AR1, HAR, Naive_Last) существенно ниже при всех окнах.]

[Рисунок 17: Сравнение R^2 по модели и паре при окне 30 дней. Для каждой пары видны 10 столбцов. DCC-GARCH выделяется низким R^2 (~0.3–0.5) по сравнению со всеми остальными моделями (R^2 0.85–0.99).]

[Рисунок 18: Среднее улучшение RMSE над наивным базисом (%). Все ML-модели в левой части (улучшение): HAR и Ridge вверху. DCC-GARCH, XGB_GPU, RF в правой части (ухудшение — хуже наивного базиса).]

B.2 Диагностика гиперпараметров и признаков

[Рисунок 19: CV RMSE при кросс-валидационном поиске по сетке для задачи прогнозирования BTC-USD vs S&P 500 при w=30. Ridge: 0.0632, ElasticNet: 0.0633, RF: 0.0904, XGB: 0.0919.]

[Рисунок 20: Путь регуляризации Ridge (CV RMSE при разных alpha). Оптимальный alpha=0.001 при поиске по сетке (красная пунктирная линия). Рабочее значение alpha=0.5 используется в финальной модели.]

[Рисунок 21: Значимость признаков Random Forest (топ-8) для пары BTC-USD vs ^GSPC при w=30. Слева: полный рейтинг — dep_lag1 доминирует (>0.8). Справа: рейтинг без dep_lag1 — dep_mom_5, dep_zscore, dep_lag5, dep_mom_20 на первых местах.]

B.3 Диагностические рисунки для репрезентативной пары акций

[Рисунок 22: Чувствительность RMSE XGBoost к длине скользящего окна для всех пар. RMSE снижается монотонно от w=14 до w=90 для всех пар. BTC-ETH-USD показывает наименьший RMSE; BTC-UUP — наибольший.]

[Рисунок 23: Диагностический scatter-plot прогнозов для пары BTC-USD vs S&P 500. Слева: HAR (R^2=0.940, RMSE=0.0650) — точки тесно вдоль диагонали. Справа: DCC-GARCH (R^2=0.462, RMSE=0.1943) — значительное рассеяние, систематическое смещение.]

[Рисунок 24: Распределение ошибок прогноза для репрезентативного эксперимента. Три панели: гистограммы ошибок (HAR vs DCC), Q-Q для HAR-ошибок, Q-Q для DCC-ошибок. HAR-ошибки примерно нормальные с небольшими хвостами; DCC-ошибки существенно не нормальные.]

B.4 Чувствительность по парам активов

[Рисунки 25–29: Анализ чувствительности скользящей корреляции для каждой пары (^IXIC, GLD, SLV, UUP, ETH-USD) при всех четырёх длинах окна (w=14, 30, 60, 90). Показывает различное поведение: ETH-USD очень высокая корреляция (0.4–1.0), GLD/SLV/UUP колеблются вокруг нуля, акционные индексы — промежуточные.]

B.5 Интерпретация

Дополнительные рисунки подтверждают несколько пунктов из основного текста. Качество прогноза существенно зависит от выбора скользящего окна, цель остаётся сильно персистентно управляемой, а различия в

производительности между семействами моделей легче интерпретировать через сравнительные графики, чем через единственную ранговую статистику.

ПРИЛОЖЕНИЕ C: ДОПОЛНИТЕЛЬНЫЕ РЕЗУЛЬТАТЫ СИГНАЛЬНОГО УРОВНЯ

C.1 Рисунки сигнала по активу

[Рисунок 30: Выход сигнального уровня для связи Биткоин–NASDAQ при 30-дневном окне (2022-07 — 2026-07). Верхняя панель: предсказанная вероятность стресса (Logit P(down)), порог 0.55. Нижняя панель: помеченные и пропущенные стрессовые дни NASDAQ.]

[Рисунок 31: Выход сигнального уровня для связи Биткоин–золото при 30-дневном окне. Сигнал слабее, больше пропущенных стрессовых событий по сравнению с парой акций.]

[Рисунок 32: Выход сигнального уровня для связи Биткоин–серебро при 30-дневном окне.]

[Рисунок 33: Выход сигнального уровня для связи Биткоин–UUP при 30-дневном окне. Наиболее шумный сигнал среди всех пар.]

C.2 Интерпретация межрыночных предупреждений

Дополнительные рисунки сигнала показывают, что практический уровень ведёт себя по-разному в разных рынках. Цель S&P 500 демонстрирует наиболее чёткие предупредительные эпизоды; цель NASDAQ заметно слабее, с несколькими конфигурациями, опускающимися ниже случайного. Это объясняется концентрацией NASDAQ в технологическом секторе. Металлические и долларовые цели более шумны, но не равномерно неинформативны. Эта гетерогенность подтверждает интерпретацию, что сигнальный уровень инвестора следует использовать избирательно.

C.3 Сводная таблица

ТАБЛИЦА 6: Средняя эффективность сигнального уровня по семействам классификаторов.

Модель	Balanced Accuracy	F1_down	AUC
Logit	0.511	0.214	0.513
GBM_Cls	0.508	0.158	0.517
RF_Cls	0.502	0.042	0.519

Эти сводные значения подтверждают: сигнальный уровень значим, но умерен. Его сильнейшая роль — как дополнительный предупредительный механизм, а не как самостоятельный аллокатор.

[Рисунки 34–35: Дополнительные сигналы S&P 500 при 14-дневном и 60-дневном окнах.]

[Рисунок 36: Дополнительный сигнал S&P 500 при 90-дневном окне.]

[Рисунки 37–38: Дополнительные сигналы NASDAQ при 14-дневном и 60-дневном окнах.]

ПРИЛОЖЕНИЕ D: ВОСПРОИЗВОДИМОСТЬ И СТРУКТУРА КОДА

D.1 Организация проекта

Вычислительная часть диссертации структурирована как воспроизводимый исследовательский проект. Основные каталоги:

master-thesis/ ├── main.py # главная точка входа пайплайна ├── run_all.py # полная автоматизация: пайплайн + ноутбуки + LaTeX ├── config.yaml # конфигурация экспериментов ├── requirements.txt # зависимости Python ├── thesis_app/ # основные модули Python │ ├── pipeline.py # данные, признаки, walk-forward, метрики │ ├── dcc_walk.py # защищённая от утечек реализация DCC-GARCH │ ├── signal_layer.py # сигнальный уровень инвестора │ ├── notebook_helpers.py # общие вспомогательные функции │ ├── data_quality.py # диагностика качества данных │ └── regime_analysis.py # исторический каталог режимов ├── notebooks/ # семь Jupyter-ноутбуков (01–07) ├── data/raw/ # кэшированные скачанные ценовые данные ├── data/processed/ # производные доходности ├── outputs/results/ # CSV-сводки экспериментов ├── outputs/tables/ # таблицы, экспортированные в LaTeX ├── outputs/figures/ # все сгенерированные рисунки └── thesis/ # данный документ

D.2 Основные модули реализации

- pipeline.py: оркестрирует полный рабочий процесс прогнозирования зависимости.
- dcc_walk.py: содержит защищённую от утечек пошаговую реализацию DCC-GARCH.
- signal_layer.py: определяет сигнальный уровень инвестора и метрики классификации.
- notebook_helpers.py: общие вспомогательные функции построения графиков.
- data_quality.py: диагностика пропущенных значений и выбросов.
- regime_analysis.py: реализует исторический каталог режимов.

D.3 Аналитические ноутбуки

Семь Jupyter-ноутбуков дополняют основной пайплайн:

1. 01_EDA_Dataset.ipynb — разведочный анализ данных. Нормализованные ценовые

траектории, профили скользящей волатильности, тепловая карта парных корреляций, временные ряды скользящих корреляций и сравнительный график распределений до и после преобразования Фишера-z.

2. 02_GridSearch.ipynb — диагностика поиска гиперпараметров. Кросс-валидационные

поверхности RMSE, пути регуляризации, рейтинги важности признаков RF.

3. 03_Model_Comparison.ipynb — сводка рейтинга моделей. Гистограмма RMSE,

сравнение R^2 по окнам, улучшение над наивным базисом.

4. 04_DM_Tests_Visuals.ipynb — визуализация теста DM. Тепловая карта и репрезентативный прогнозный панель (Рисунок 5).

5. 05_XGB_vs_DCC.ipynb — диагностика профиля ошибок. Скользящий RMSE, scatter-plots прогнозов, гистограммы распределений ошибок.

6. 06_Regime_Analysis.ipynb — режимно-условный анализ. Статистика каталога режимов, гистограммы RMSE.

7. 07_Robustness_Checks.ipynb — анализ надёжности и чувствительности. Развёртки чувствительности к refit_every, кривые чувствительности порогов стресса, бутстрэп-доверительные интервалы, межактивный тест DM.

D.4 Поток выполнения

Полный пайплайн запускается через единственную точку входа:

python run_all.py

Это выполняет:

1. Загрузку конфигурации.
2. Загрузку или обновление данных с Yahoo Finance.
3. Вычисление логарифмических доходностей.
4. Генерацию целей скользящей корреляции.
5. Построение матриц признаков.
6. Обучение всех моделей в пошаговом режиме.
7. Вычисление метрик, тестов DM и экспорт таблиц.
8. Запуск сигнального уровня инвестора.
9. Выполнение семи ноутбуков.
10. Запуск автоматического набора тестов pytest (81 тест).
11. Компиляцию LaTeX-документа диссертации.

D.5 Конфигурация

Параметры экспериментов хранятся в config.yaml:

start_date: "2016-01-01" # эффективное начало: 2017-11-09 (доступность ETH) end_date: null # null = скачать до сегодня assets: crypto: ["BTC-USD", "ETH-USD"] traditional: ["^GSPC", "^IXIC", "GLD", "SLV", "UUP"] base_asset: "BTC-USD" rolling_windows: [14, 30, 60, 90] forecast_horizon: 1 use_fisher_transform: true min_train_size: 800 refit_every: 20 xgb_device: "cuda" random_state: 42

D.6 Проверка при очистке проекта

Во время доработки проекта ряд ошибок реализации был исправлен:

- Введён защищённый от утечек пошаговый DCC-ориентир.
- Пайплайн метрик унифицирован для всех моделей.
- Добавлено масштабирование признаков для регуляризованных линейных моделей.

- Блок XGBoost сделан надёжным к сбою GPU (резерв на CPU).
- Сигнальный уровень интегрирован в основной пайплайн.
- Стабилизированы импорты ноутбуков и логика построения графиков.

D.7 Как пересобрать артефакты диссертации

Полный рабочий процесс можно перезапустить с нуля:

python run_all.py

Или пошагово:

1. python main.py
2. jupyter nbconvert --to notebook --execute notebooks/01_EDA_Dataset.ipynb ...
3. python -m pytest tests/ -v --junit-xml=outputs/results/test_results.xml
4. pdflatex main.tex && biber main && pdflatex main.tex && pdflatex main.tex

D.8 Итоговое замечание о воспроизводимости

Ценность воспроизводимости в данной диссертации не только техническая. Поскольку тема касается финансового прогнозирования, где случайные утечки и избирательная отчётность являются постоянными рисками, прозрачная и перезапускаемая кодовая база напрямую усиливает достоверность эмпирических выводов.

ПРИЛОЖЕНИЕ E: ДОПОЛНИТЕЛЬНЫЕ СТАТИСТИЧЕСКИЕ ТЕСТЫ

E.1 Тест прогностической эффективности Минцера-Зарновица

Тест Минцера-Зарновица (MZ) [21] проверяет, являются ли прогнозы несмещёнными и информационно эффективными. Для каждой модели оценивается вспомогательная регрессия:

$$y_t = \alpha + \beta \cdot \hat{y}_t + \varepsilon_t$$

методом МНК и тестируется совместная нулевая гипотеза H_0: $\alpha=0$, $\beta=1$ с помощью F-статистики. Отклонение ($p < 0.05$) указывает, что прогноз либо смещён ($\alpha \neq 0$), либо не использует полностью доступную информацию ($\beta \neq 1$).

ТАБЛИЦА 7: Эффективность прогнозов Минцера-Зарновица — процент из 24 экспериментов, прошедших совместный F-тест ($p \geq 0.05$), и средние оценки коэффициентов.

Модель	Эффективных(%)	$\bar{\alpha}$	$\bar{\beta}$	$\bar{F}$
AR1	70.8	+0.0006	0.9976	2.0
HAR	70.8	+0.0006	0.9974	2.4
Ridge	45.8	-0.0015	0.9992	4.1
RF	16.7	-0.0019	1.0140	26.2
Naive_Last	8.3	+0.0097	0.9706	16.3
GBM	8.3	-0.0046	1.0226	35.0
ElasticNet	4.2	-0.0056	1.0175	20.9
Ensemble	0.0	-0.0077	1.0252	30.1
XGB_GPU	0.0	-0.0252	1.0979	202.2
DCC_GARCH	0.0	-0.0881	1.4433	237.3

AR1 и HAR проходят тест эффективности с одинаковым показателем (70.8%), подтверждая, что обе модели почти оптимально используют доступную информацию. Ridge наиболее эффективен среди регуляризованных ML-моделей (45.8%). DCC-GARCH не проходит ни разу: его $\beta=1.44$ отражает сильную систематическую тенденцию переоценивать магнитуды корреляций.

ТАБЛИЦА 8: Тест Минцера-Зарновица для пары BTC-USD vs S&P 500, w=30.

Модель	$\hat{\alpha}$	$\hat{\beta}$	F	p_MZ	Эффективно
Ridge	+0.0071	0.9903	4.76	0.009	Нет
AR1	+0.0071	0.9909	5.07	0.006	Нет
HAR	+0.0074	0.9913	5.77	0.003	Нет
Naive_Last	+0.0114	0.9695	16.74	<0.001	Нет
ElasticNet	+0.0065	1.0048	17.18	<0.001	Нет
Ensemble	+0.0086	1.0113	39.91	<0.001	Нет
RF	+0.0221	0.9951	57.04	<0.001	Нет
GBM	+0.0226	0.9945	62.30	<0.001	Нет
DCC_GARCH	-0.0886	1.4616	261.03	<0.001	Нет
XGB_GPU	+0.0436	1.0316	318.18	<0.001	Нет

При данной паре и окне все модели технически отклоняются, но градиент производительности крутой. Ridge (F=4.76), AR1 (F=5.07) и HAR (F=5.77) имеют коэффициенты, очень близкие к (0,1), указывая на почти эффективное использование информации. Статистики DCC-GARCH (261.0) и XGBoost (318.2) выделяются как наиболее серьёзно неверно специфицированные.

E.2 Диагностика остатков: тесты Льюнга-Бокса и ARCH LM

Два классических теста применяются к ошибкам прогноза OOS e_t = y_t - ŷ_t для каждой комбинации «модель × зависимость × окно» (192 случая).

Тест Льюнга-Бокса Q (10 лагов): тестирует H_0: отсутствие серийной автокорреляции. Тест ARCH LM (5 лагов): регрессирует e^2_t на его лаги, тестирует H_0: отсутствие условной гетероскедастичности.

ТАБЛИЦА 9: Диагностика остатков — процент из 24 экспериментов, прошедших тест Льюнга-Бокса и тест ARCH LM при α=0.05.

Модель	Нет автокорр. (%)	Нет ARCH (%)
Naive_Last	50.0	58.3
AR1	41.7	62.5
HAR	41.7	58.3
Ridge	20.8	54.2
ElasticNet	0.0	37.5
Ensemble	0.0	12.5
RF	0.0	0.0
GBM	0.0	0.0
XGB_GPU	0.0	0.0
DCC_GARCH	0.0	0.0

Результаты следуют чёткому градиенту. Naive_Last и авторегрессионные модели (AR1, HAR) частично захватывают серийную структуру (42–50%). Ridge проходит в 21% случаев. ElasticNet, несмотря на линейную форму, проходит 0% тестов на автокорреляцию, но сохраняет значимые показатели прохождения ARCH (38%). Методы на основе деревьев и DCC-GARCH оставляют значимую автокорреляцию и гетероскедастичность в каждом эксперименте.

E.3 Скорректированный тест Дибольда-Мариано Харви-Лейборна-Ньюболда (HLN)

Стандартная статистика DM использует асимптотическое стандартное нормальное распределение, которое склонно чрезмерно отклонять в конечных выборках. Харви, Лейборн и Ньюболд [22] предлагают умножить статистику DM на поправочный коэффициент:

k = sqrt[(n + 1 - 2h + h(h-1)/n) / n],

где n — число прогнозных наблюдений, h — горизонт прогноза, и сравнить результат с t(n-1) распределением. Для h=1 и n>1000 коэффициент k≈1.000.

ТАБЛИЦА 10: HLN-скорректированный тест DM: ML-модели vs DCC-GARCH, BTC-USD vs S&P 500, w=30. Все модели превосходят DCC-GARCH при p<0.001 по обоим тестам.

Модель	DM	p_DM	DM_HLN	p_HLN	Знач.
Ridge	26.86	<0.001	26.86	<0.001	***
HAR	26.83	<0.001	26.83	<0.001	***
ElasticNet	26.97	<0.001	26.97	<0.001	***
Ensemble	27.05	<0.001	27.04	<0.001	***
RF	26.44	<0.001	26.43	<0.001	***
GBM	26.16	<0.001	26.16	<0.001	***
XGB_GPU	24.29	<0.001	24.28	<0.001	***

Применительно ко всем 336 сравнениям DM (168 ML-моделей vs DCC-GARCH и 168 vs Naive_Last) поправка HLN не меняет ни одного решения о значимости на 5%-ном уровне (средний поправочный коэффициент k=1.000226).

E.4 Автоматизированный набор тестов

В дополнение к статистическим тестам выше, полный проект поставляется с автоматизированным набором pytest из 81 юнит- и интеграционного теста, организованных в десять тестовых классов:

- Целостность датасета — файлы цен и доходностей существуют, тикеры верны,

цены положительны, даты отсортированы и не дублируются, данные до 2026+.

- Качество данных — пороги пропущенных значений, обнаружение нулевых цен,

разумная годовая волатильность, попарное перекрытие покрытия.

- Инженерия признаков — идентичность преобразования Фишера-z в оба конца,

диапазон скользящей корреляции, отсутствие заглядывания в будущее.

- Метрики моделей — RMSE>0, $R^2 \leq 1$, MAE≤RMSE, все окна и модели присутствуют,

AR1 в среднем превосходит DCC-GARCH.

- Тесты DM — конечные статистики DM, p-значения в [0,1], верное знаковое

соглашение для Ridge vs DCC-GARCH.

- Метрики сигнала — Balanced Accuracy и F1 в [0,1], AUC выше случайного,

exit rate в разумных пределах.

- Walk-Forward — верное число предсказательных CSV, нетривиальные прогнозы,

согласование индекса с доходностями.

- Выходные файлы — все ожидаемые CSV, JSON, PNG и .tex артефакты присутствуют.
- Bootstrap CI — нижний ≤ средний ≤ верхний для RMSE и R^2; ширина CI < 0.10.
- Чувствительность — все пять значений refit_every присутствуют; RMSE в физически

правдоподобном диапазоне.

Все 81 тест проходят на текущих выходных данных.

СПИСОК ЛИТЕРАТУРЫ

[1] François Longin, Bruno Solnik. «Extreme Correlation of International Equity Markets». The Journal of Finance 56.2 (2001): 649–676.

[2] Elie Bouri et al. «On the hedge and safe haven properties of Bitcoin». Finance Research Letters 20 (2017): 192–198.

[3] Shaen Corbet et al. «Exploring the dynamic relationships between cryptocurrencies and other financial assets». Economics Letters 165 (2018): 28–34.

[4] Qiang Ji et al. «Network causality structures among Bitcoin and other financial assets». Quarterly Review of Economics and Finance 70 (2018): 203–213.

[5] Ladislav Kristoufek. «What are Bitcoin's main drivers?». PLOS ONE 10.4 (2015).

[6] Anne Haubo Dyhrberg. «Bitcoin, gold and the dollar — A GARCH volatility analysis». Finance Research Letters 16 (2016): 85–92.

[7] Tony Klein et al. «Bitcoin is not the new gold». International Review of Financial Analysis 59 (2018): 105–116.

[8] Andrew J. Patton. «Modelling asymmetric exchange rate dependence». International Economic Review 47.2 (2006): 527–556.

[9] Robert F. Engle, Kevin Sheppard. «Theoretical and empirical properties of dynamic conditional correlation multivariate GARCH». NBER Working Paper 8554 (2001).

[10] Robert F. Engle. «Dynamic Conditional Correlation: A Simple Class of Multivariate GARCH Models». Journal of Business & Economic Statistics 20.3 (2002).

[11] Fulvio Corsi. «A simple approximate long-memory model of realized volatility». Journal of Financial Econometrics 7.2 (2009): 174–196.

[12] Torben G. Andersen et al. «Modeling and forecasting realized volatility». Econometrica 71.2 (2003): 579–625.

[13] Hui Zou, Trevor Hastie. «Regularization and Variable Selection via the Elastic Net». JRSS Series B 67.2 (2005): 301–320.

[14] Leo Breiman. «Random Forests». Machine Learning 45.1 (2001): 5–32.

[15] Jerome H. Friedman. «Greedy Function Approximation: A Gradient Boosting Machine». Annals of Statistics 29.5 (2001): 1189–1232.

[16] Tianqi Chen, Carlos Guestrin. «XGBoost: A Scalable Tree Boosting System». KDD 2016: 785–794.

[17] Francis X. Diebold, Roberto S. Mariano. «Comparing Predictive Accuracy». Journal of Business & Economic Statistics 13.3 (1995): 253–263.

[18] yfinance developers. yfinance Documentation, 2026. https://ranaroussi.github.io/yfinance/

[19] Marcos Lopez de Prado. Advances in Financial Machine Learning. Wiley, 2018.

[20] Ivo Welch, Amit Goyal. «A Comprehensive Look at the Empirical Performance of Equity Premium Prediction». Review of Financial Studies 21.4 (2008): 1455–1508.

[21] Jacob Mincer, Victor Zarnowitz. «The Evaluation of Economic Forecasts». Economic Forecasts and Expectations. NBER, 1969: 1–46.

[22] David Harvey, Stephen Leybourne, Paul Newbold. «Testing the equality of prediction mean squared errors». International Journal of Forecasting 13.2 (1997): 281–291.

[23] Факультет инженерских наук, Университет в Крагуевце. Мастер-диссертации, 2026. https://www.cis.kg.ac.rs/master/

[24] elektrotehnika. finlatex: finthesis dokument klasa, 2026. https://github.com/elektrotehnika/finlatex

[25] scikit-learn developers. scikit-learn User Guide, 2026. https://scikit-learn.org/stable/user_guide.html

[26] XGBoost developers. XGBoost Documentation, 2026. https://xgboost.readthedocs.io/en/stable/

[27] arch developers. arch Documentation, 2026. https://bashtage.github.io/arch/

[28] Shihao Gu, Bryan Kelly, Dacheng Xiu. «Empirical asset pricing via machine learning». Review of Financial Studies 33.5 (2020): 2223–2273.

[29] Satoshi Nakamoto. «Bitcoin: A peer-to-peer electronic cash system». Decentralized Business Review (2008).

[30] Greta M. Ljung, George E.P. Box. «On a measure of lack of fit in time series models». Biometrika 65.2 (1978): 297–303.

[31] Robert F. Engle. «Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation». Econometrica 50.4 (1982): 987–1007.

ОПУБЛИКОВАННЫЕ РАБОТЫ

Кандидат не публиковал работ в ходе выполнения магистерской диссертации.

КОНЕЦ ПЕРЕВОДА